BỘ CÔNG THƯƠNG

TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP VIỆT-HUNG



BÁO CÁO TỔNG KẾT

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN
NĂM HỌC 2026

Nghiên cứu xây dựng mô hình kiểm tra trùng lặp văn bản dựa trên xử lý ngôn ngữ tự nhiên

Họ và tên: Cao Văn Hưng **Lớp: K4618-CNTT1**

Giảng viên hướng dẫn: ThS.Chu Thị Thanh Xuân

Hà Nội, Tháng 10 Năm 2026

BỘ CÔNG THƯƠNG

TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP VIỆT-HUNG



BÁO CÁO TỔNG KẾT

ĐỀ TÀI NGHIÊN CỨU KHOA HỌC SINH VIÊN
NĂM HỌC 2026

Nghiên cứu xây dựng mô hình kiểm tra trùng lặp văn bản dựa trên xử lý ngôn ngữ tự nhiên

Họ và tên: Cao Văn Hưng **Lớp: K4618-CNTT1**

Giảng viên hướng dẫn: ThS.Chu Thị Thanh Xuân

Hà Nội, Tháng 10 Năm 2026

BỘ CÔNG THƯƠNG
TRƯỜNG ĐHCN VIỆT-HUNG

THÔNG TIN KẾT QUẢ NGHIÊN CỨU CỦA ĐỀ TÀI

1. Thông tin chung:

- Tên đề tài: Nghiên cứu xây dựng mô hình kiểm tra trùng lặp văn bản dựa trên xử lý ngôn ngữ tự nhiên.
- Sinh viên thực hiện: Cao Văn Hưng
- Lớp K4618-CNTT1 Khoa: CNTT Năm thứ: 4 Số năm đào tạo: 4,5
- Người hướng dẫn chính: ThS.Chu Thị Thanh Xuân

2. Mục tiêu đề tài:

Phát hiện và giảm thiểu tình trạng sao chép nội dung: Xây dựng một công cụ giúp phát hiện nội dung trùng lặp hoặc sao chép trong các báo cáo, nhằm đảm bảo tính trung thực và sự công bằng trong quá trình đánh giá.

Nâng cao ý thức học thuật của sinh viên: Giúp sinh viên hiểu rõ tầm quan trọng của việc tự nghiên cứu và xây dựng báo cáo học thuật, từ đó nâng cao tư duy độc lập, khả năng tổng hợp tài liệu và ý thức tuân thủ chuẩn mực học thuật.

Hỗ trợ giảng viên trong việc đánh giá: Cung cấp một công cụ tự động, nhanh chóng và chính xác để hỗ trợ giảng viên kiểm tra tính nguyên bản của các báo cáo, giảm thiểu thời gian và công sức so với việc kiểm tra thủ công.

Cải thiện chất lượng đào tạo: Góp phần nâng cao chất lượng đào tạo của khoa Công nghệ Thông tin bằng cách đảm bảo các sản phẩm học thuật của sinh viên đạt chuẩn chất lượng và đạo đức học thuật.

Ứng dụng công nghệ trong giáo dục: Ứng dụng công nghệ xử lý ngôn ngữ tự nhiên và các thuật toán đo độ tương đồng văn bản trong giáo dục nhằm xây dựng công cụ phát hiện trùng lặp văn bản hiệu quả, phù hợp với đặc thù dữ liệu văn bản tiếng Việt trong môi trường học thuật.

3. Tính mới và sáng tạo:

Mô hình đối sánh văn bản lai (Hybrid Text Similarity Matching Model): Đề xuất mô hình phát hiện trùng lặp văn bản kết hợp nhiều kỹ thuật đo độ tương đồng khác nhau, bao gồm Exact Match, Inverted Index, Winnowing, TF-IDF/Cosine Similarity và Jaccard Similarity. Việc kết hợp nhiều phương pháp trong cùng một quy trình giúp tận

dụng ưu điểm của từng kỹ thuật và nâng cao hiệu quả phát hiện trùng lặp đối với nhiều dạng sao chép khác nhau.

Cơ chế phát hiện trùng lặp đa mức: Hệ thống không chỉ xác định tỷ lệ trùng lặp tổng thể của tài liệu mà còn thực hiện đối sánh ở cấp độ câu và đoạn văn. Cách tiếp cận này giúp cung cấp thông tin chi tiết hơn về vị trí và mức độ trùng lặp so với các phương pháp chỉ đánh giá trên phạm vi toàn bộ tài liệu.

Cơ chế phát hiện đoạn trùng liên tiếp và nội dung chắp vá (Passage Match và Patchwork Match): Hệ thống tự động nhóm các câu trùng lặp liên tiếp thành các đoạn văn hoàn chỉnh, đồng thời phát hiện các trường hợp sao chép từ nhiều nguồn khác nhau trong cùng một tài liệu. Đây là cơ chế hỗ trợ nhận diện dạng đạo văn chắp vá, một trong những hình thức sao chép khó phát hiện bằng các phương pháp đối sánh thông thường.

Cơ chế trực quan hóa kết quả kiểm tra: Kết quả phát hiện trùng lặp được trình bày trực quan theo từng câu, từng đoạn và từng nguồn tham chiếu, giúp người sử dụng dễ dàng xác định nội dung trùng lặp và đánh giá mức độ sao chép của tài liệu.

Kiến trúc xử lý bất đồng bộ sử dụng BullMQ và Redis: Xây dựng cơ chế hàng đợi tác vụ giúp tách biệt quá trình tiếp nhận tài liệu và quá trình xử lý kiểm tra trùng lặp. Kiến trúc này hỗ trợ xử lý nhiều yêu cầu đồng thời, nâng cao tính ổn định và khả năng mở rộng của hệ thống.

4. Kết quả nghiên cứu:

4.1. Kết quả chức năng hệ thống

Sau quá trình nghiên cứu, thiết kế và triển khai thực nghiệm, đề tài đã xây dựng thành công hệ thống kiểm tra trùng lặp văn bản dựa trên xử lý ngôn ngữ tự nhiên, đáp ứng các mục tiêu nghiên cứu đã đề ra.

Các chức năng chính của hệ thống bao gồm:

- Hệ thống cho phép người dùng tải lên tài liệu định dạng DOCX hoặc PDF để thực hiện kiểm tra trùng lặp.
- Hệ thống tự động tiền xử lý văn bản, chuẩn hóa dữ liệu và thực hiện đối sánh với các tài liệu trong cơ sở dữ liệu mẫu.
- Hệ thống tính toán và trả về tỷ lệ trùng lặp tổng thể của tài liệu cùng với thông tin chi tiết theo từng nguồn tham chiếu.

- Hệ thống phát hiện được các trường hợp sao chép nguyên văn ở mức câu, các đoạn sao chép liên tiếp cũng như các trường hợp sao chép chắp vá từ nhiều nguồn khác nhau.
- Hệ thống hỗ trợ đánh dấu trực quan các nội dung trùng lặp trên tài liệu kết quả, giúp người sử dụng dễ dàng xác định vị trí và mức độ trùng lặp của từng nội dung.
- Hệ thống cung cấp thống kê chi tiết về số lượng câu trùng lặp, số lượng đoạn trùng lặp, tỷ lệ trùng lặp theo từng nguồn và các thông tin phục vụ quá trình đánh giá.
- Kết quả thực nghiệm trên các bộ dữ liệu kiểm thử được xây dựng từ nhiều kịch bản khác nhau cho thấy hệ thống xác định chính xác các nội dung trùng lặp, các đoạn trùng lặp liên tiếp và các trường hợp sao chép chắp vá, đáp ứng yêu cầu đặt ra đối với bài toán kiểm tra trùng lặp văn bản trong môi trường học thuật.

4.2. Kết quả xây dựng hệ thống

Đề tài đã hoàn thiện thành công một hệ thống kiểm tra trùng lặp văn bản hoàn chỉnh trên nền tảng Node.js, MongoDB, Redis và BullMQ.

Các kết quả xây dựng hệ thống bao gồm:

- Xây dựng quy trình xử lý khép kín từ tiếp nhận tài liệu, tiền xử lý dữ liệu, phân tích văn bản, phát hiện nội dung trùng lặp, lưu trữ kết quả đến hiển thị thông tin cho người sử dụng.
- Hoàn thiện mô hình đối sánh văn bản đa tầng kết hợp nhiều kỹ thuật đo độ tương đồng như Exact Match, Inverted Index, Winnowing, TF-IDF/Cosine Similarity và Jaccard Similarity nhằm nâng cao hiệu quả phát hiện trùng lặp.
- Xây dựng cơ chế phát hiện trùng lặp ở nhiều mức độ khác nhau, bao gồm mức câu, mức đoạn và đoạn chắp vá, giúp tăng khả năng nhận diện các hình thức sao chép phổ biến trong báo cáo học thuật.
- Hoàn thiện chức năng trực quan hóa kết quả kiểm tra bằng cách đánh dấu các nội dung trùng lặp trên tài liệu và liên kết tới các nguồn tham chiếu tương ứng.
- Xây dựng hệ thống quản lý kết quả kiểm tra, thống kê chi tiết và theo dõi thông tin phục vụ quá trình đánh giá và tra cứu sau này.

4.3. Hiệu năng và độ ổn định thực tế

Trong quá trình triển khai và kiểm thử thực nghiệm, hệ thống cho thấy khả năng vận hành ổn định và đáp ứng tốt các yêu cầu xử lý thực tế.

Các kết quả đạt được về hiệu năng và độ ổn định bao gồm:

- Hệ thống được triển khai theo mô hình xử lý bất đồng bộ, cho phép tách biệt quá trình tiếp nhận tài liệu và quá trình xử lý kiểm tra trùng lặp, góp phần nâng cao hiệu quả vận hành tổng thể.
- Hệ thống có khả năng tiếp nhận và xử lý nhiều yêu cầu kiểm tra đồng thời mà không ảnh hưởng đến tính ổn định của các tác vụ đang thực hiện.
- Cơ chế hàng đợi tác vụ giúp kiểm soát luồng xử lý, hạn chế hiện tượng quá tải khi số lượng tài liệu cần kiểm tra tăng lên.
- Hệ thống hỗ trợ giám sát tiến trình xử lý theo thời gian thực, cho phép cập nhật trạng thái thực hiện của từng nhiệm vụ và cung cấp phản hồi trực quan cho người sử dụng.
- Hệ thống tự động ghi nhận lỗi phát sinh, cập nhật trạng thái xử lý và lưu trữ thông tin liên quan nhằm đảm bảo tính toàn vẹn của dữ liệu trong quá trình vận hành.
- Kết quả kiểm thử thực nghiệm cho thấy hệ thống duy trì khả năng hoạt động ổn định trên các bộ dữ liệu có kích thước khác nhau, đồng thời đáp ứng tốt yêu cầu kiểm tra trùng lặp trong môi trường học thuật.
- Hệ thống có khả năng mở rộng về quy mô dữ liệu và số lượng tài liệu kiểm tra trong tương lai, tạo tiền đề cho việc tiếp tục phát triển và ứng dụng thực tế trong công tác quản lý và đánh giá học thuật.

5. Đóng góp về mặt kinh tế - xã hội, giáo dục và đào tạo, an ninh, quốc phòng và khả năng áp dụng của đề tài:

Đề tài đã xây dựng thành công hệ thống kiểm tra trùng lặp văn bản tiếng Việt dựa trên các kỹ thuật xử lý ngôn ngữ tự nhiên, góp phần hỗ trợ công tác đánh giá và quản lý các tài liệu học thuật trong môi trường giáo dục.

Về mặt giáo dục và đào tạo

- Hệ thống hỗ trợ sinh viên kiểm tra mức độ trùng lặp của báo cáo, đồ án và khóa luận trước khi nộp, góp phần nâng cao ý thức tuân thủ đạo đức học thuật, kỹ năng nghiên cứu và khả năng xây dựng nội dung độc lập.

- Hệ thống hỗ trợ giảng viên phát hiện nhanh các trường hợp sao chép nguyên văn, sao chép theo đoạn liên tiếp và sao chép chắp vá từ nhiều nguồn khác nhau. Kết quả kiểm tra chi tiết giúp nâng cao hiệu quả đánh giá, giảm khối lượng kiểm tra thủ công và tăng tính khách quan trong quá trình chấm điểm.

Về mặt kinh tế - xã hội

- Đề tài cung cấp một giải pháp kiểm tra trùng lặp văn bản có chi phí triển khai thấp nhờ sử dụng các công nghệ và nền tảng mã nguồn mở. Hệ thống có thể vận hành trên các cấu hình máy tính phổ thông, không yêu cầu hạ tầng phần cứng chuyên dụng.
- Việc ứng dụng hệ thống trong quá trình đào tạo góp phần nâng cao chất lượng các sản phẩm học thuật, xây dựng môi trường học tập trung thực và hạn chế tình trạng sao chép nội dung trong học tập và nghiên cứu.

Về mặt an ninh, quốc phòng và quản lý thông tin

- Hệ thống cho phép lưu trữ và xử lý dữ liệu trên hạ tầng của đơn vị triển khai, hỗ trợ quản lý tập trung các tài liệu học thuật và kết quả kiểm tra. Cách tiếp cận này giúp nâng cao khả năng kiểm soát dữ liệu và giảm sự phụ thuộc vào các dịch vụ kiểm tra trực tuyến bên ngoài.
- Kết quả nghiên cứu có thể tham khảo cho các bài toán quản lý tài liệu số, phân tích văn bản và kiểm soát nội dung trong các môi trường yêu cầu mức độ bảo mật dữ liệu cao.

Về khả năng áp dụng

- Hệ thống có thể được triển khai để kiểm tra bài tập lớn, báo cáo thực tập, đồ án môn học, khóa luận tốt nghiệp và các tài liệu học thuật khác trong các cơ sở giáo dục.
- Kiến trúc hệ thống cho phép mở rộng quy mô dữ liệu và tích hợp với các hệ thống quản lý học tập hoặc kho học liệu điện tử trong tương lai.

Ngày tháng năm 2026

Sinh viên (Chủ nhiệm đề tài)

(ký, họ và tên)



Cao Văn Hưng

Nhận xét của GV hướng dẫn chính về những đóng góp khoa học của sinh viên thực hiện đề tài *(phần này do người hướng dẫn ghi)*:

……

……

……

……

……

……

……

……

……

……

……

……

……

……

……

……

Xác nhận của đơn vị

Ngày tháng năm 2026

GVHD thực hiện đề tài

(ký, họ và tên)

Chu Thị Thanh Xuân

MỤC LỤC

CHƯƠNG 1 CƠ SỞ LÝ THUYẾT 1
1.1. Tổng quan về bài toán kiểm tra trùng lặp văn bản 1
1.1.1. Khái niệm liêm chính học thuật 1
1.1.2. Khái niệm đạo văn và trùng lặp văn bản 1
1.1.3. Các hình thức đạo văn trong học thuật 2
1.1.4. Thực trạng đạo văn trong giáo dục và nghiên cứu khoa học 4
1.1.5. Vai trò của các hệ thống kiểm tra trùng lặp văn bản 6
1.2. Cơ sở lý thuyết về xử lý ngôn ngữ tự nhiên 6
1.2.1. Khái niệm xử lý ngôn ngữ tự nhiên 6
1.2.2. Quy trình xử lý ngôn ngữ tự nhiên đối với dữ liệu văn bản 7
1.2.3. Vai trò của NLP trong bài toán kiểm tra trùng lặp văn bản 7
1.2.4. Các mức biểu diễn và phân tích văn bản 7
1.3. Đặc thù tiếng Việt trong bài toán NLP 8
1.3.1. Đặc điểm từ vựng tiếng Việt 8
1.3.2. Hiện tượng từ ghép đa âm tiết 9
1.3.3. Hiện tượng đồng nghĩa và đa nghĩa 9
1.3.4. Đặc điểm cú pháp và cấu trúc câu tiếng Việt 10
1.3.5. Đặc điểm của văn bản học thuật tiếng Việt 10
1.3.6. Những khó khăn của tiếng Việt trong bài toán phát hiện trùng lặp văn bản 11
1.4. Tiền xử lý văn bản trong bài toán kiểm tra trùng lặp 11
1.4.1. Khái niệm tiền xử lý văn bản 11
1.4.2. Chuẩn hóa văn bản 11
1.4.3. Tách câu (Sentence Segmentation) 12
1.4.4. Tách từ tiếng Việt (Word Segmentation) 12
1.4.5. Loại bỏ từ dừng (Stop Word Removal) 13
1.4.6. Biểu diễn văn bản sau tiền xử lý 13
1.5. Các phương pháp biểu diễn văn bản 13
1.5.1. Khái niệm biểu diễn văn bản 13
1.5.2. Mô hình Bag of Words (BoW) 14
1.5.3. Mô hình không gian véc-tơ (Vector Space Model) 15
1.5.4. Biểu diễn văn bản bằng N-Gram. 15
1.5.5. Trọng số từ trong biểu diễn văn bản 16
1.5.6. Ý nghĩa của biểu diễn văn bản trong bài toán phát hiện trùng lặp 16
1.6. Các thuật toán và độ đo tương đồng văn bản 17
1.6.1. Khái niệm độ tương đồng văn bản 17

1.6.2. Độ đo Jaccard Similarity 17
1.6.3. Độ đo Cosine Similarity 18
1.6.4. So sánh Jaccard Similarity và Cosine Similarity 19
1.6.5. Vai trò của các độ đo tương đồng trong phát hiện trùng lặp văn bản 20
1.7. Kỹ thuật Hashing và Fingerprinting trong phát hiện trùng lặp 20
1.7.1. Hàm băm (Hash Function) 20
1.7.2. Hashing trong phát hiện trùng lặp văn bản 21
1.7.3. Khái niệm Fingerprint văn bản 21
1.7.4. Vai trò của Fingerprint trong giảm chi phí so khớp 22
1.8. Thuật toán Winnowing 22
1.8.1. Giới thiệu thuật toán Winnowing 22
1.8.2. Nguyên lý hoạt động 23
1.8.3. Ưu điểm và hạn chế của Winnowing 23
1.8.4. Ứng dụng của Winnowing trong phát hiện đạo văn 24
CHƯƠNG 2 PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG 25
2.1. Khảo sát hệ thống 25
2.1.1. Mô tả bài toán 25
2.1.2. Cơ cấu tổ chức 26
2.1.3. Quy trình xử lý 27
2.1.4. Đánh giá ưu điểm và hạn chế của hệ thống 28
2.1.5. Giải pháp và định hướng phát triển hệ thống mới 29
2.2. Sơ đồ phân rã chức năng 31
2.3. Sơ đồ mức ngữ cảnh 32
2.4. Sơ đồ mức đỉnh 33
2.5. Sơ đồ mức dưới đỉnh 34
2.5.1. Sơ đồ mức dưới đỉnh với chức năng quản lý hệ thống 34
2.5.2. Sơ đồ mức dưới đỉnh với chức năng quản lý nghiệp vụ 34
2.5.3. Sơ đồ mức dưới đỉnh với chức năng kiểm tra trùng lặp 36
2.5.4. Sơ đồ mức dưới đỉnh với chức năng thống kê hệ thống 37
2.6. Chuẩn hóa dữ liệu 38
2.6.1. Chuẩn hóa dữ liệu Người dùng 38
2.6.2. Chuẩn hóa dữ liệu Sinh viên 38
2.6.3. Chuẩn hóa dữ liệu Giảng viên 39
2.6.4. Chuẩn hóa dữ liệu Lớp học 39
2.6.5. Chuẩn hóa dữ liệu Bài tập 40
2.6.6. Chuẩn hóa dữ liệu Báo cáo 40
2.6.7. Chuẩn hóa dữ liệu Kết quả kiểm tra 41

2.6.8. Chuẩn hóa dữ liệu Chi tiết nộp bài 41
2.7. Phát hiện thực thể 42
2.7.1. Thực thể người dùng 42
2.7.2. Thực thể sinh viên 42
2.7.3. Thực thể giảng viên 42
2.7.4. Thực thể lớp học 43
2.7.5. Thực thể bài tập 43
2.7.6. Thực thể báo cáo 43
2.7.7. Thực thể kết quả kiểm tra 44
2.7.8. Thực thể chi tiết nộp bài 44
2.8. Xây ma trận thực thể khóa 45
CHƯƠNG 3 XÂY DỰNG VÀ CÀI ĐẶT THỰC NGHIỆM 46
3.1. Môi trường và công nghệ phát triển hệ thống 46
3.1.1. Ngôn ngữ lập trình Node.js 46
3.1.2. Framework ExpressJS 46
3.1.3. Hệ quản trị cơ sở dữ liệu MongoDB 47
3.1.4. Redis và BullMQ 47
3.2. Xây dựng kiến trúc hệ thống 48
3.2.1. Kiến trúc tổng thể 48
3.2.2. Luồng xử lý kiểm tra trùng lặp 48
3.3. Hiện thực thuật toán kiểm tra trùng lặp 49
3.3.1. Phát hiện trùng lặp bằng Fingerprint 49
3.3.2. Áp dụng thuật toán Winnowing 49
3.3.3. Tính độ tương đồng bằng TF-IDF và Cosine Similarity 50
3.3.4. Áp dụng Jaccard Similarity 50
3.3.5. Phát hiện đoạn trùng lặp liên tiếp 51
3.3.6. Phát hiện nội dung chắp vá từ nhiều nguồn 51
3.3.7. Mô hình phát hiện trùng lặp lai 52
3.4. Xây dựng giao diện hệ thống 53
3.4.1. Giao diện hướng dẫn sử dụng 53
3.4.2. Giao diện đăng nhập 53
3.4.3. Giao diện đăng ký 53
3.4.4. Giao diện giới thiệu hệ thống 53
3.4.5. Giao diện quản lý tài liệu 54
3.4.6. Giao diện quản lý lớp học 54
3.4.7. Giao diện thống kê hệ thống 55
3.5. Cài đặt thực nghiệm 55

3.5.1. Cấu hình phần cứng 55
3.5.2. Cấu hình phần mềm 55
3.5.3. Bộ dữ liệu thực nghiệm.....56
CHƯƠNG 4 KIỂM THỬ VÀ ĐÁNH GIÁ KẾT QUẢ THỰC NGHIỆM 58
4.1. Kiểm thử chức năng hệ thống.....58
4.1.1. Kiểm thử chức năng đăng ký tài khoản 58
4.1.2. Kiểm thử chức năng đăng nhập tài khoản.....59
4.1.3. Kiểm thử giao diện trang chủ sau đăng nhập.....61
4.1.4. Kiểm thử chức năng quản lý tài liệu 62
4.1.5. Kiểm thử chức năng quản lý lớp học 64
4.1.6. Kiểm thử chức năng kiểm tra trùng lặp văn bản.....69
4.2. Đánh giá kết quả thực nghiệm 72
4.2.1. Đánh giá khả năng phát hiện trùng lặp văn bản.....72
4.2.2. Đánh giá khả năng xác định nguồn tham chiếu 72
4.2.3. Đánh giá mức độ đáp ứng mục tiêu đề tài 73
KẾT LUẬN 74
TÀI LIỆU THAM KHẢO.....78

CHƯƠNG 1
CƠ SỞ LÝ THUYẾT

1.1. Tổng quan về bài toán kiểm tra trùng lặp văn bản

1.1.1. Khái niệm liêm chính học thuật

Liêm chính học thuật (Academic Integrity) là nguyên tắc nền tảng trong hoạt động học tập, giảng dạy và nghiên cứu khoa học. Khái niệm này đề cập đến việc tuân thủ các chuẩn mực đạo đức và chuyên môn trong quá trình tạo ra, sử dụng và công bố tri thức. Một môi trường học thuật chỉ có thể phát triển bền vững khi các cá nhân tham gia thực hiện nghiêm túc các nguyên tắc về tính trung thực, trách nhiệm, công bằng và tôn trọng quyền sở hữu trí tuệ.

Trong giáo dục đại học, liêm chính học thuật được thể hiện thông qua việc người học tự thực hiện các nhiệm vụ học tập, không gian lận trong kiểm tra, không sao chép kết quả của người khác và thực hiện trích dẫn đầy đủ khi sử dụng tài liệu tham khảo. Trong nghiên cứu khoa học, liêm chính học thuật yêu cầu các công trình nghiên cứu phải phản ánh trung thực quá trình nghiên cứu, dữ liệu và kết quả đạt được, đồng thời ghi nhận chính xác các nguồn tri thức đã được kế thừa.

Việc duy trì liêm chính học thuật có ý nghĩa quan trọng đối với cả người học và các cơ sở giáo dục. Đối với người học, đây là điều kiện để hình thành tư duy độc lập, năng lực nghiên cứu và khả năng sáng tạo. Đối với các cơ sở đào tạo và tổ chức nghiên cứu, liêm chính học thuật góp phần bảo đảm chất lượng đào tạo, nâng cao uy tín học thuật và bảo vệ giá trị của các sản phẩm khoa học.

Sự phát triển mạnh mẽ của Internet và các nguồn học liệu trực tuyến đã tạo điều kiện thuận lợi cho việc tiếp cận tri thức. Tuy nhiên, điều này cũng làm gia tăng các hành vi sao chép nội dung và sử dụng tài liệu không đúng quy định. Trong bối cảnh đó, việc nghiên cứu các phương pháp phát hiện trùng lặp văn bản nhằm hỗ trợ bảo đảm liêm chính học thuật ngày càng trở nên cần thiết.

1.1.2. Khái niệm đạo văn và trùng lặp văn bản

Đạo văn (Plagiarism) là hành vi sử dụng nội dung, ý tưởng, dữ liệu hoặc kết quả nghiên cứu của người khác mà không ghi nhận nguồn gốc một cách phù hợp. Hành vi này làm cho người đọc hiểu sai rằng nội dung được trình bày là kết quả nghiên cứu hoặc sáng tạo của chính tác giả.

Trong môi trường học thuật, đạo văn có thể xuất hiện ở nhiều dạng khác nhau như sao chép nguyên văn, diễn giải lại nội dung của người khác mà không trích dẫn nguồn, hoặc kết hợp nội dung từ nhiều tài liệu khác nhau để tạo thành một văn bản mới. Mặc dù mức độ vi phạm có thể khác nhau, điểm chung của các hình thức này là không bảo đảm tính minh bạch về nguồn gốc của tri thức được sử dụng.

Khái niệm trùng lặp văn bản (Text Similarity) thường được sử dụng trong lĩnh vực xử lý ngôn ngữ tự nhiên để mô tả mức độ giống nhau giữa hai hoặc nhiều văn bản. Trùng lặp văn bản không đồng nghĩa hoàn toàn với đạo văn. Hai văn bản có thể chứa nhiều nội dung tương đồng do cùng trình bày một khái niệm, một định nghĩa hoặc một tri thức phổ biến nào đó. Vì vậy, kết quả phát hiện trùng lặp chỉ cung cấp bằng chứng về mức độ tương đồng nội dung, còn việc kết luận có tồn tại hành vi đạo văn hay không cần dựa trên sự đánh giá của người có chuyên môn.

1.1.3. Các hình thức đạo văn trong học thuật

Đạo văn có thể được thực hiện dưới nhiều hình thức khác nhau với mức độ phức tạp ngày càng cao. Việc phân loại các hình thức đạo văn giúp làm rõ bản chất của bài toán phát hiện trùng lặp văn bản và là cơ sở cho việc nghiên cứu các phương pháp phát hiện phù hợp.



Hình 1.1. Các hình thức đạo văn phổ biến trong học thuật

Nguồn: Scribbr (2024).

Hình 1.1 minh họa một số hình thức đạo văn phổ biến được tổng hợp bởi Scribbr. Bên cạnh các dạng đạo văn được trình bày trong hình, nhiều nghiên cứu hiện nay còn đề cập đến các hình thức khác như đạo văn ý tưởng và đạo văn từ các hệ thống trí tuệ nhân tạo tạo sinh, vốn đang trở thành những thách thức mới đối với việc bảo đảm liêm chính học thuật.

Trên cơ sở đó, các hình thức đạo văn có thể được phân tích cụ thể như sau:

1.1.3.1. Đạo văn sao chép nguyên văn

Đây là hình thức đạo văn phổ biến và dễ nhận biết nhất. Người thực hiện sao chép toàn bộ hoặc một phần nội dung từ tài liệu của người khác mà không thực hiện trích dẫn nguồn. Nội dung được giữ nguyên về từ ngữ, cấu trúc câu và ý nghĩa so với tài liệu gốc. Đạo văn sao chép nguyên văn thường tạo ra mức độ tương đồng rất cao giữa các văn bản nên tương đối dễ phát hiện bằng các kỹ thuật đối sánh văn bản truyền thống.

1.1.3.2. Đạo văn diễn giải

Đạo văn diễn giải xảy ra khi người viết thay đổi cách diễn đạt của nội dung gốc bằng cách sử dụng từ đồng nghĩa, thay đổi cấu trúc câu hoặc sắp xếp lại nội dung nhưng vẫn giữ nguyên ý nghĩa cơ bản. So với sao chép nguyên văn, dạng đạo văn này khó phát hiện hơn do mức độ giống nhau về mặt từ vựng giảm xuống đáng kể. Trong nhiều trường hợp, hai câu có hình thức biểu đạt khác nhau nhưng truyền tải cùng một nội dung thông tin.

1.1.3.3. Đạo văn chắp vá

Đạo văn chắp vá là hành vi kết hợp nội dung được lấy từ nhiều nguồn khác nhau để tạo thành một tài liệu mới. Người thực hiện có thể trích một số câu hoặc một số đoạn từ các tài liệu khác nhau rồi ghép lại thành nội dung hoàn chỉnh. Loại đạo văn này thường không tạo ra tỷ lệ tương đồng quá cao với từng nguồn riêng lẻ, tuy nhiên tổng thể tài liệu vẫn được hình thành từ các nội dung đã tồn tại trước đó.

1.1.3.4. Tự đạo văn

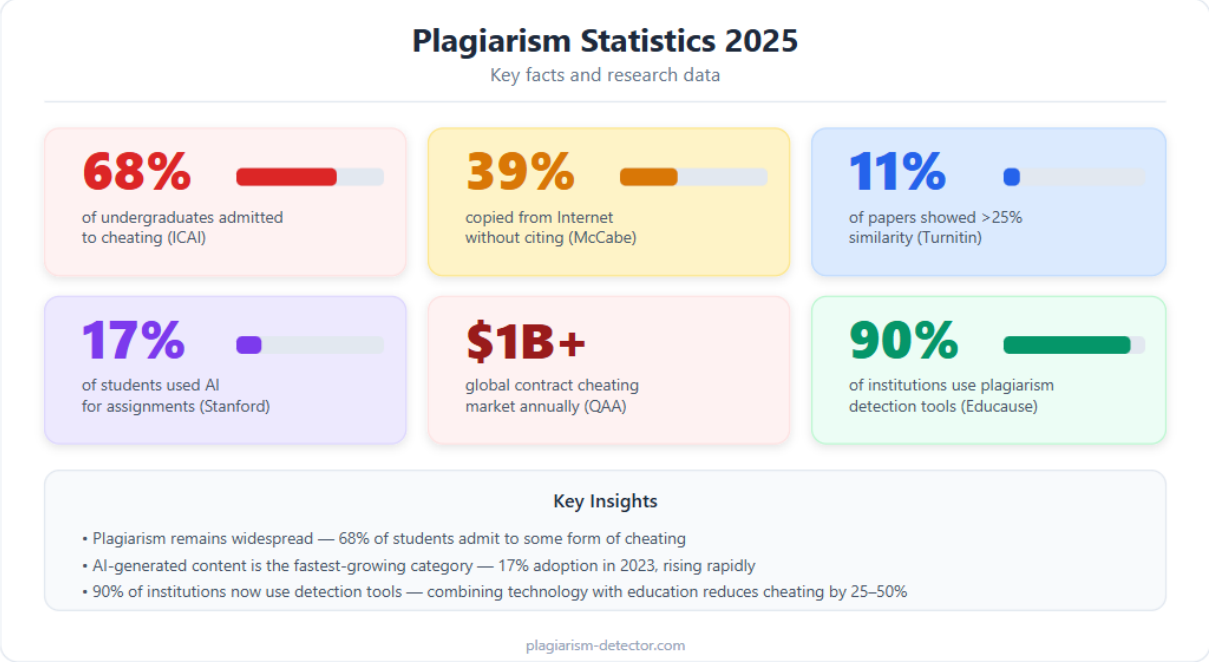
Tự đạo văn là việc tái sử dụng một phần hoặc toàn bộ sản phẩm học thuật do chính tác giả thực hiện trước đó mà không công khai hoặc không dẫn nguồn phù hợp. Ví dụ, một bài báo khoa học đã công bố hoặc một báo cáo đã được nộp trước đó được sử dụng lại trong một công trình mới nhưng không ghi nhận nguồn gốc ban đầu. Hành vi này có thể gây hiểu nhầm về tính mới và tính nguyên bản của công trình nghiên cứu.

1.1.3.5. Đạo văn ý tưởng

Đạo văn ý tưởng xảy ra khi người viết sử dụng ý tưởng, phương pháp nghiên cứu hoặc kết quả suy luận của người khác mà không ghi nhận nguồn tham khảo tương ứng. Đây là một trong những dạng đạo văn khó phát hiện nhất vì mức độ giống nhau không nằm ở văn bản mà nằm ở nội dung tư tưởng và phương pháp nghiên cứu.

1.1.4. Thực trạng đạo văn trong giáo dục và nghiên cứu khoa học

Trong bối cảnh phát triển mạnh mẽ của công nghệ thông tin và sự phổ biến của các nguồn học liệu số, vấn đề đạo văn và gian lận học thuật đang trở thành một thách thức nghiêm trọng đối với các cơ sở giáo dục đại học và tổ chức nghiên cứu trên toàn thế giới. Khả năng tiếp cận nhanh chóng các kho dữ liệu trực tuyến, thư viện số, công cụ tìm kiếm và gần đây là các hệ thống trí tuệ nhân tạo tạo sinh đã tạo điều kiện thuận lợi cho hoạt động học tập và nghiên cứu. Tuy nhiên, điều này cũng làm gia tăng nguy cơ sao chép nội dung, sử dụng trái phép tài liệu tham khảo và các hành vi vi phạm liêm chính học thuật. Nhiều nghiên cứu đã chỉ ra rằng đạo văn hiện nay không còn là hiện tượng cá biệt mà đã trở thành một vấn đề mang tính toàn cầu.



Hình 1.2. Một số thống kê tiêu biểu về tình trạng đạo văn và gian lận học thuật trên thế giới

Nguồn: Plagiarism Detector Team (2025).

Hình 1.2 cho thấy tình trạng đạo văn và gian lận học thuật vẫn đang diễn ra phổ biến trong môi trường giáo dục đại học trên toàn thế giới, thể hiện qua nhiều chỉ số thống

kê đáng chú ý liên quan đến hành vi sao chép, sử dụng AI và việc triển khai các hệ thống phát hiện đạo văn.

Theo số liệu từ International Center for Academic Integrity (ICAI), được tổng hợp từ các cuộc khảo sát quy mô lớn do Donald McCabe và cộng sự thực hiện tại nhiều trường đại học ở Bắc Mỹ, hơn 60% sinh viên đại học thừa nhận đã từng thực hiện ít nhất một hành vi gian lận học thuật trong quá trình học tập. Đáng chú ý, 39% sinh viên đại học thừa nhận đã sao chép hoặc diễn giải lại (paraphrase) nội dung từ nguồn Internet mà không trích dẫn đầy đủ, trong khi 62% sinh viên thừa nhận đã từng gian lận trong các bài tập viết. Các kết quả nghiên cứu này cho thấy các hành vi liên quan đến sao chép nội dung và vi phạm quyền tác giả đang diễn ra với tần suất đáng kể trong môi trường giáo dục đại học.

Một nghiên cứu khác của Tran, Huynh và Nguyen (2017) khảo sát 977 báo cáo tốt nghiệp đại học trong lĩnh vực kinh tế và quản trị từ giai đoạn 2013-2015. Kết quả cho thấy tại trường đại học chưa áp dụng hệ thống kiểm tra đạo văn, có tới 91,7% báo cáo được xác định có dấu hiệu đạo văn, trong khi tỷ lệ này giảm xuống còn 61,7% tại trường sử dụng phần mềm Turnitin. Nghiên cứu đồng thời chỉ ra rằng nguồn đạo văn chủ yếu xuất phát từ việc sao chép nội dung trên Internet mà không thực hiện trích dẫn nguồn đầy đủ.

Bên cạnh những hình thức đạo văn truyền thống, sự xuất hiện của các hệ thống trí tuệ nhân tạo tạo sinh như ChatGPT, Gemini hay Copilot cũng đặt ra những thách thức mới đối với việc duy trì liêm chính học thuật. Các công cụ này có khả năng tạo ra văn bản hoàn chỉnh trong thời gian rất ngắn, khiến việc phân biệt giữa nội dung do người học tự viết và nội dung được hỗ trợ tự động trở nên khó khăn hơn. Một nghiên cứu tổng quan về gian lận học thuật trong giáo dục đại học công bố năm 2024 cho thấy việc sử dụng công nghệ và công cụ AI không phù hợp đang trở thành một trong những yếu tố làm gia tăng nguy cơ đạo văn và gian lận học thuật trong môi trường giáo dục hiện đại.

Thực trạng nêu trên cho thấy rằng đạo văn không chỉ là vấn đề của riêng một cá nhân hay một cơ sở đào tạo mà đã trở thành một thách thức chung của toàn bộ hệ thống giáo dục và nghiên cứu khoa học. Việc gia tăng số lượng tài liệu trực tuyến, sự phát triển của trí tuệ nhân tạo và nhận thức chưa đầy đủ về quyền sở hữu trí tuệ là những nguyên nhân chính làm cho tình trạng này ngày càng phức tạp. Do đó, việc nghiên cứu và phát triển các hệ thống kiểm tra trùng lặp văn bản có độ chính xác cao, đặc biệt đối với tiếng

Việt, là yêu cầu cấp thiết nhằm hỗ trợ các cơ sở giáo dục bảo đảm chất lượng đào tạo, tăng cường liêm chính học thuật và nâng cao hiệu quả quản lý các sản phẩm nghiên cứu khoa học.

1.1.5. Vai trò của các hệ thống kiểm tra trùng lặp văn bản

Các hệ thống kiểm tra trùng lặp văn bản được phát triển nhằm hỗ trợ quá trình đánh giá tính nguyên bản của tài liệu học thuật. Mục tiêu chính của các hệ thống này là xác định các nội dung có mức độ tương đồng cao với các tài liệu tham chiếu và cung cấp thông tin hỗ trợ cho quá trình đánh giá của người sử dụng.

Trong giáo dục đại học, các công cụ kiểm tra trùng lặp giúp nâng cao nhận thức của người học về việc sử dụng tài liệu tham khảo đúng quy định. Việc áp dụng các công cụ kiểm tra trước khi nộp bài góp phần hình thành thói quen nghiên cứu nghiêm túc và tuân thủ các chuẩn mực học thuật.

Đối với giảng viên và nhà quản lý giáo dục, các hệ thống kiểm tra trùng lặp giúp giảm đáng kể thời gian rà soát tài liệu thủ công, đồng thời cung cấp các bằng chứng khách quan về mức độ tương đồng giữa các tài liệu.

Trong nghiên cứu khoa học, việc đánh giá mức độ trùng lặp trước khi công bố giúp bảo đảm tính nguyên bản của công trình nghiên cứu, nâng cao chất lượng học thuật của các bài báo và bảo vệ quyền sở hữu trí tuệ của tác giả.

1.2. Cơ sở lý thuyết về xử lý ngôn ngữ tự nhiên

1.2.1. Khái niệm xử lý ngôn ngữ tự nhiên

Xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP) là lĩnh vực nghiên cứu thuộc trí tuệ nhân tạo và khoa học máy tính, tập trung vào việc xây dựng các phương pháp cho phép máy tính tiếp nhận, phân tích và xử lý dữ liệu ngôn ngữ của con người. Mục tiêu của NLP là chuyển đổi ngôn ngữ tự nhiên từ dạng văn bản hoặc lời nói thành các biểu diễn mà máy tính có thể hiểu và thực hiện tính toán.

Khác với dữ liệu số hoặc dữ liệu có cấu trúc, ngôn ngữ tự nhiên chứa nhiều hiện tượng phức tạp như đa nghĩa, đồng nghĩa, từ ghép, biến đổi ngữ cảnh và nhiều cách diễn đạt khác nhau cho cùng một nội dung. Điều này làm cho việc xử lý ngôn ngữ trở thành một trong những bài toán phức tạp của lĩnh vực trí tuệ nhân tạo.

Trong quá trình phát triển, NLP đã trải qua nhiều giai đoạn khác nhau, từ các phương pháp dựa trên tập luật ngôn ngữ học cho đến các mô hình thống kê, học máy và học sâu. Mặc dù các phương pháp hiện đại có sự khác biệt đáng kể về kỹ thuật triển

khai, mục tiêu chung vẫn là giúp máy tính khai thác và xử lý hiệu quả thông tin chứa trong ngôn ngữ của con người.

Trong bài toán phân tích tài liệu, NLP đóng vai trò như một cầu nối giữa dữ liệu văn bản và các mô hình tính toán. Các kỹ thuật của NLP cho phép văn bản được chuẩn hóa, phân tích và chuyển đổi sang dạng dữ liệu số để phục vụ cho quá trình đo lường mức độ tương đồng.

1.2.2. Quy trình xử lý ngôn ngữ tự nhiên đối với dữ liệu văn bản

Một bài toán NLP thông thường thường bao gồm nhiều giai đoạn xử lý liên tiếp. Mỗi giai đoạn đảm nhận một nhiệm vụ riêng nhằm chuẩn hóa và trích xuất thông tin từ dữ liệu văn bản.

Quy trình xử lý văn bản tổng quát có thể được mô tả như sau: Văn bản thô → Tiền xử lý → Trích xuất đặc trưng → Biểu diễn văn bản → Phân tích và đánh giá

1.2.3. Vai trò của NLP trong bài toán kiểm tra trùng lặp văn bản

Chuẩn hóa dữ liệu đầu vào. Hai văn bản có thể giống nhau về nội dung nhưng khác nhau về chữ hoa, chữ thường, cách sử dụng dấu câu hoặc định dạng trình bày. NLP giúp loại bỏ những khác biệt này để việc so sánh tập trung vào nội dung thực sự của văn bản.

Phân tách văn bản thành các đơn vị ngôn ngữ có ý nghĩa như từ, cụm từ hoặc câu. Đây là cơ sở để xây dựng các mô hình biểu diễn văn bản và tính toán độ tương đồng.

Hỗ trợ trích xuất đặc trưng văn bản. Thay vì sử dụng toàn bộ nội dung văn bản để so sánh, NLP cho phép lựa chọn những thành phần mang nhiều giá trị thông tin hơn nhằm giảm chi phí tính toán và nâng cao hiệu quả xử lý.

Hỗ trợ đánh giá sự tương đồng giữa các văn bản ở nhiều cấp độ khác nhau. Việc đo lường độ tương đồng có thể được thực hiện ở mức từ, mức câu, mức đoạn văn hoặc mức tài liệu. Nhờ đó, hệ thống có khả năng xác định chính xác hơn vị trí và phạm vi của các nội dung trùng lặp.

1.2.4. Các mức biểu diễn và phân tích văn bản

1.2.4.1. Mức ký tự (Character Level)

Đây là mức phân tích thấp nhất, trong đó văn bản được xem như một chuỗi các ký tự liên tiếp. Phương pháp này thường được sử dụng trong các bài toán phát hiện lỗi chính tả, băm văn bản hoặc xây dựng n-gram ký tự.

1.2.4.2. Mức từ (Word Level)

Ở cấp độ này, văn bản được phân tách thành các từ hoặc cụm từ mang ý nghĩa độc lập. Phân tích ở mức từ là nền tảng của nhiều phương pháp đo độ tương đồng văn bản.

1.2.4.3. Mức câu (Sentence Level)

Trong nhiều bài toán học thuật, câu thường được xem là đơn vị thông tin cơ bản. Phân tích ở mức câu giúp xác định chính xác những nội dung nào có dấu hiệu tương đồng giữa các tài liệu.

1.2.4.4. Mức đoạn văn (Paragraph Level)

Một đoạn văn bao gồm nhiều câu liên kết với nhau để trình bày một nội dung hoặc ý tưởng nhất định. Phân tích ở mức đoạn văn cho phép đánh giá sự tương đồng trên phạm vi lớn hơn câu đơn lẻ, đồng thời hỗ trợ phát hiện các trường hợp sao chép liên tiếp nhiều câu trong cùng một nội dung.

1.2.4.5. Mức tài liệu (Document Level)

Đây là mức phân tích tổng thể của toàn bộ văn bản. Thay vì đánh giá từng câu hoặc từng đoạn riêng lẻ, toàn bộ tài liệu được biểu diễn thành một thực thể duy nhất để tính toán mức độ tương đồng. Phân tích ở mức tài liệu phù hợp cho việc đánh giá nhanh mối quan hệ giữa các văn bản, tuy nhiên thường khó xác định chính xác vị trí xuất hiện của các nội dung trùng lặp.

1.3. Đặc thù tiếng Việt trong bài toán NLP

1.3.1. Đặc điểm từ vựng tiếng Việt

Tiếng Việt thuộc nhóm ngôn ngữ đơn lập (Isolating Language), trong đó các đơn vị ngôn ngữ cơ bản không biến đổi hình thái như nhiều ngôn ngữ khác. Mỗi âm tiết thường được viết tách rời bằng dấu cách và có thể mang ý nghĩa độc lập hoặc tham gia tạo thành các từ ghép có ý nghĩa hoàn chỉnh.

Một đặc điểm nổi bật của tiếng Việt là sự tồn tại phổ biến của các từ ghép đa âm tiết. Trong nhiều trường hợp, một khái niệm hoàn chỉnh được biểu diễn bằng nhiều âm tiết liên tiếp thay vì một từ đơn lẻ.

Đặc điểm này tạo ra sự khác biệt đáng kể giữa tiếng Việt và nhiều ngôn ngữ sử dụng dấu cách như một ranh giới từ rõ ràng. Trong các bài toán xử lý ngôn ngữ tự nhiên, việc xác định đúng ranh giới từ là yêu cầu quan trọng trước khi thực hiện các bước phân tích sâu hơn.

Ngoài ra, vốn từ vựng tiếng Việt liên tục được mở rộng thông qua quá trình ghép từ, vay mượn ngôn ngữ nước ngoài và hình thành các thuật ngữ chuyên ngành. Điều này làm cho việc xử lý văn bản tiếng Việt trở nên phức tạp hơn do số lượng từ vựng và cách diễn đạt ngày càng đa dạng.

1.3.2. Hiện tượng từ ghép đa âm tiết

Trong tiếng Việt, nhiều đơn vị từ vựng được cấu thành từ hai hoặc nhiều âm tiết. Ý nghĩa của toàn bộ từ ghép không thể được xác định chính xác nếu các thành phần của chúng bị tách rời.

Nếu văn bản được xử lý trực tiếp dựa trên dấu cách, cụm từ: "xử lý ngôn ngữ tự nhiên" sẽ bị chia thành: xử | lý | ngôn | ngữ | tự | nhiên. Trong khi đó, về mặt ngữ nghĩa, toàn bộ cụm từ này biểu diễn một lĩnh vực nghiên cứu hoàn chỉnh.

Việc phân tách sai từ ghép có thể làm thay đổi đáng kể nội dung biểu diễn của văn bản, dẫn đến sai lệch kết quả trong các bước trích xuất đặc trưng và đo độ tương đồng. Vì vậy, bài toán nhận diện từ ghép là một trong những nhiệm vụ nền tảng của xử lý ngôn ngữ tự nhiên tiếng Việt.

1.3.3. Hiện tượng đồng nghĩa và đa nghĩa

Bên cạnh đặc điểm từ ghép, tiếng Việt còn tồn tại nhiều hiện tượng đồng nghĩa và đa nghĩa.

1.3.3.1. Từ đồng nghĩa

Từ đồng nghĩa là những từ hoặc cụm từ khác nhau về hình thức biểu đạt nhưng có ý nghĩa tương tự hoặc gần tương đương trong một ngữ cảnh nhất định. Trong các bài toán phân tích độ tương đồng văn bản, hai câu có thể sử dụng các từ đồng nghĩa khác nhau nhưng vẫn truyền tải cùng một nội dung thông tin.

Ví dụ: "Sinh viên thực hiện đề tài nghiên cứu" và "Người học tiến hành khảo cứu đề tài". Mặc dù mức độ giống nhau về từ vựng không cao, nội dung ngữ nghĩa giữa hai câu vẫn có sự tương đồng đáng kể.

1.3.3.2. Từ đa nghĩa

Đa nghĩa là hiện tượng một từ có nhiều ý nghĩa khác nhau tùy thuộc vào ngữ cảnh sử dụng. Hiện tượng đa nghĩa làm tăng độ phức tạp trong việc phân tích ngữ nghĩa của văn bản vì ý nghĩa thực tế chỉ có thể được xác định thông qua ngữ cảnh xung quanh.

Ví dụ: "bảng" có thể được hiểu là: "bảng dữ liệu", "bảng viết trong lớp học", "bảng thống kê", "bảng kết quả", …

1.3.4. Đặc điểm cú pháp và cấu trúc câu tiếng Việt

Một đặc điểm quan trọng khác của tiếng Việt là tính linh hoạt trong cách tổ chức câu. Cùng một nội dung thông tin có thể được biểu đạt theo nhiều cấu trúc khác nhau.

Ví dụ: "Sinh viên thực hiện đề tài nghiên cứu" và "Đề tài nghiên cứu được thực hiện bởi sinh viên". Hai câu này có cấu trúc cú pháp khác nhau nhưng cùng mô tả một nội dung.

Sự linh hoạt trong trật tự từ và cấu trúc diễn đạt giúp tiếng Việt giàu tính biểu đạt, tuy nhiên lại tạo ra thách thức lớn cho các hệ thống phân tích văn bản. Hai câu có nội dung tương đương không nhất thiết phải sử dụng cùng một tập từ hoặc cùng một cấu trúc ngữ pháp.

1.3.5. Đặc điểm của văn bản học thuật tiếng Việt

Các tài liệu học thuật như báo cáo, đồ án, luận văn hoặc bài báo khoa học thường không chỉ chứa nội dung chuyên môn mà còn bao gồm nhiều thành phần khác. Một tài liệu hoàn chỉnh có thể xuất hiện các phần như:

- Bìa
- Lời cảm ơn
- Mục lục
- Danh mục hình
- Danh mục bảng
- Danh mục chữ viết tắt
- Tiêu đề chương và tiêu đề mục
- Kết luận
- Tài liệu tham khảo
- Phụ lục

Những thành phần này thường được lặp lại giữa nhiều tài liệu khác nhau và không phản ánh trực tiếp nội dung nghiên cứu.

Ví dụ: "MỤC LỤC", "DANH MỤC HÌNH", "TÀI LIỆU THAM KHẢO" có thể xuất hiện trong hầu hết các báo cáo học thuật.

Nếu các thành phần này được đưa trực tiếp vào quá trình phân tích, kết quả đánh giá độ tương đồng có thể bị sai lệch do hệ thống nhận diện các phần định dạng chung thay vì nội dung học thuật thực sự.

1.3.6. Những khó khăn của tiếng Việt trong bài toán phát hiện trùng lặp văn bản

Từ các đặc điểm đã trình bày ở trên có thể thấy rằng tiếng Việt đặt ra nhiều thách thức đối với các hệ thống phân tích văn bản. Một số khó khăn chính bao gồm:

- Khó xác định chính xác ranh giới từ do sự tồn tại của các từ ghép đa âm tiết.
- Hiện tượng đồng nghĩa làm giảm khả năng phát hiện sự tương đồng dựa trên so khớp từ đơn thuần.
- Hiện tượng đa nghĩa làm tăng độ phức tạp trong quá trình phân tích ngữ nghĩa.
- Cấu trúc câu linh hoạt khiến cùng một nội dung có thể được diễn đạt theo nhiều cách khác nhau.
- Văn bản học thuật chứa nhiều thành phần thông tin không mang giá trị nội dung nhưng lại xuất hiện với tần suất cao.
- Cách trình bày và định dạng tài liệu không thống nhất giữa các nguồn dữ liệu.

1.4. Tiền xử lý văn bản trong bài toán kiểm tra trùng lặp

1.4.1. Khái niệm tiền xử lý văn bản

Tiền xử lý văn bản (Text Preprocessing) là giai đoạn đầu tiên trong hầu hết các bài toán xử lý ngôn ngữ tự nhiên. Mục tiêu của giai đoạn này là chuyển đổi văn bản thô thành dạng dữ liệu chuẩn hóa, nhất quán và phù hợp cho các bước phân tích tiếp theo.

Trong thực tế, dữ liệu văn bản thường được thu thập từ nhiều nguồn khác nhau như tài liệu học thuật, sách điện tử, bài báo khoa học hoặc các nguồn dữ liệu trực tuyến. Các văn bản này có thể tồn tại nhiều khác biệt về định dạng, cách sử dụng ký tự, dấu câu, khoảng trắng hoặc cấu trúc trình bày. Nếu dữ liệu được đưa trực tiếp vào các thuật toán phân tích mà không trải qua quá trình tiền xử lý, kết quả tính toán độ tương đồng có thể bị sai lệch đáng kể.

Đối với bài toán kiểm tra trùng lặp văn bản, tiền xử lý đóng vai trò đặc biệt quan trọng. Hai đoạn văn có thể mang nội dung giống nhau nhưng khác nhau về cách trình bày, cách viết hoa hoặc sử dụng dấu câu. Những khác biệt này không phản ánh sự thay đổi về nội dung ngữ nghĩa nhưng lại có thể ảnh hưởng đến kết quả so khớp nếu không được chuẩn hóa trước.

1.4.2. Chuẩn hóa văn bản

Chuẩn hóa văn bản là bước đầu tiên trong quy trình tiền xử lý. Mục tiêu của bước này là đưa toàn bộ dữ liệu về cùng một dạng biểu diễn nhằm giảm thiểu các khác biệt không mang ý nghĩa nội dung.

Một số thao tác chuẩn hóa thường được sử dụng bao gồm:

- Chuẩn hóa bảng mã ký tự
- Chuyển đổi toàn bộ văn bản về chữ thường
- Chuẩn hóa khoảng trắng
- Loại bỏ các ký tự đặc biệt không cần thiết
- Chuẩn hóa dấu câu và định dạng văn bản

1.4.3. Tách câu (Sentence Segmentation)

Tách câu là quá trình phân chia một văn bản thành các đơn vị câu độc lập dựa trên các dấu hiệu ngữ pháp và dấu câu. Trong các tài liệu học thuật, câu thường được xem là đơn vị thông tin cơ bản vì mỗi câu thường biểu diễn một nhận định, một dữ kiện hoặc một ý tưởng tương đối hoàn chỉnh.

Ví dụ: "Xử lý ngôn ngữ tự nhiên là một lĩnh vực của trí tuệ nhân tạo. Lĩnh vực này được ứng dụng rộng rãi trong giáo dục và nghiên cứu.". Sau khi tách câu:

- Câu 1: Xử lý ngôn ngữ tự nhiên là một lĩnh vực của trí tuệ nhân tạo.
- Câu 2: Lĩnh vực này được ứng dụng rộng rãi trong giáo dục và nghiên cứu.

Việc chia nhỏ văn bản thành các đơn vị câu giúp:

- Xác định chính xác vị trí xuất hiện của nội dung trùng lặp.
- Thuận lợi trong việc phân tích từng phần của tài liệu.
- Hỗ trợ phát hiện các đoạn văn được hình thành từ nhiều câu liên tiếp có mức độ tương đồng cao.

Tuy nhiên, đối với tiếng Việt, bài toán tách câu không hoàn toàn đơn giản. Một số dấu chấm có thể xuất hiện trong tên viết tắt, địa danh hoặc tài liệu tham khảo mà không biểu thị sự kết thúc câu. Ví dụ: "TS.", "PGS.TS.", "TP.HCM". Những trường hợp này đòi hỏi phải kết hợp thêm các quy tắc ngôn ngữ để bảo đảm độ chính xác của quá trình tách câu.

1.4.4. Tách từ tiếng Việt (Word Segmentation)

Tách từ là quá trình xác định ranh giới giữa các từ trong văn bản. Đối với nhiều ngôn ngữ như tiếng Anh, dấu cách thường được xem là ranh giới tự nhiên giữa các từ. Tuy nhiên, trong tiếng Việt, nhiều từ có thể được tạo thành từ nhiều âm tiết tách rời bởi dấu cách.

Ví dụ: “xử lý ngôn ngữ tự nhiên”. Nếu tách đơn giản theo dấu cách sẽ thu được: “xử | lý | ngôn | ngữ | tự | nhiên”. Trong khi đơn vị từ mang ý nghĩa ngữ nghĩa thực sự là: “xử_lý_ngôn_ngữ_tự_nhiên”.

Việc xác định đúng ranh giới từ có ý nghĩa đặc biệt quan trọng vì hầu hết các phương pháp biểu diễn văn bản đều hoạt động trên tập từ hoặc cụm từ. Nếu quá trình tách từ không chính xác, các bước tiếp theo như tính TF-IDF, xây dựng n-gram hay đo độ tương đồng văn bản sẽ bị ảnh hưởng đáng kể. Do đó, tách từ được xem là một trong những bước cốt lõi trong xử lý ngôn ngữ tự nhiên tiếng Việt.

1.4.5. Loại bỏ từ dừng (Stop Word Removal)

Từ dừng (Stop Words) là các từ xuất hiện với tần suất cao trong ngôn ngữ nhưng mang ít giá trị phân biệt nội dung. Trong tiếng Việt, các từ dừng phổ biến bao gồm: “là”, “và”, “của”, “được”, “với”, “cho”, “những”, “các”, “trong”, “trên”, ….Những từ này thường xuất hiện ở hầu hết các văn bản nên không giúp phân biệt nội dung giữa các tài liệu.

Loại bỏ từ dừng mang lại một số lợi ích:

- Giảm kích thước dữ liệu cần xử lý.
- Giảm nhiễu trong quá trình tính toán.
- Tăng khả năng phân biệt nội dung giữa các văn bản.
- Cải thiện hiệu quả của các thuật toán đo độ tương đồng.

1.4.6. Biểu diễn văn bản sau tiền xử lý

Sau khi hoàn thành các bước làm sạch và chuẩn hóa dữ liệu, văn bản được chuyển sang dạng thích hợp cho các bước trích xuất đặc trưng dữ liệu văn bản không còn được xem là chuỗi ký tự đơn thuần mà được biểu diễn thông qua các thành phần ngôn ngữ đã được xử lý.

1.5. Các phương pháp biểu diễn văn bản

1.5.1. Khái niệm biểu diễn văn bản

Văn bản ở dạng tự nhiên là tập hợp các ký tự, từ và câu được con người sử dụng để truyền đạt thông tin. Tuy nhiên, máy tính không thể trực tiếp hiểu và xử lý dữ liệu ngôn ngữ theo cách con người thực hiện. Do đó, trước khi áp dụng các thuật toán phân tích, văn bản cần được chuyển đổi sang dạng biểu diễn phù hợp cho việc tính toán.

Biểu diễn văn bản (Text Representation) là quá trình chuyển đổi dữ liệu ngôn ngữ tự nhiên thành các cấu trúc dữ liệu số hoặc tập đặc trưng có thể được sử dụng trong các thuật toán xử lý ngôn ngữ tự nhiên và khai phá dữ liệu.

Mục đích của việc biểu diễn văn bản gồm:

- Chuyển đổi ngôn ngữ tự nhiên thành dạng dữ liệu có thể tính toán.
- Hỗ trợ quá trình so sánh và phân tích nội dung.
- Giảm độ phức tạp của dữ liệu đầu vào.
- Tạo cơ sở cho các thuật toán đo độ tương đồng văn bản.

1.5.2. Mô hình Bag of Words (BoW)

Bag of Words (BoW) là một trong những phương pháp biểu diễn văn bản đơn giản và phổ biến nhất trong xử lý ngôn ngữ tự nhiên. Ý tưởng cơ bản của mô hình này là xem văn bản như một tập hợp các từ xuất hiện trong tài liệu mà không quan tâm đến thứ tự xuất hiện của chúng.

Ví dụ:

- Văn bản A: “xử lý ngôn ngữ tự nhiên”
- Văn bản B: “ngôn ngữ tự nhiên và trí tuệ nhân tạo”

Tập từ vựng tổng quát:

Từ	Văn bản A	Văn bản B
xử_lý	1	0
ngôn_ngữ	1	1
tự_nhiên	1	1
và	0	1
trí_tuệ	0	1
nhân_tạo	0	1

Khi đó:

- A=(1,1,1,0,0,0)
- B=(0,1,1,1,1,1)

Mỗi chiều của vector tương ứng với một từ trong tập từ vựng.

Ưu điểm

- Đơn giản và dễ triển khai.
- Phù hợp với dữ liệu văn bản có kích thước lớn.

- Là nền tảng cho nhiều phương pháp biểu diễn hiện đại.

Hạn chế

- Không phản ánh được thứ tự từ trong câu.
- Không thể biểu diễn ngữ nghĩa.
- Mất thông tin về mối quan hệ giữa các từ.

1.5.3. Mô hình không gian véc-tơ (Vector Space Model)

Mô hình không gian véc-tơ (Vector Space Model - VSM) là phương pháp biểu diễn văn bản dưới dạng các véc-tơ trong không gian nhiều chiều. Trong mô hình này, mỗi tài liệu được biểu diễn bằng một véc-tơ số học, trong đó mỗi chiều tương ứng với một đặc trưng của văn bản, thường là một từ hoặc một cụm từ trong tập từ vựng. Mô hình không gian véc-tơ là nền tảng của các kỹ thuật biểu diễn văn bản dựa trên trọng số từ như TF-IDF.

Giả sử tập từ vựng gồm: V = {NLP, TFIDF, Jaccard}

- Tài liệu A: NLP TFIDF được biểu diễn thành: A=(1,1,0)
- Tài liệu B: NLP Jaccard được biểu diễn thành: B=(1,0,1)

Ưu điểm

- Dễ dàng áp dụng các công thức toán học.
- Hỗ trợ nhiều phương pháp đo độ tương đồng.
- Có khả năng xử lý văn bản với kích thước lớn.

Hạn chế

- Kích thước véc-tơ có thể rất lớn khi tập từ vựng mở rộng.
- Chưa phản ánh đầy đủ mối quan hệ ngữ nghĩa giữa các từ.

1.5.4. Biểu diễn văn bản bằng N-Gram.

N-Gram là phương pháp chia văn bản thành các chuỗi liên tiếp gồm n phần tử. Phần tử có thể là: ký tự, âm tiết, từ. N-Gram giúp mô tả cấu trúc cục bộ của văn bản và được sử dụng rộng rãi trong các bài toán đo độ tương đồng.

1.5.4.1. Character N-Gram

Đối với Character N-Gram, văn bản được chia thành các chuỗi ký tự liên tiếp. Character N-Gram có khả năng phát hiện các biến đổi nhỏ trong văn bản.

Ví dụ: Văn bản: “PLAGIARISM” với n = 4 ta thu được: “PLAG”, “LAGI”, “AGIA”, “GIAR”, “IARI”, “ARIS”, “RISM”.

1.5.4.2. Word N-Gram

Trong Word N-Gram, phần tử cơ sở là từ thay vì ký tự. Word N-Gram phản ánh tốt hơn ý nghĩa của văn bản so với Character N-Gram và thường được sử dụng trong các bài toán phát hiện trùng lặp học thuật.

Ví dụ: Câu: "xử lý ngôn ngữ tự nhiên trong giáo dục" với n = 3 ta thu được: "xử_lý ngôn_ngữ tự_nhiên", "ngôn_ngữ tự_nhiên trong", "tự_nhiên trong giáo_dục".

Ưu điểm

- Bảo tồn được ngữ cảnh cục bộ.
- Hỗ trợ phát hiện các đoạn văn tương đồng.

Hạn chế

- Kích thước dữ liệu tăng nhanh khi giá trị nnn lớn.
- Nhạy cảm với việc thay đổi từ ngữ hoặc trật tự câu.

1.5.5. Trọng số từ trong biểu diễn văn bản

Không phải tất cả các từ trong văn bản đều có mức độ quan trọng như nhau.

Ví dụ: "là", "và", "của", "được" xuất hiện rất nhiều nhưng mang ít giá trị phân biệt. Ngược lại: "đạo văn", "trùng lặp", "winnowing", "fingerprint" thường chứa nhiều thông tin hơn.

Do đó, các mô hình biểu diễn hiện đại thường không chỉ quan tâm đến việc một từ có xuất hiện hay không, mà còn xem xét mức độ quan trọng của từ đó trong văn bản và trong toàn bộ tập tài liệu. Ý tưởng này dẫn đến sự ra đời của các phương pháp gán trọng số từ, trong đó TF-IDF là một trong những kỹ thuật được sử dụng phổ biến nhất.

1.5.6. Ý nghĩa của biểu diễn văn bản trong bài toán phát hiện trùng lặp

Biểu diễn văn bản đóng vai trò trung gian giữa dữ liệu ngôn ngữ tự nhiên và các thuật toán phân tích. Thông qua các phương pháp biểu diễn phù hợp, văn bản có thể được chuyển đổi thành dữ liệu có cấu trúc để thực hiện:

- Đánh giá mức độ tương đồng.
- Tìm kiếm văn bản liên quan.
- Phát hiện nội dung sao chép.
- Trích xuất đặc trưng ngôn ngữ.

1.6. Các thuật toán và độ đo tương đồng văn bản

1.6.1. Khái niệm độ tương đồng văn bản

Độ tương đồng văn bản (Text Similarity) là đại lượng được sử dụng để đánh giá mức độ giống nhau giữa hai hoặc nhiều văn bản. Trong lĩnh vực xử lý ngôn ngữ tự nhiên, độ tương đồng thường được biểu diễn dưới dạng một giá trị số nằm trong khoảng từ 0 đến 1 hoặc từ 0% đến 100%. Giá trị càng lớn cho thấy mức độ giống nhau giữa hai văn bản càng cao. Ngược lại, giá trị càng nhỏ thể hiện mức độ khác biệt về nội dung giữa các văn bản.

Ví dụ 1:

- Văn bản A: "Trí tuệ nhân tạo đang được ứng dụng rộng rãi trong giáo dục."
- Văn bản B: "Trí tuệ nhân tạo đang được ứng dụng rộng rãi trong giáo dục."

Độ tương đồng giữa hai văn bản gần bằng: Similarity(A,B) = 1

Ví dụ 2:

- Văn bản A: "Trí tuệ nhân tạo đang được ứng dụng rộng rãi trong giáo dục".
- Văn bản B: "Kinh tế số đang làm thay đổi hoạt động thương mại điện tử."

Hai văn bản có rất ít điểm chung nên độ tương đồng sẽ gần bằng: Similarity(A,B) = 0

1.6.2. Độ đo Jaccard Similarity

Jaccard Similarity là một trong những độ đo phổ biến nhất được sử dụng để đánh giá mức độ tương đồng giữa hai tập hợp. Trong bài toán văn bản, mỗi tài liệu thường được biểu diễn dưới dạng một tập từ. Độ đo Jaccard được xác định dựa trên tỷ lệ giữa số lượng phần tử chung của hai tập hợp và tổng số phần tử thuộc hợp của hai tập đó.

Công thức:

$$\text{Jaccard Similarity(A, B)} = \frac{|A \cap B|}{|A \cup B|}$$

Trong đó:

A: tập từ/ngữ của văn bản 1

B: tập từ/ngữ của văn bản 2

|A∩B| là số phần tử thuộc giao của hai tập

|A∪B| là số phần tử thuộc hợp của hai tập

Ưu điểm

- Dễ tính toán.
- Phù hợp với dữ liệu dạng tập hợp.

- Không bị ảnh hưởng bởi số lần lặp của từ.

Hạn chế

- Không xem xét trọng số từ.
- Không phản ánh được ngữ nghĩa.
- Khó phát hiện các trường hợp diễn giải mạnh.

1.6.3. Độ đo Cosine Similarity

Cosine Similarity là độ đo được sử dụng rất phổ biến trong xử lý ngôn ngữ tự nhiên nhằm đánh giá mức độ giống nhau giữa hai véc-tơ văn bản. Thay vì so sánh số lượng phần tử chung, Cosine Similarity đánh giá góc giữa hai véc-tơ trong không gian nhiều chiều.

$$\text{Cosine Similarity(A,B)} = \frac{A_1B_1+A_2B_2+\cdots+A_nB_n}{\sqrt{A_1^2+A_2^2+A_n^2} \times \sqrt{B_1^2+B_2^2+B_n^2}}$$

Công thức tổng quát:

$$\text{Cosine Similarity(A,B)} = \frac{\sum_{i=1}^{n} A_iB_i}{\sqrt{\sum_{i=1}^{n} A_i^2} \times \sqrt{\sum_{i=1}^{n} B_i^2}}$$

Trong đó:

$A=(A_1,A_2,\ldots,A_n)$: vector biểu diễn văn bản A.

$B=(B_1,B_2,\ldots,B_n)$: vector biểu diễn văn bản B.

A_i,B_i trọng số của từ thứ i trong hai văn bản (thường là TF hoặc TF-IDF).

Tử số:

$$\sum_{i=1}^{n} A_iB_i$$

là tích vô hướng của hai vector.

Mẫu số:

$$\sqrt{\sum_{i=1}^{n} A_i^2} \times \sqrt{\sum_{i=1}^{n} B_i^2}$$

là tích độ dài 2 vector.

Ưu điểm

- Hoạt động hiệu quả với dữ liệu TF-IDF.

- Phù hợp với dữ liệu có kích thước lớn.
- Không phụ thuộc độ dài văn bản.

Hạn chế

- Phụ thuộc vào chất lượng biểu diễn véc-tơ.
- Khó phát hiện nội dung có ý nghĩa tương đồng nhưng sử dụng từ vựng khác nhau.

1.6.4. So sánh Jaccard Similarity và Cosine Similarity

Mặc dù đều được sử dụng để đo mức độ tương đồng giữa các văn bản, Jaccard Similarity và Cosine Similarity có sự khác biệt đáng kể về cách tiếp cận và phạm vi ứng dụng.

Jaccard Similarity xem mỗi văn bản như một tập hợp các từ hoặc đặc trưng. Độ tương đồng được xác định dựa trên tỷ lệ giữa số lượng phần tử chung và tổng số phần tử thuộc hợp của hai tập hợp. Phương pháp này tập trung vào việc đánh giá mức độ giao nhau của các thành phần xuất hiện trong văn bản.

Cosine Similarity biểu diễn văn bản dưới dạng các véc-tơ trong không gian nhiều chiều và đo góc giữa hai véc-tơ. Phương pháp này không chỉ xem xét sự xuất hiện của từ mà còn đánh giá mức độ quan trọng của từng từ thông qua trọng số tương ứng. Sự khác biệt giữa hai phương pháp được trình bày trong Bảng 1.1.

Bảng 1.1. So sánh Jaccard Similarity và Cosine Similarity

Tiêu chí	Jaccard Similarity	Cosine Similarity
Đối tượng xử lý	Tập hợp từ	Véc-tơ đặc trưng
Nguyên tắc đánh giá	Tỷ lệ giao và hợp của hai tập	Góc giữa hai véc-tơ
Xem xét trọng số từ	Không	Có
Ảnh hưởng bởi tần suất từ	Thấp	Có
Độ phức tạp tính toán	Thấp	Cao hơn
Khả năng xử lý văn bản dài	Trung bình	Tốt
Khả năng phản ánh nội dung	Trung bình	Tốt hơn

Jaccard Similarity phù hợp trong các trường hợp cần đánh giá nhanh mức độ giao nhau giữa các tập từ, đặc biệt khi dữ liệu được biểu diễn dưới dạng tập hợp đặc trưng. Cosine Similarity thường được sử dụng khi văn bản đã được biểu diễn dưới dạng véc-tơ trọng số, cho phép phản ánh tốt hơn mức độ tương đồng về nội dung.

1.6.5. Vai trò của các độ đo tương đồng trong phát hiện trùng lặp văn bản

Trong bài toán phát hiện trùng lặp văn bản, các độ đo tương đồng đóng vai trò là cơ sở định lượng để đánh giá mức độ giống nhau giữa các đơn vị văn bản. Thay vì đưa ra nhận định mang tính cảm tính, các độ đo này cho phép lượng hóa mức độ tương đồng dưới dạng các giá trị số cụ thể. Thông qua các độ đo tương đồng, hệ thống có thể xác định mức độ giống nhau giữa hai văn bản ở nhiều cấp độ khác nhau như mức từ, mức câu, mức đoạn văn hoặc mức tài liệu. Điều này giúp quá trình đánh giá trở nên khách quan hơn và hỗ trợ phát hiện chính xác các vị trí có dấu hiệu trùng lặp.

Bên cạnh việc xác định các trường hợp sao chép nguyên văn, các độ đo tương đồng còn cho phép nhận diện những nội dung có sự thay đổi nhất định về từ ngữ hoặc cấu trúc diễn đạt. Trong nhiều trường hợp, mặc dù hai văn bản không hoàn toàn giống nhau về mặt hình thức, chúng vẫn có thể đạt mức độ tương đồng cao do cùng truyền tải một lượng lớn thông tin giống nhau.

Các độ đo tương đồng cũng đóng vai trò quan trọng trong việc giảm khối lượng dữ liệu cần xử lý. Thay vì phải lưu giữ và đối chiếu toàn bộ văn bản theo cách thủ công, hệ thống có thể sử dụng các giá trị tương đồng để sàng lọc và ưu tiên các tài liệu có khả năng liên quan cao nhất.

Ngoài ra, kết quả đo tương đồng còn là cơ sở cho nhiều kỹ thuật phát hiện trùng lặp hiện đại như phân tích nội dung theo câu, nhận diện các đoạn văn tương đồng hoặc phát hiện sự sao chép từ nhiều nguồn khác nhau. Nhờ đó, quá trình đánh giá không chỉ dừng lại ở việc xác định tỷ lệ giống nhau của toàn bộ tài liệu mà còn có khả năng chỉ ra chính xác vị trí xuất hiện của các nội dung trùng lặp.

1.7. Kỹ thuật Hashing và Fingerprinting trong phát hiện trùng lặp

1.7.1. Hàm băm (Hash Function)

Trong khoa học máy tính, hàm băm (Hash Function) là một hàm toán học được sử dụng để chuyển đổi dữ liệu đầu vào có độ dài bất kỳ thành một giá trị đầu ra có độ dài cố định, thường được gọi là giá trị băm (Hash Value). Quá trình này được thực hiện thông qua các phép toán xác định, bảo đảm rằng cùng một dữ liệu đầu vào luôn tạo ra cùng một giá trị băm. Cho hàm băm H và dữ liệu đầu vào x, giá trị băm được xác định theo công thức: $h=H(x)$

Trong đó:

- x: dữ liệu đầu vào;

- H: hàm băm;
- h: giá trị băm sinh ra từ dữ liệu đầu vào.

Một số tính chất quan trọng của hàm băm gồm:

- Tính xác định: cùng một đầu vào luôn tạo ra cùng một giá trị băm.
- Tốc độ tính toán cao.
- Khó suy ngược dữ liệu từ giá trị băm.
- Độ nhạy cao với sự thay đổi dữ liệu đầu vào.

1.7.2. Hashing trong phát hiện trùng lặp văn bản

Hashing là quá trình áp dụng hàm băm lên dữ liệu nhằm tạo ra các giá trị đại diện cho nội dung văn bản. Trong bài toán phát hiện trùng lặp văn bản, việc so sánh trực tiếp toàn bộ nội dung giữa các tài liệu thường tiêu tốn nhiều thời gian và tài nguyên tính toán, đặc biệt khi số lượng tài liệu lớn. Để khắc phục điều này, các đơn vị văn bản thường được chuyển đổi thành các giá trị băm trước khi thực hiện đối sánh.

Việc sử dụng giá trị băm thay cho chuỗi ký tự gốc mang lại nhiều lợi ích:

- Giảm dung lượng lưu trữ.
- Tăng tốc độ so sánh dữ liệu.
- Giảm chi phí xử lý đối với tập dữ liệu lớn.
- Hỗ trợ xây dựng các kỹ thuật phát hiện trùng lặp hiệu quả.

1.7.3. Khái niệm Fingerprint văn bản

Fingerprint (dấu vân tay văn bản) là tập hợp các giá trị đại diện cho nội dung của một văn bản hoặc một phần văn bản. Mục tiêu của Fingerprinting là tạo ra một biểu diễn ngắn gọn nhưng vẫn giữ được những đặc trưng quan trọng của dữ liệu gốc. Thay vì lưu trữ toàn bộ nội dung văn bản, hệ thống chỉ cần lưu giữ các Fingerprint để phục vụ việc đối sánh. Quá trình tạo Fingerprint thường bao gồm các bước:

- Bước 1: Chia văn bản thành các n-gram.
- Bước 2: Tính giá trị băm cho từng n-gram.
- Bước 3: Lựa chọn một tập giá trị đại diện.

Một Fingerprint tốt cần bảo đảm hai yêu cầu:

- Đại diện được đặc trưng của nội dung văn bản.
- Có kích thước nhỏ hơn rất nhiều so với dữ liệu gốc.

1.7.4. Vai trò của Fingerprint trong giảm chi phí so khớp

Trong các hệ thống phát hiện trùng lặp văn bản, số lượng tài liệu cần đối sánh có thể rất lớn. Nếu thực hiện so sánh trực tiếp từng ký tự hoặc từng từ giữa tất cả các tài liệu, chi phí tính toán sẽ tăng rất nhanh theo kích thước dữ liệu. Fingerprint được sử dụng nhằm giải quyết vấn đề này thông qua việc thay thế văn bản gốc bằng một tập giá trị đại diện có kích thước nhỏ hơn.

Lợi ích của Fingerprinting trong phát hiện trùng lặp văn bản gồm:

- Giảm khối lượng dữ liệu cần xử lý.
- Tăng tốc độ tìm kiếm tài liệu tương đồng.
- Giảm chi phí bộ nhớ.
- Hỗ trợ kiểm tra trên tập dữ liệu lớn.
- Duy trì khả năng phát hiện các nội dung có mức độ tương đồng cao.

1.8. Thuật toán Winnowing

1.8.1. Giới thiệu thuật toán Winnowing

Winnowing là một thuật toán lựa chọn dấu vân tay văn bản (Document Fingerprinting) được đề xuất nhằm phát hiện hiệu quả các đoạn nội dung giống nhau giữa các tài liệu. Thay vì sử dụng toàn bộ tập giá trị băm được tạo ra từ văn bản, thuật toán chỉ lựa chọn một số giá trị đại diện có khả năng phản ánh đặc trưng của nội dung cần phân tích.

Ý tưởng cốt lõi của Winnowing là giảm số lượng dữ liệu phải lưu trữ và so sánh nhưng vẫn bảo đảm khả năng phát hiện các đoạn văn bản có mức độ tương đồng cao. Nhờ đặc điểm này, thuật toán được sử dụng rộng rãi trong các hệ thống phát hiện đạo văn, tìm kiếm tài liệu tương tự và kiểm tra trùng lặp mã nguồn.

Khác với các phương pháp đối sánh trực tiếp toàn bộ văn bản, Winnowing hoạt động dựa trên các dấu vân tay (Fingerprint) được lựa chọn từ tập giá trị băm của các n-gram. Điều này giúp giảm đáng kể khối lượng tính toán trong khi vẫn duy trì khả năng phát hiện các nội dung sao chép có độ dài đủ lớn.

Một ưu điểm quan trọng của Winnowing là khả năng loại bỏ các thay đổi nhỏ không làm ảnh hưởng đáng kể đến nội dung tổng thể của văn bản. Những khác biệt như thêm hoặc xóa một vài từ, thay đổi dấu câu hoặc điều chỉnh cách trình bày thường không làm biến đổi đáng kể tập Fingerprint của tài liệu.

1.8.2. Nguyên lý hoạt động

Thuật toán Winnowing hoạt động thông qua bốn giai đoạn chính gồm sinh K-Gram, tính giá trị băm, tạo cửa sổ trượt và lựa chọn Fingerprint.

Giai đoạn 1: Sinh K-Gram: Sau khi văn bản được tiền xử lý, nội dung sẽ được chia thành các chuỗi liên tiếp gồm k phần tử, gọi là K-Gram. K-Gram có thể được xây dựng ở mức ký tự hoặc mức từ. Trong các bài toán xử lý văn bản học thuật, Word K-Gram thường được sử dụng nhiều hơn do phản ánh tốt hơn nội dung ngữ nghĩa. Mỗi K-Gram đại diện cho một phần nội dung liên tiếp của văn bản. Giá trị của k ảnh hưởng trực tiếp đến độ nhạy của thuật toán.

- k nhỏ làm tăng khả năng phát hiện nhưng dễ xuất hiện nhiễu.
- k lớn làm giảm nhiễu nhưng có thể bỏ sót các đoạn sao chép ngắn.

Giai đoạn 2: Tính giá trị băm: Sau khi sinh K-Gram, mỗi K-Gram sẽ được chuyển đổi thành một giá trị băm. Dãy giá trị băm sẽ được sử dụng ở các bước tiếp theo để lựa chọn Fingerprint.

Giai đoạn 3: Tạo cửa sổ trượt: Sau khi thu được dãy giá trị băm, thuật toán tạo các cửa sổ trượt (Sliding Window) có kích thước cố định. Mỗi cửa sổ bao gồm một tập các giá trị băm liên tiếp. Việc sử dụng cửa sổ trượt giúp bảo đảm rằng một đoạn văn bản đủ dài sẽ luôn tạo ra ít nhất một Fingerprint đại diện.

Giai đoạn 4: Chọn Fingerprint: Trong mỗi cửa sổ, thuật toán lựa chọn giá trị băm nhỏ nhất làm Fingerprint đại diện. Tập giá trị này được xem như dấu vân tay đại diện cho văn bản ban đầu. Khi hai tài liệu chứa các đoạn nội dung giống nhau, chúng sẽ có xu hướng tạo ra các Fingerprint giống nhau. Mức độ giao nhau giữa các tập Fingerprint có thể được sử dụng để đánh giá mức độ tương đồng giữa các tài liệu.

1.8.3. Ưu điểm và hạn chế của Winnowing

1.8.3.1. Ưu điểm

Giảm chi phí lưu trữ: Thay vì lưu trữ toàn bộ văn bản hoặc toàn bộ tập giá trị băm, thuật toán chỉ giữ lại một số Fingerprint đại diện. Điều này giúp giảm đáng kể dung lượng dữ liệu cần lưu trữ.

Tăng tốc độ so sánh: Số lượng Fingerprint luôn nhỏ hơn nhiều so với số lượng K-Gram ban đầu. Nhờ đó, thời gian tìm kiếm và đối sánh được cải thiện đáng kể.

Phát hiện hiệu quả các đoạn sao chép nguyên văn: Các đoạn văn bản giống nhau thường tạo ra các Fingerprint tương tự, giúp thuật toán phát hiện nhanh những nội dung có dấu hiệu sao chép.

Khả năng mở rộng tốt: Thuật toán phù hợp với các tập dữ liệu lớn do khối lượng dữ liệu cần xử lý được giảm đáng kể.

1.8.3.2. Hạn chế

Nhạy cảm với việc thay đổi nội dung lớn: Nếu văn bản bị thay đổi đáng kể về từ ngữ hoặc cấu trúc câu, tập Fingerprint có thể thay đổi mạnh và làm giảm khả năng phát hiện.

Hạn chế trong phát hiện đạo văn diễn giải: Trường hợp tác giả thay đổi cách diễn đạt nhưng vẫn giữ nguyên ý nghĩa thường khó được phát hiện chỉ bằng Fingerprint.

Phụ thuộc vào tham số: Kết quả của thuật toán chịu ảnh hưởng bởi:

- Kích thước K-Gram (k);
- Kích thước cửa sổ (w).

1.8.4. Ứng dụng của Winnowing trong phát hiện đạo văn

Trong các hệ thống kiểm tra trùng lặp văn bản hiện đại, Winnowing thường được sử dụng như một lớp lọc ban đầu nhằm phát hiện nhanh các tài liệu có khả năng tương đồng cao.

Quy trình xử lý tổng quát thường bao gồm: Văn bản → Tiền xử lý → Sinh K-Gram → Hashing → Winnowing → Fingerprint → Đối sánh tài liệu

Nhờ sử dụng tập Fingerprint thay cho toàn bộ văn bản, hệ thống có thể nhanh chóng xác định các tài liệu có dấu hiệu sao chép mà không cần thực hiện đối sánh trực tiếp trên toàn bộ nội dung.

Winnowing đặc biệt hiệu quả trong việc phát hiện:

- Sao chép nguyên văn.
- Sao chép một phần tài liệu.
- Sao chép các đoạn văn liên tiếp.
- Trùng lặp nội dung có mức độ chỉnh sửa nhỏ.

CHƯƠNG 2
PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

2.1. Khảo sát hệ thống

2.1.1. Mô tả bài toán

Trong các cơ sở giáo dục đại học hiện nay, số lượng báo cáo học phần, đồ án, khóa luận tốt nghiệp và các công trình nghiên cứu khoa học được tạo ra ngày càng lớn. Cùng với sự phát triển của Internet và các nguồn học liệu trực tuyến, người học có thể dễ dàng tiếp cận nhiều tài liệu phục vụ cho quá trình học tập và nghiên cứu. Tuy nhiên, điều này cũng làm gia tăng nguy cơ sao chép nội dung, sử dụng tài liệu tham khảo không đúng quy định hoặc vi phạm các nguyên tắc về liêm chính học thuật.

Để bảo đảm chất lượng đào tạo và nâng cao tính trung thực trong học tập, nhiều cơ sở giáo dục đã triển khai hoạt động kiểm tra tính nguyên bản của các sản phẩm học thuật trước khi đánh giá hoặc công bố. Quá trình này thường được thực hiện đối với các loại tài liệu như bài tập lớn, báo cáo thực tập, đồ án môn học, khóa luận tốt nghiệp, luận văn và các bài báo nghiên cứu khoa học.

Trong mô hình hiện tại, người học nộp tài liệu cho giảng viên hoặc đơn vị quản lý đào tạo thông qua các hệ thống quản lý học tập hoặc bằng hình thức gửi trực tiếp tệp văn bản. Sau khi tiếp nhận tài liệu, giảng viên hoặc cán bộ chuyên trách thực hiện việc kiểm tra mức độ trùng lặp giữa tài liệu được nộp với các tài liệu đã tồn tại trong cơ sở dữ liệu hoặc trên các nguồn tham khảo khác.

Hiện nay, nhiều cơ sở giáo dục sử dụng các phần mềm hỗ trợ phát hiện trùng lặp văn bản nhằm giảm khối lượng công việc kiểm tra thủ công. Các hệ thống này có nhiệm vụ tiếp nhận tài liệu, thực hiện đối sánh với tập dữ liệu tham chiếu và cung cấp báo cáo về mức độ tương đồng giữa các tài liệu. Kết quả kiểm tra thường bao gồm tỷ lệ trùng lặp tổng thể, danh sách các nguồn tham chiếu có liên quan và vị trí xuất hiện các nội dung tương đồng trong văn bản.

Trong quá trình sử dụng, dữ liệu của hệ thống thường bao gồm các tài liệu học thuật được lưu trữ qua nhiều năm học khác nhau, tạo thành một kho dữ liệu phục vụ cho việc kiểm tra. Khi một tài liệu mới được đưa vào hệ thống, nội dung của tài liệu sẽ được so sánh với các tài liệu đã tồn tại trong kho dữ liệu nhằm xác định các phần nội dung có dấu hiệu tương đồng.

Đối tượng tham gia vào hệ thống bao gồm các nhóm chính sau:

- **Sinh viên hoặc người học:** là đối tượng tạo và nộp các sản phẩm học thuật để được đánh giá.
- **Giảng viên:** là người sử dụng kết quả kiểm tra để hỗ trợ quá trình chấm điểm, đánh giá và phản biện học thuật.
- **Cán bộ quản lý đào tạo hoặc quản trị hệ thống:** là người quản lý cơ sở dữ liệu tài liệu, tài khoản người dùng và vận hành hệ thống.

Thông qua hoạt động kiểm tra trùng lặp văn bản, các cơ sở giáo dục có thể nâng cao hiệu quả giám sát chất lượng học thuật, hỗ trợ phát hiện các hành vi sao chép nội dung và góp phần xây dựng môi trường học tập trung thực, khách quan và minh bạch hơn.

2.1.2. Cơ cấu tổ chức

Trong hoạt động kiểm tra tính nguyên bản của các tài liệu học thuật, nhiều đối tượng khác nhau cùng tham gia vào quá trình tiếp nhận, quản lý, kiểm tra và đánh giá tài liệu. Mỗi đối tượng đảm nhận những vai trò và trách nhiệm riêng nhằm bảo đảm quá trình kiểm tra được thực hiện một cách khách quan và hiệu quả.

Về mặt tổ chức, hệ thống kiểm tra trùng lặp văn bản có thể được mô tả thông qua ba nhóm đối tượng chính gồm sinh viên, giảng viên và bộ phận quản lý hệ thống.

2.1.2.1. Sinh viên

Sinh viên là đối tượng tạo lập và nộp các sản phẩm học thuật như bài tập lớn, báo cáo thực tập, đồ án môn học, khóa luận tốt nghiệp hoặc các công trình nghiên cứu. Đây là nguồn cung cấp dữ liệu đầu vào cho hệ thống.

2.1.2.2. Giảng viên

Giảng viên là đối tượng trực tiếp tham gia đánh giá chất lượng học thuật của tài liệu được nộp. Trong quá trình kiểm tra, giảng viên sử dụng kết quả phân tích của hệ thống như một nguồn thông tin hỗ trợ cho việc nhận xét và đánh giá.

2.1.2.3. Quản trị viên

Quản trị viên là bộ phận chịu trách nhiệm quản lý và vận hành hệ thống kiểm tra trùng lặp văn bản. Bộ phận này bảo đảm hệ thống hoạt động ổn định và duy trì cơ sở dữ liệu phục vụ quá trình kiểm tra.

2.1.3. Quy trình xử lý

2.1.3.1. Quản lý tài liệu

Quản lý tài liệu là chức năng trung tâm của các hệ thống kiểm tra trùng lặp văn bản. Chức năng này cho phép lưu trữ, cập nhật và khai thác các tài liệu phục vụ cho quá trình kiểm tra trùng lặp. Người dùng có thể tải tài liệu lên hệ thống dưới các định dạng được hỗ trợ. Sau khi tiếp nhận, hệ thống thực hiện lưu trữ thông tin tài liệu và cập nhật vào kho dữ liệu phục vụ đối sánh.

Bên cạnh việc lưu trữ nội dung tài liệu, hệ thống còn quản lý các thông tin mô tả như tên tài liệu, tác giả, thời gian tải lên, đơn vị đào tạo, môn học hoặc khóa học liên quan. Các thông tin này hỗ trợ quá trình tìm kiếm và quản lý dữ liệu sau này. Trong quá trình sử dụng, người dùng có thể thực hiện tìm kiếm, xem thông tin hoặc xóa tài liệu khi được cấp quyền phù hợp.

2.1.3.2. Quản lý người dùng

Quản lý người dùng là chức năng cơ bản của hệ thống nhằm kiểm soát việc truy cập và khai thác dữ liệu. Hệ thống thường phân chia người sử dụng thành nhiều nhóm với quyền hạn khác nhau như quản trị viên, giảng viên và sinh viên.

Khi một người dùng mới tham gia hệ thống, thông tin tài khoản sẽ được tạo lập và lưu trữ trong cơ sở dữ liệu. Người dùng sử dụng tài khoản được cấp để đăng nhập vào hệ thống. Sau khi xác thực thành công, hệ thống sẽ phân quyền và hiển thị các chức năng phù hợp với vai trò của người sử dụng.

Trong quá trình hoạt động, quản trị viên có thể thực hiện các thao tác như tạo mới tài khoản, cập nhật thông tin người dùng, khóa tài khoản hoặc phân quyền sử dụng hệ thống. Thông qua chức năng này, hệ thống bảo đảm rằng chỉ những người được cấp quyền mới có thể truy cập và sử dụng dữ liệu.

2.1.3.3. Kiểm tra trùng lặp văn bản

Đây là chức năng quan trọng nhất của hệ thống. Quy trình bắt đầu khi người dùng lựa chọn tài liệu cần kiểm tra. Hệ thống tiếp nhận tài liệu và thực hiện quá trình đối chiếu với các tài liệu đã tồn tại trong kho dữ liệu.

Sau khi hoàn thành việc phân tích và so sánh, hệ thống xác định các nội dung có mức độ tương đồng cao và tổng hợp kết quả kiểm tra. Kết quả thường bao gồm tỷ lệ tương đồng tổng thể, danh sách các tài liệu liên quan và vị trí xuất hiện các nội dung

tương đồng trong văn bản. Thông tin này được cung cấp cho người dùng nhằm hỗ trợ quá trình đánh giá tính nguyên bản của tài liệu.

2.1.3.4. Quản lý kết quả

Sau khi quá trình kiểm tra hoàn tất, kết quả sẽ được lưu trữ trong hệ thống để phục vụ tra cứu và theo dõi. Người dùng có thể xem lại lịch sử kiểm tra, tỷ lệ tương đồng của từng tài liệu và các nội dung được hệ thống đánh dấu. Trong trường hợp cần thiết, kết quả có thể được xuất thành báo cáo để phục vụ công tác đánh giá học thuật hoặc lưu trữ hồ sơ.

Việc lưu giữ kết quả kiểm tra giúp giảm thời gian thực hiện các lần đối chiếu tiếp theo và hỗ trợ theo dõi quá trình chỉnh sửa của người học.

2.1.4. Đánh giá ưu điểm và hạn chế của hệ thống

2.1.4.1. Ưu điểm

- Hệ thống hỗ trợ tự động hóa quá trình kiểm tra trùng lặp văn bản. Thay vì phải đọc và đối chiếu thủ công từng tài liệu, người sử dụng có thể nhanh chóng nhận được kết quả phân tích mức độ tương đồng giữa các tài liệu.
- Hệ thống có khả năng xử lý khối lượng dữ liệu lớn và thực hiện kiểm tra trên nhiều nguồn dữ liệu khác nhau. Điều này giúp mở rộng phạm vi đối sánh và nâng cao khả năng phát hiện nội dung trùng lặp.
- Kết quả kiểm tra thường được trình bày trực quan thông qua tỷ lệ tương đồng, danh sách nguồn tham chiếu và các vị trí nội dung giống nhau, tạo điều kiện thuận lợi cho việc đánh giá và xem xét của giảng viên.
- Góp phần nâng cao nhận thức của người học về liêm chính học thuật, khuyến khích việc sử dụng tài liệu tham khảo đúng quy định và hạn chế các hành vi sao chép không phù hợp.

2.1.4.2. Hạn chế

- Hệ thống hiện nay được phát triển chủ yếu cho ngôn ngữ tiếng Anh. Do được xây dựng trên các kho dữ liệu và các mô hình ngôn ngữ tiếng Anh nên hiệu quả xử lý đối với tiếng Việt trong nhiều trường hợp còn chưa cao. Các đặc điểm ngôn ngữ riêng của tiếng Việt như từ ghép đa âm tiết, cách diễn đạt linh hoạt, hiện tượng đồng nghĩa và đa nghĩa làm cho việc phát hiện sự tương đồng nội dung gặp nhiều khó khăn.

- Chi phí sử dụng các hệ thống kiểm tra đạo văn thương mại hiện nay tương đối cao. Nhiều hệ thống yêu cầu người dùng hoặc cơ sở giáo dục phải trả phí định kỳ để duy trì quyền sử dụng, gây khó khăn cho các trường học hoặc tổ chức có nguồn kinh phí hạn chế. Đối với các đơn vị đào tạo có số lượng lớn sinh viên và tài liệu cần kiểm tra hằng năm, chi phí vận hành có thể tăng lên đáng kể.
- Nhiều hệ thống chỉ cung cấp tỷ lệ tương đồng tổng thể của tài liệu mà chưa hỗ trợ đầy đủ việc phân tích chi tiết theo từng câu hoặc từng đoạn văn. Điều này khiến người sử dụng gặp khó khăn trong quá trình xác định chính xác vị trí xuất hiện nội dung trùng lặp.
- Khả năng phát hiện các hình thức đạo văn phức tạp như đạo văn chắp vá hoặc việc sao chép từ nhiều nguồn khác nhau trong cùng một tài liệu vẫn còn hạn chế. Trong nhiều trường hợp, tài liệu có thể được hình thành từ nhiều đoạn nội dung lấy từ các nguồn khác nhau nhưng tỷ lệ tương đồng với từng nguồn riêng lẻ không quá cao, dẫn đến khó khăn trong quá trình phát hiện.

2.1.5. Giải pháp và định hướng phát triển hệ thống mới

2.1.5.1. Giải pháp

Từ kết quả khảo sát các hệ thống kiểm tra đạo văn hiện nay có thể thấy rằng mặc dù các hệ thống đã hỗ trợ hiệu quả trong việc phát hiện nội dung trùng lặp, tuy nhiên vẫn còn tồn tại nhiều hạn chế liên quan đến khả năng xử lý tiếng Việt, chi phí sử dụng và mức độ chi tiết của kết quả kiểm tra. Để khắc phục những hạn chế này, đề tài đề xuất xây dựng một hệ thống kiểm tra trùng lặp văn bản hướng tới đối tượng sử dụng là các cơ sở giáo dục và nghiên cứu khoa học tại Việt Nam. Hệ thống tập trung vào việc hỗ trợ xử lý tài liệu tiếng Việt và cung cấp kết quả phân tích chi tiết hơn so với các hệ thống hiện có.

- Xây dựng một hệ thống có khả năng tiếp nhận, lưu trữ và quản lý tập trung các tài liệu học thuật. Khi một tài liệu mới được đưa vào hệ thống, nội dung của tài liệu sẽ được phân tích và đối chiếu với các tài liệu đã tồn tại trong cơ sở dữ liệu nhằm xác định các nội dung có dấu hiệu tương đồng.
- Hệ thống được thiết kế nhằm hỗ trợ phát hiện trùng lặp ở nhiều mức độ khác nhau, từ mức câu đến mức đoạn văn. Việc phân tích chi tiết theo từng câu và từng đoạn giúp người sử dụng có thể xác định chính xác vị trí xuất hiện các nội dung tương đồng thay vì chỉ nhận được một tỷ lệ tương đồng tổng thể.

- Hệ thống được xây dựng theo hướng chủ động quản lý và khai thác kho dữ liệu nội bộ của đơn vị sử dụng. Điều này giúp giảm sự phụ thuộc vào các hệ thống thương mại bên ngoài, đồng thời tạo điều kiện thuận lợi cho việc mở rộng và cập nhật dữ liệu trong tương lai.
- Việc nghiên cứu và xây dựng hệ thống kiểm tra trùng lặp văn bản tiếng Việt cũng góp phần hỗ trợ các cơ sở giáo dục nâng cao hiệu quả quản lý học thuật, bảo đảm tính nguyên bản của các sản phẩm nghiên cứu và tăng cường nhận thức về liêm chính học thuật trong môi trường đào tạo.

2.1.5.2. Định hướng phát triển hệ thống mới

Giai đoạn 1: Hệ thống cần hỗ trợ hiệu quả việc kiểm tra các tài liệu học thuật bằng tiếng Việt. Đây là yêu cầu quan trọng nhằm bảo đảm khả năng xử lý phù hợp với đặc điểm ngôn ngữ và cách trình bày của các tài liệu trong môi trường giáo dục Việt Nam.

Giai đoạn 2: Hệ thống cần cho phép quản lý tập trung dữ liệu tài liệu học thuật. Các tài liệu được lưu trữ trong cơ sở dữ liệu sẽ tạo thành nguồn tham chiếu phục vụ quá trình kiểm tra và đối sánh trong những lần sử dụng tiếp theo. Việc quản lý tập trung giúp nâng cao hiệu quả lưu trữ, tìm kiếm và khai thác dữ liệu.

Giai đoạn 3: Hệ thống cần hỗ trợ phát hiện nội dung trùng lặp ở nhiều cấp độ khác nhau. Ngoài việc đánh giá mức độ tương đồng của toàn bộ tài liệu, hệ thống cần có khả năng xác định các câu hoặc đoạn văn có dấu hiệu sao chép nhằm cung cấp thông tin chi tiết hơn cho người sử dụng. Điều này giúp nâng cao hiệu quả phát hiện các nội dung trùng lặp và hỗ trợ quá trình đánh giá học thuật.

Giai đoạn 4: Hệ thống cần hỗ trợ quản lý người dùng và phân quyền sử dụng phù hợp với từng đối tượng tham gia. Các nhóm người dùng như quản trị viên, giảng viên và sinh viên sẽ được cấp các quyền truy cập khác nhau nhằm bảo đảm tính bảo mật và nâng cao hiệu quả quản lý dữ liệu trong quá trình vận hành hệ thống.

Giai đoạn 5: Hệ thống cần hỗ trợ quản lý lớp học và quá trình nộp bài của sinh viên. Giảng viên có thể tạo lớp học, quản lý danh sách sinh viên, theo dõi tình trạng nộp bài và kiểm tra kết quả của từng bài nộp. Chức năng này giúp đơn giản hóa công tác quản lý bài tập, đồ án và các sản phẩm học thuật của sinh viên.

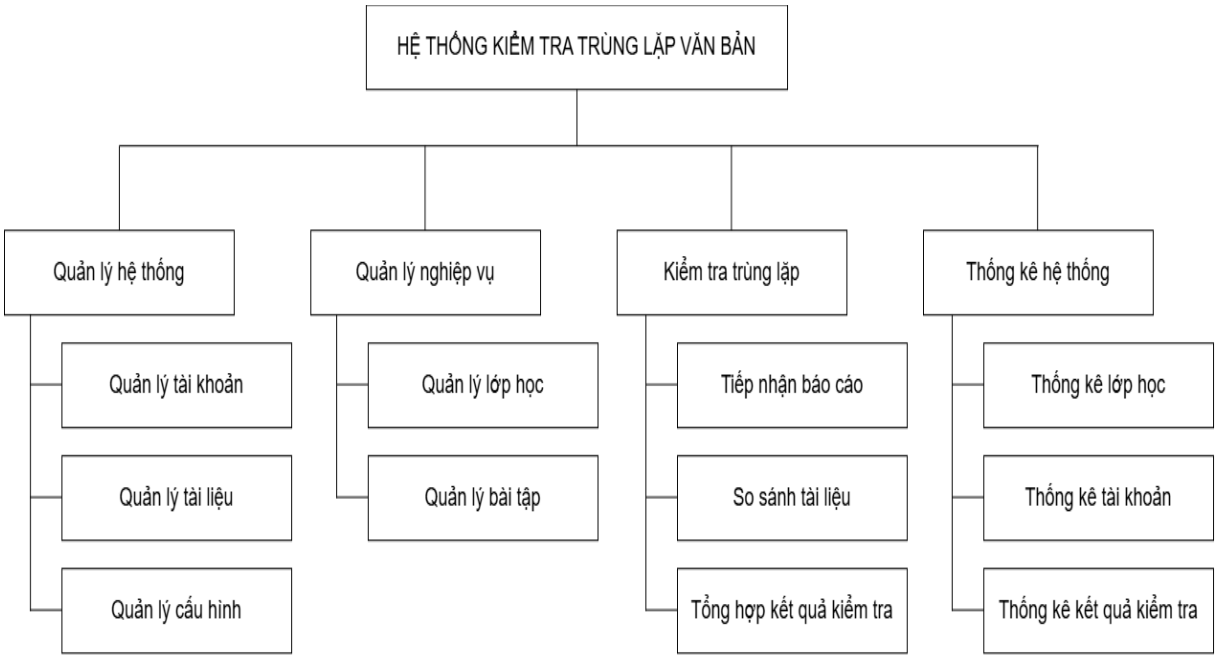
Giai đoạn 6: Hệ thống cần cung cấp kết quả kiểm tra dưới dạng trực quan và dễ theo dõi. Người sử dụng có thể nhanh chóng xác định các vị trí có mức độ tương đồng

cao, xem tỷ lệ trùng lặp của từng tài liệu, theo dõi các bài vượt ngưỡng cảnh báo và tra cứu lịch sử kiểm tra của từng tài liệu.

Giai đoạn 7: Hệ thống cần hỗ trợ chức năng thống kê và báo cáo. Thông qua các công cụ thống kê, người sử dụng có thể theo dõi tổng số bài đã nộp, số lượng lớp học, số lượng tài khoản đang hoạt động, số bài đang xử lý, số bài đã có kết quả và số bài vượt ngưỡng cảnh báo. Các thông tin thống kê được trình bày dưới dạng biểu đồ và báo cáo tổng hợp nhằm hỗ trợ công tác quản lý và ra quyết định.

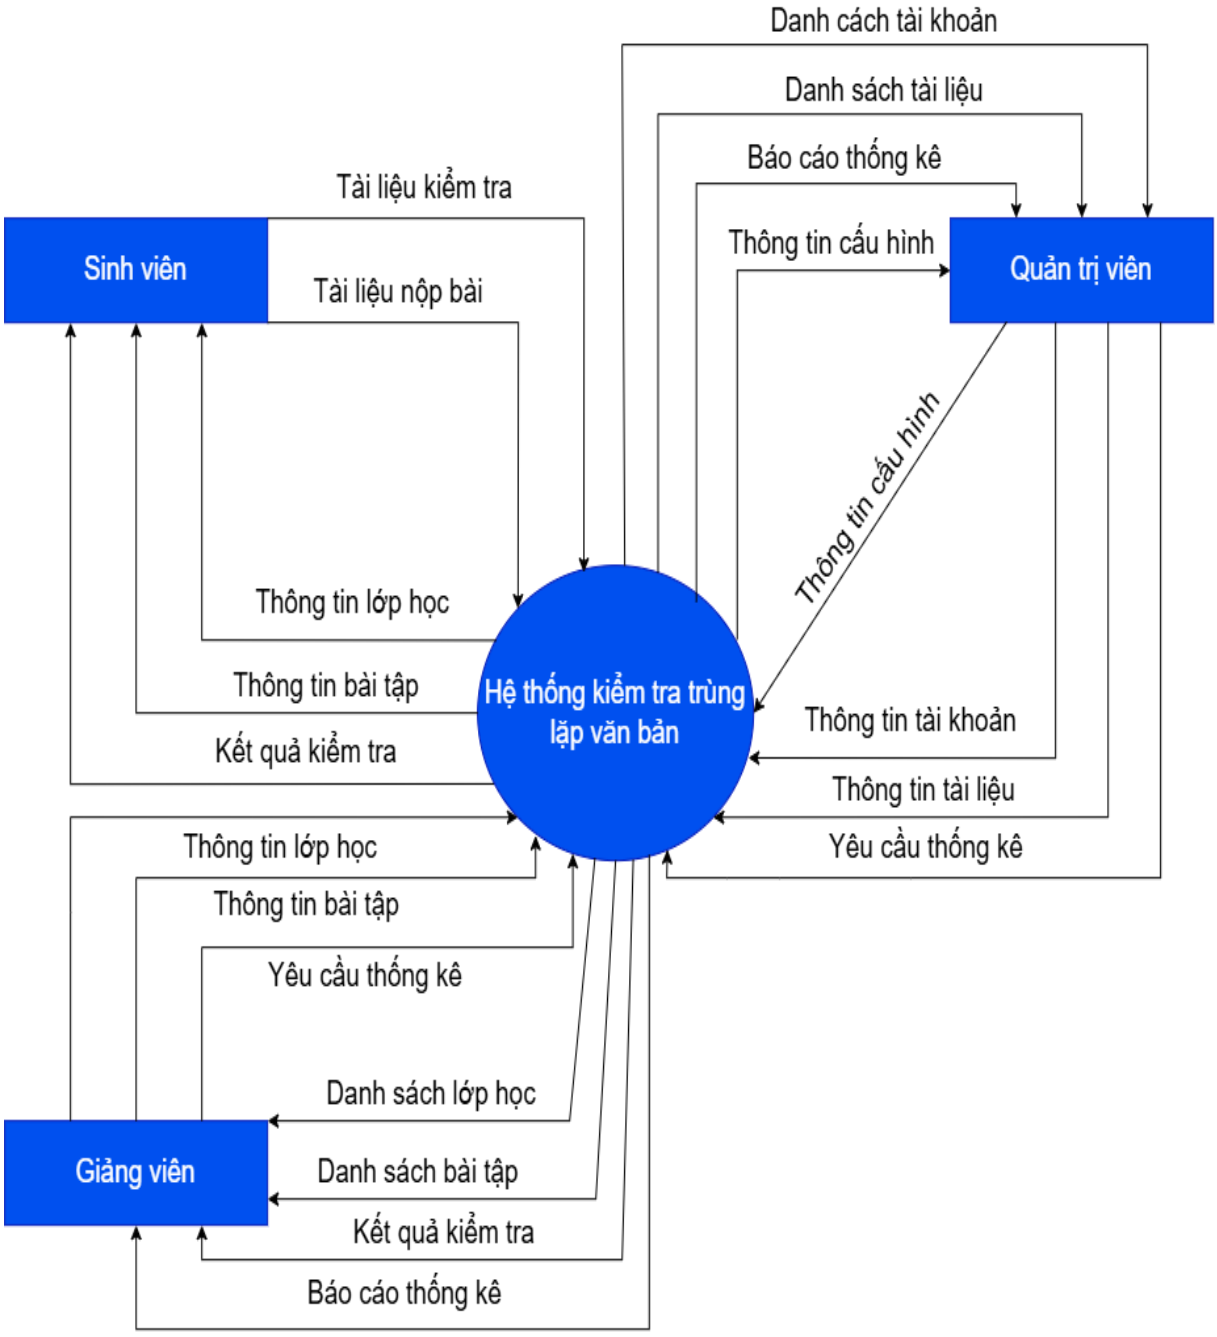
Giai đoạn 8: Hệ thống cần hỗ trợ xuất báo cáo dưới định dạng Excel. Giảng viên và quản trị viên có thể xuất danh sách sinh viên đã nộp bài, danh sách sinh viên chưa nộp bài, kết quả kiểm tra trùng lặp của từng sinh viên, thống kê theo lớp học và các báo cáo tổng hợp khác phục vụ công tác quản lý đào tạo.

2.2. Sơ đồ phân rã chức năng



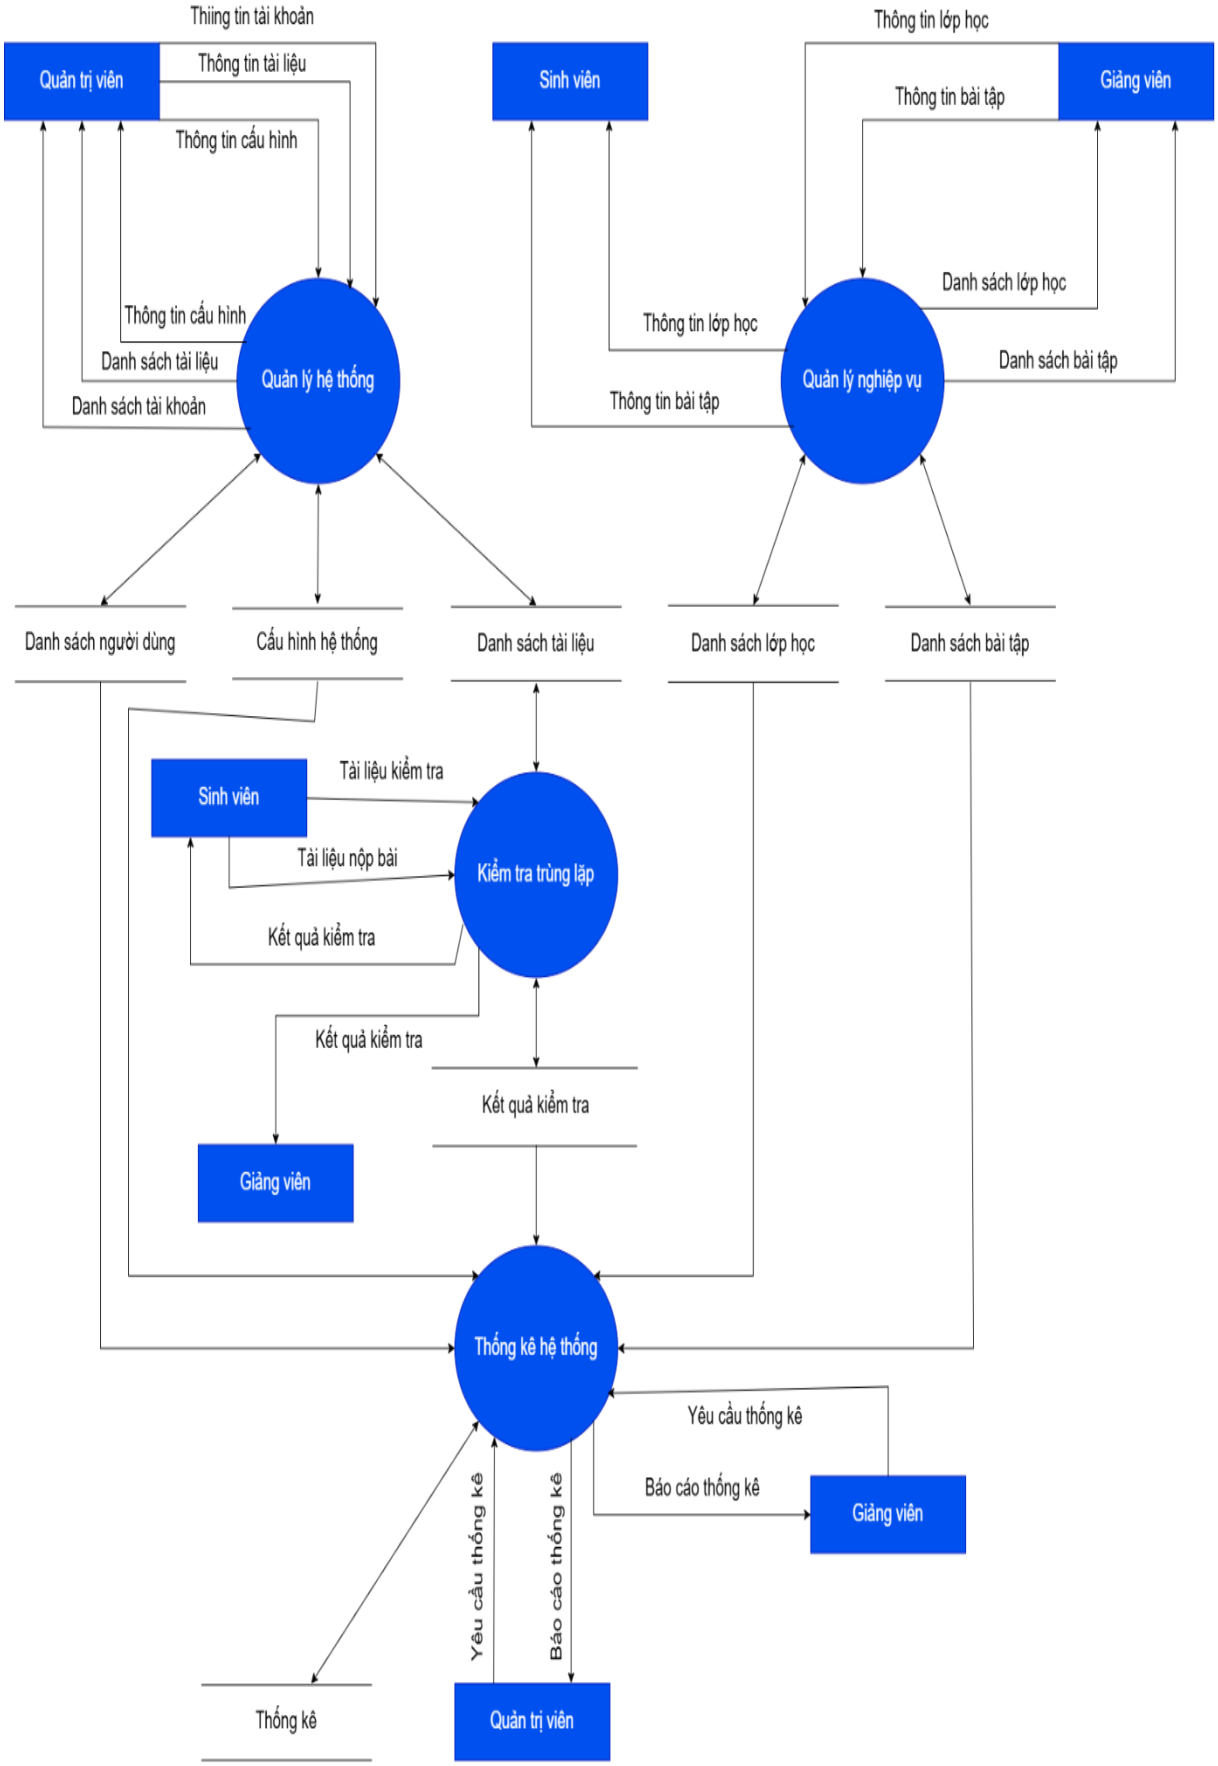
Hình 2.1. Sơ đồ phân rã chức năng

2.3. Sơ đồ mức ngữ cảnh



Hình 2.2. Sơ đồ mức ngữ cảnh

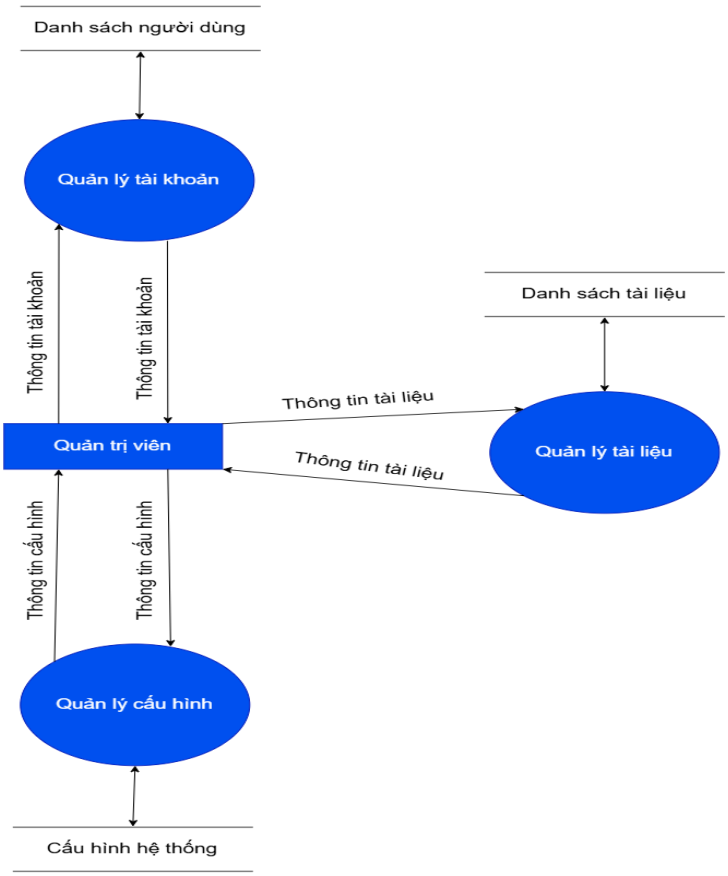
2.4. Sơ đồ mức đỉnh



Hình 2.3. Sơ đồ mức đỉnh

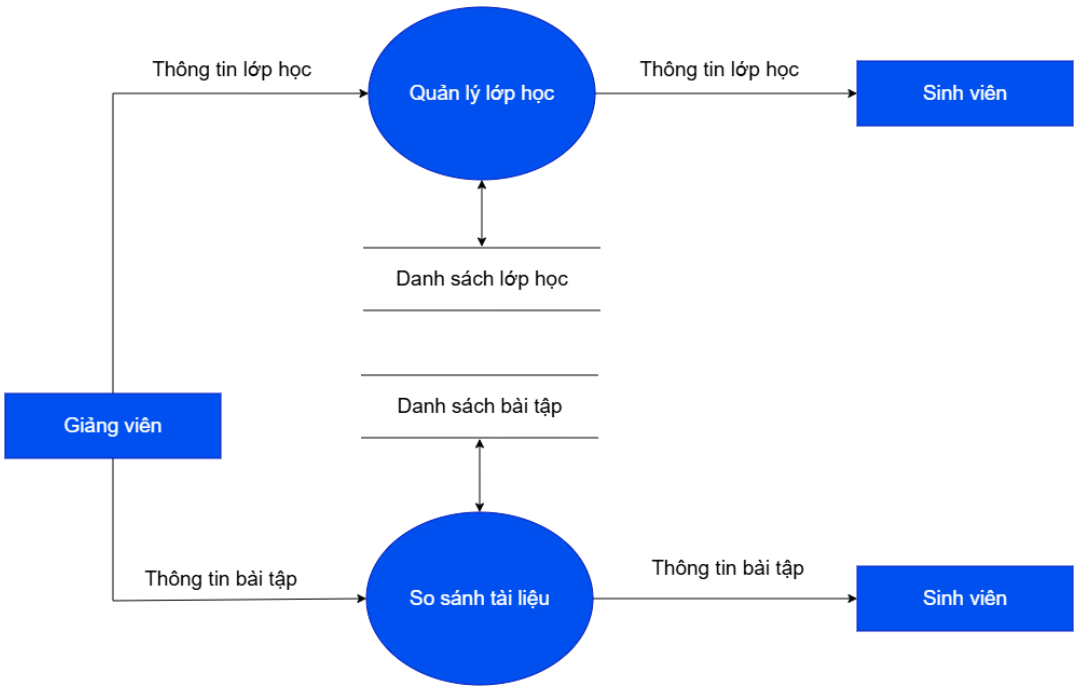
2.5. Sơ đồ mức dưới đỉnh

2.5.1. Sơ đồ mức dưới đỉnh với chức năng quản lý hệ thống



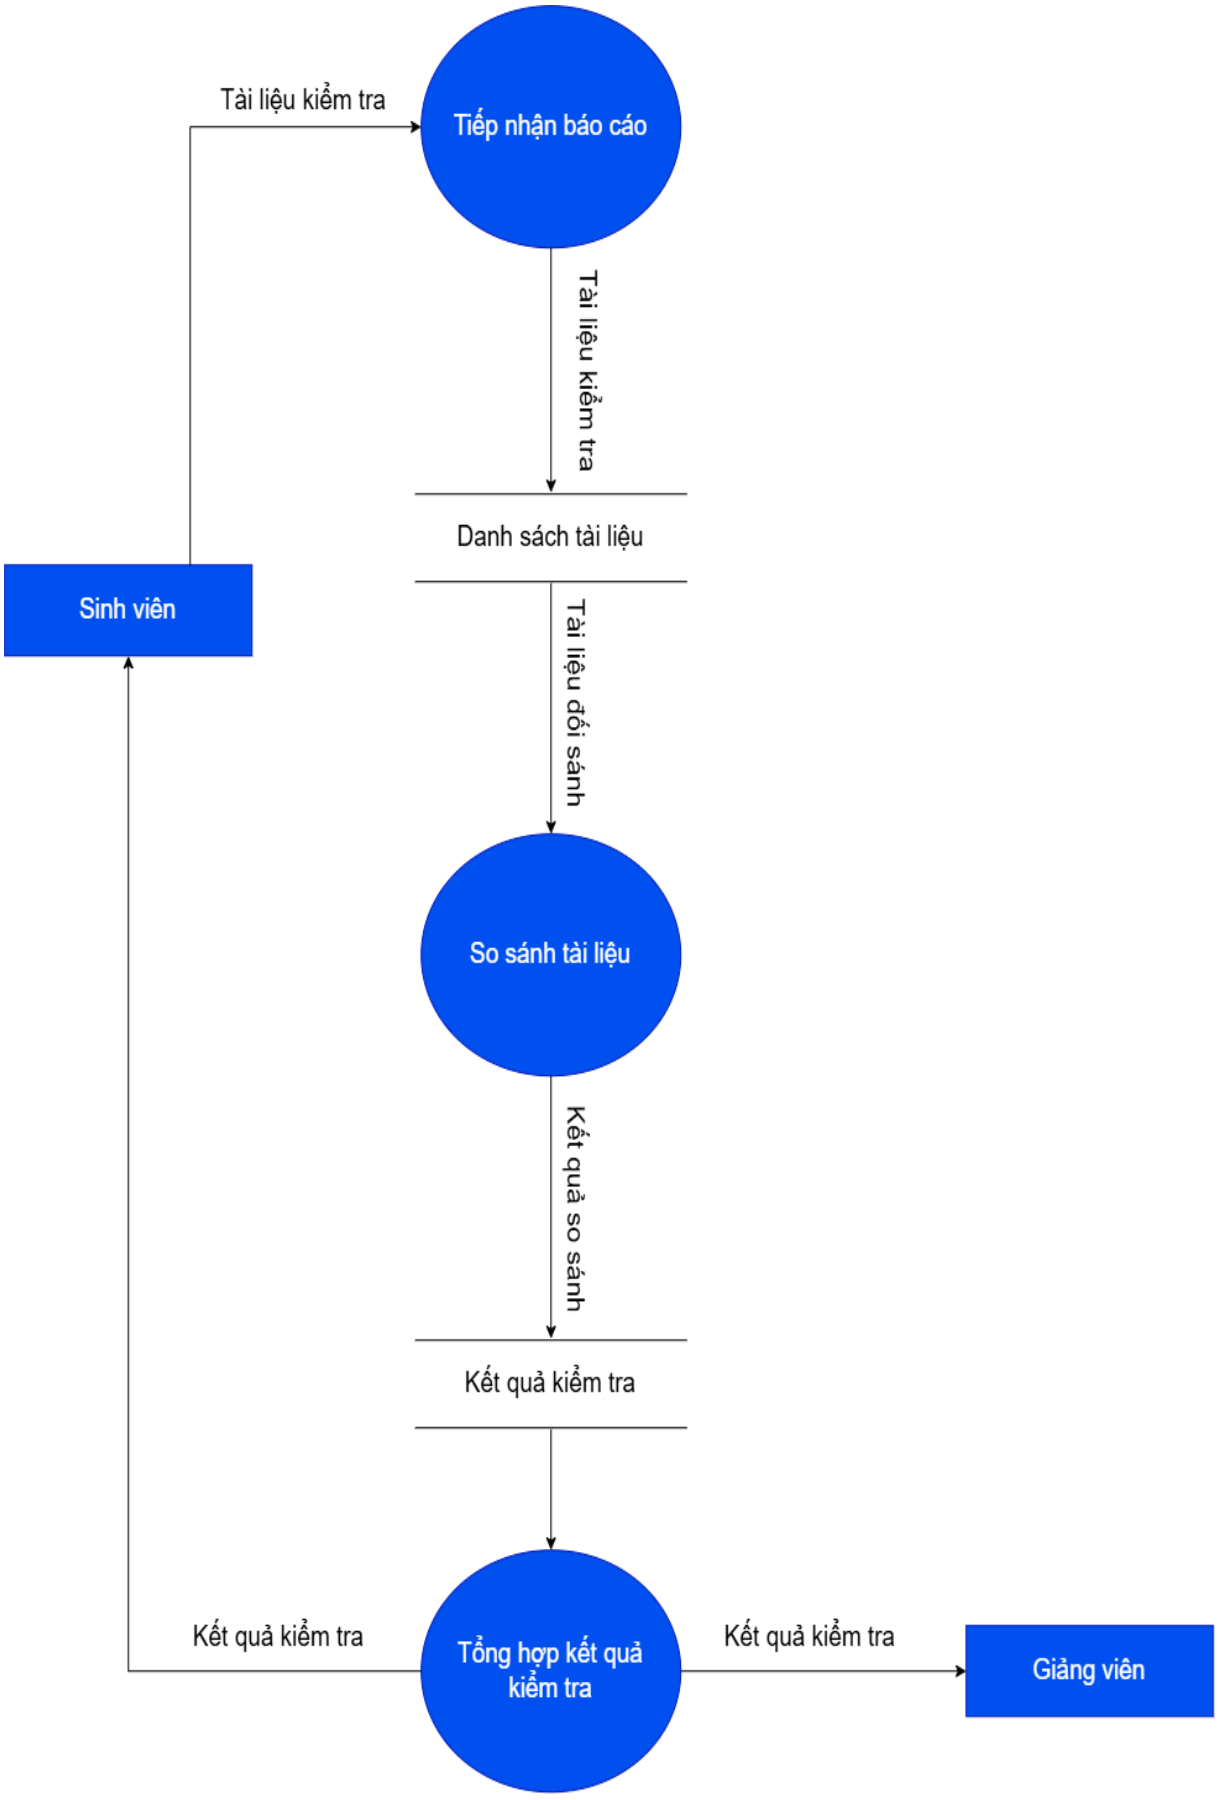
Hình 2.4. Sơ đồ mức dưới đỉnh với chức năng quản lý hệ thống

2.5.2. Sơ đồ mức dưới đỉnh với chức năng quản lý nghiệp vụ



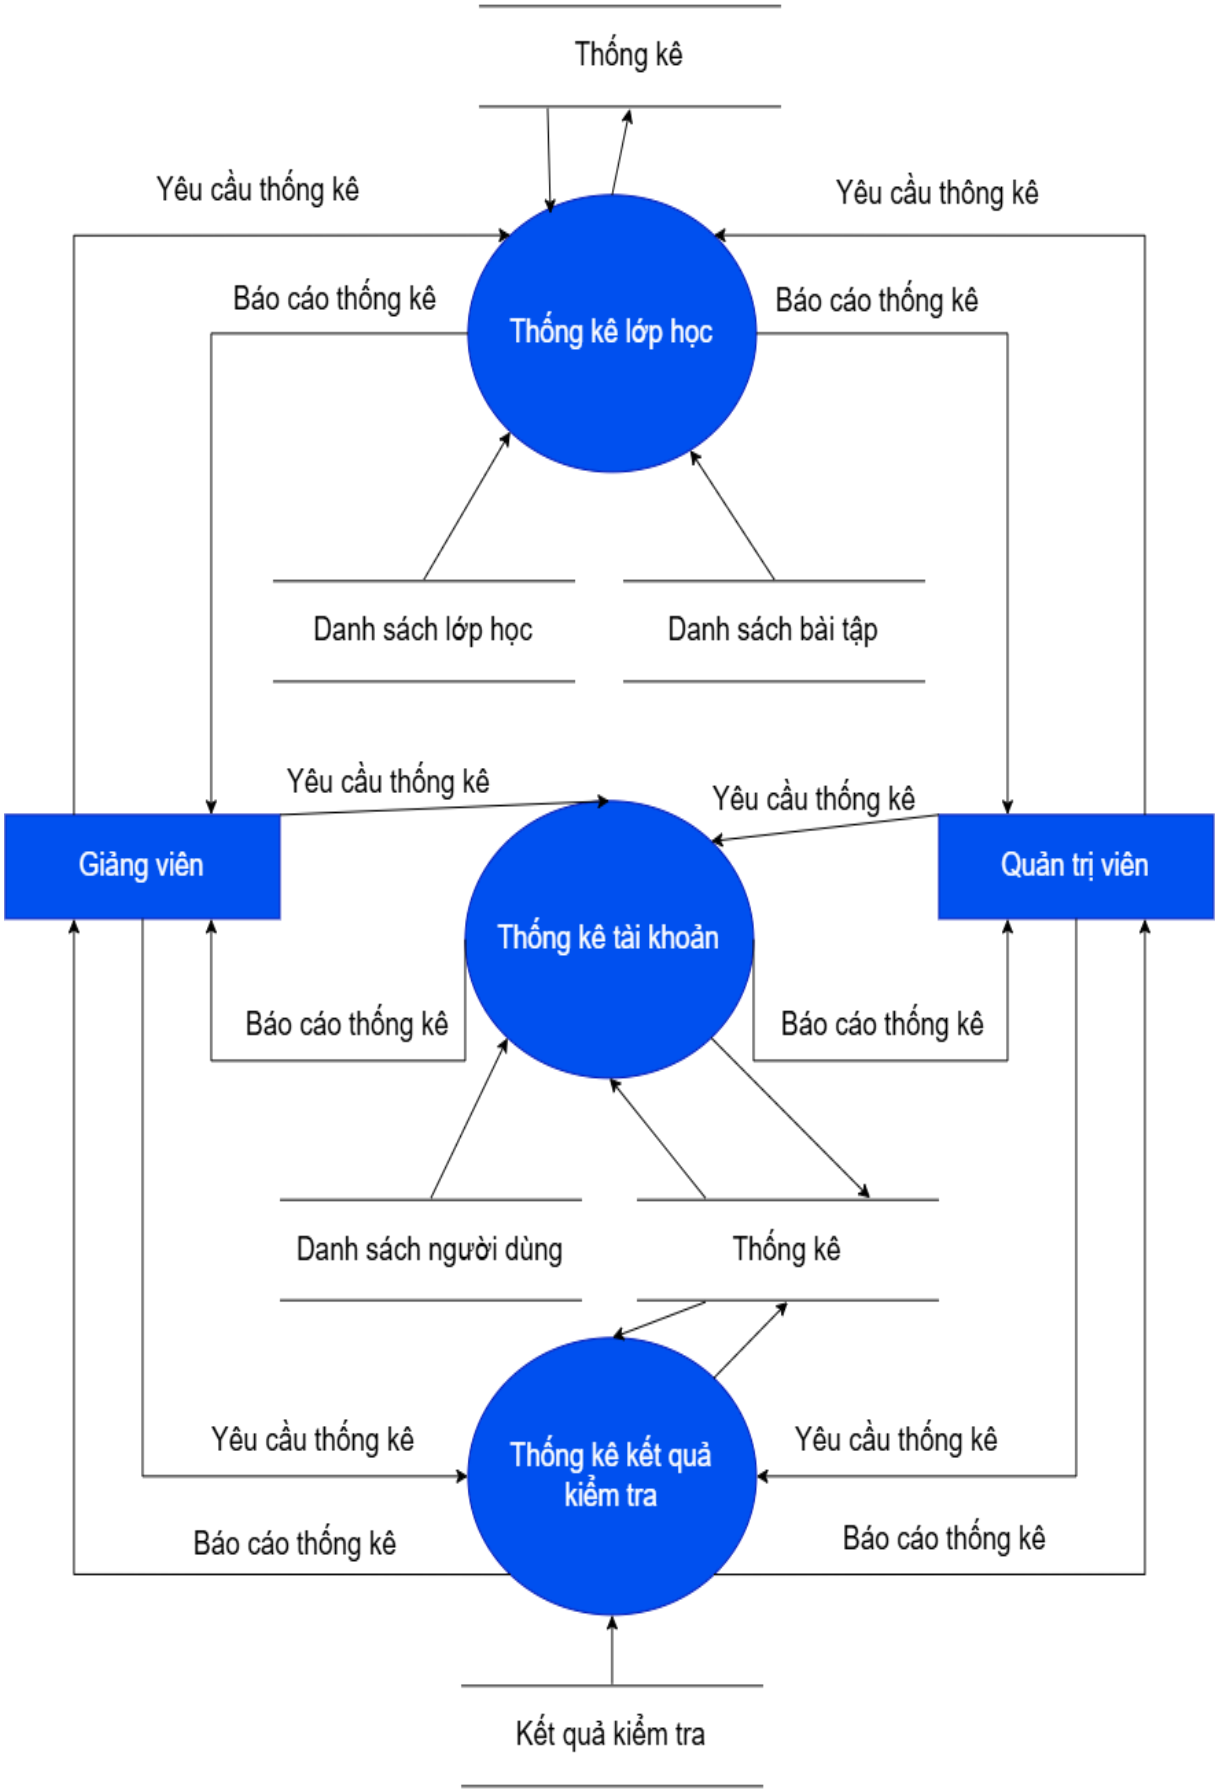
Hình 2.5. Sơ đồ mức dưới đỉnh với chức năng quản lý nghiệp vụ

2.5.3. Sơ đồ mức dưới đỉnh với chức năng kiểm tra trùng lặp



Hình 2.6. Sơ đồ mức dưới đỉnh với chức năng kiểm tra trùng lặp

2.5.4. Sơ đồ mức dưới đỉnh với chức năng thống kê hệ thống



Hình 2.7. Sơ đồ mức dưới đỉnh với chức năng thống kê hệ thống

2.6. Chuẩn hóa dữ liệu

2.6.1. Chuẩn hóa dữ liệu Người dùng

Bảng 2.1. Bảng chuẩn hóa dữ liệu người dùng

Thuộc tính chưa chuẩn hóa	1NF	2NF	3NF
Mã người dùng	#Mã người dùng	#Mã người dùng	#Mã người dùng
Tên đăng nhập	Tên đăng nhập	Tên đăng nhập	Tên đăng nhập
Mật khẩu	Mật khẩu	Mật khẩu	Mật khẩu
Họ tên	Họ tên	Họ tên	Họ tên
Email	Email	Email	Email
Vai trò	Vai trò	Vai trò	Vai trò
Trạng thái	Trạng thái	Trạng thái	Trạng thái
Ngày tạo	Ngày tạo	Ngày tạo	Ngày tạo
Ngày cập nhật	Ngày cập nhật	Ngày cập nhật	Ngày cập nhật
Hình ảnh	Hình ảnh	Hình ảnh	Hình ảnh

2.6.2. Chuẩn hóa dữ liệu Sinh viên

Bảng 2.2. Bảng chuẩn hóa dữ liệu sinh viên

Thuộc tính chưa chuẩn hóa	1NF	2NF	3NF
Mã sinh viên	#Mã sinh viên	#Mã sinh viên	#Mã sinh viên
Họ tên	Họ tên	Họ tên	Họ tên
Lớp	Lớp	Lớp	Lớp
Khóa học	Khóa học	Khóa học	Khóa học
Email	Email	Email	Email
Số báo cáo	Số báo cáo	Số báo cáo	Số báo cáo
Mã người dùng	Mã người dùng	Mã người dùng	Mã người dùng

2.6.3. Chuẩn hóa dữ liệu Giảng viên

Bảng 2.3. Bảng chuẩn hóa dữ liệu giảng viên

Thuộc tính chưa chuẩn hóa	1NF	2NF	3NF
Mã giảng viên Họ tên Bộ môn Email Mã người dùng	#Mã giảng viên Họ tên Bộ môn Email Mã người dùng	#Mã giảng viên Họ tên Bộ môn Email Mã người dùng	#Mã giảng viên Họ tên Bộ môn Email Mã người dùng

2.6.4. Chuẩn hóa dữ liệu Lớp học

Bảng 2.4. Bảng chuẩn hóa dữ liệu lớp học

Thuộc tính chưa chuẩn hóa	1NF	2NF	3NF
Mã lớp học Tiêu đề lớp Mô tả lớp Mã lớp Ngày tạo Ngày cập nhật Mã người dùng Danh sách thành viên (Mã người dùng, Họ tên, Email)	#Mã lớp học Tiêu đề lớp Mô tả lớp Mã lớp Ngày tạo Ngày cập nhật Mã người dùng #Mã người dùng, Họ tên, Email	#Mã lớp học Tiêu đề lớp Mô tả lớp Mã lớp Ngày tạo Ngày cập nhật Mã người dùng Danh sách thành viên (#Mã người dùng, Họ tên, Email)	#Mã lớp học Tiêu đề lớp Mô tả lớp Mã lớp Ngày tạo Ngày cập nhật Mã người dùng Danh sách thành viên(#Mã người dùng, Họ tên, Email)

2.6.5. Chuẩn hóa dữ liệu Bài tập

Bảng 2.5. Bảng chuẩn hóa dữ liệu bài tập

Thuộc tính chưa chuẩn hóa	1NF	2NF	3NF
Mã bài tập Mã lớp học Tiêu đề Hướng dẫn Thời gian bắt đầu Thời gian kết thúc Trạng thái Định dạng tệp Danh sách nộp bài (Mã sinh viên, Họ tên, Trạng thái nộp, Thời gian nộp)	#Mã bài tập Mã lớp học Tiêu đề Hướng dẫn Thời gian bắt đầu Thời gian kết thúc Trạng thái Định dạng tệp #Mã sinh viên, Họ tên, Trạng thái nộp, Thời gian nộp	#Mã bài tập Mã lớp học Tiêu đề Hướng dẫn Thời gian bắt đầu Thời gian kết thúc Trạng thái Định dạng tệp Danh sách nộp bài(#Mã bài tập, #Mã sinh viên, Trạng thái nộp, Thời gian nộp)	#Mã bài tập Mã lớp học Tiêu đề Hướng dẫn Thời gian bắt đầu Thời gian kết thúc Trạng thái Định dạng tệp Danh sách nộp bài(#Mã bài tập, #Mã sinh viên, Mã báo cáo, Trạng thái nộp, Thời gian nộp)

2.6.6. Chuẩn hóa dữ liệu Báo cáo

Bảng 2.6. Bảng chuẩn hóa dữ liệu báo cáo

Thuộc tính chưa chuẩn hóa	1NF	2NF	3NF
Mã báo cáo Tiêu đề Loại báo cáo Tệp tin Ngày tải lên Trạng thái Mã sinh viên Mẫu kiểm tra	#Mã báo cáo Tiêu đề Loại báo cáo Tệp tin Ngày tải lên Trạng thái Mã sinh viên Mẫu kiểm tra	#Mã báo cáo Tiêu đề Loại báo cáo Tệp tin Ngày tải lên Trạng thái Mã sinh viên Mẫu kiểm tra	#Mã báo cáo Tiêu đề Loại báo cáo Tệp tin Ngày tải lên Trạng thái Mã sinh viên Mẫu kiểm tra

2.6.7. Chuẩn hóa dữ liệu Kết quả kiểm tra

Bảng 2.7. Bảng chuẩn hóa dữ liệu kết quả kiểm tra

Thuộc tính chưa chuẩn hóa	1NF	2NF	3NF
Mã kiểm tra Mã báo cáo Mã sinh viên Tỷ lệ trùng lặp Tổng số câu Tổng số từ Tổng số câu trùng Tổng số từ trùng Tổng số đoạn trùng Tổng số đoạn chắp vá Số nguồn phát hiện Trạng thái Ngày kiểm tra	#Mã kiểm tra Mã báo cáo Mã sinh viên Tỷ lệ trùng lặp Tổng số câu Tổng số từ Tổng số câu trùng Tổng số từ trùng Tổng số đoạn trùng Tổng số đoạn chắp vá Số nguồn phát hiện Trạng thái Ngày kiểm tra	#Mã kiểm tra Mã báo cáo Mã sinh viên Tỷ lệ trùng lặp Tổng số câu Tổng số từ Tổng số câu trùng Tổng số từ trùng Tổng số đoạn trùng Tổng số đoạn chắp vá Số nguồn phát hiện Trạng thái Ngày kiểm tra	#Mã kiểm tra Mã báo cáo Mã sinh viên Tỷ lệ trùng lặp Tổng số câu Tổng số từ Tổng số câu trùng Tổng số từ trùng Tổng số đoạn trùng Tổng số đoạn chắp vá Số nguồn phát hiện Trạng thái Ngày kiểm tra

2.6.8. Chuẩn hóa dữ liệu Chi tiết nộp bài

Bảng 2.8. Bảng chuẩn hóa dữ liệu chi tiết nộp bài

Thuộc tính chưa chuẩn hóa	1NF	2NF	3NF
Mã bài tập Mã sinh viên Mã báo cáo Tiêu đề tệp Ngày nộp Trạng thái Loại báo cáo	#Mã bài tập #Mã sinh viên Mã báo cáo Tiêu đề tệp Ngày nộp Trạng thái Loại báo cáo	#Mã bài tập #Mã sinh viên Mã báo cáo bao_cao(#Mã báo cáo, Tiêu đề tệp) Ngày nộp Trạng thái Loại báo cáo	#Mã bài tập #Mã sinh viên Mã báo cáo bao_cao(#Mã báo cáo, Tiêu đề tệp) Ngày nộp Trạng thái Loại báo cáo

2.7. Phát hiện thực thể

Dựa trên các bảng dữ liệu đã chuẩn hóa, xác định được 8 thực thể chính của hệ thống kiểm tra trùng lặp văn bản gồm: Người dùng, Sinh viên, Giảng viên, Lớp học, Bài tập, Báo cáo, Kết quả kiểm tra và Chi tiết nộp bài.

2.7.1. Thực thể người dùng

Các thuộc tính:

- ✓ Mã người dùng (**Khóa chính**): Mã người dùng là thuộc tính khóa để phân biệt với các người dùng khác.
- ✓ Tên đăng nhập
- ✓ Mật khẩu
- ✓ Họ tên
- ✓ Email
- ✓ Vai trò
- ✓ Trạng thái
- ✓ Hình ảnh đại diện
- ✓ Ngày tạo
- ✓ Ngày cập nhật

2.7.2. Thực thể sinh viên

Các thuộc tính:

- ✓ Mã sinh viên (**Khóa chính**): Mã sinh viên là thuộc tính khóa để phân biệt với các sinh viên khác.
- ✓ Họ tên
- ✓ Lớp
- ✓ Khóa học
- ✓ Email
- ✓ Số báo cáo
- ✓ Mã người dùng (**Khóa ngoại**)

2.7.3. Thực thể giảng viên

Các thuộc tính:

- ✓ Mã giảng viên (**Khóa chính**): Mã giảng viên là thuộc tính khóa để phân biệt với các giảng viên khác.
- ✓ Họ tên

- ✓ Bộ môn
- ✓ Email
- ✓ Mã người dùng (**Khóa ngoại**)

2.7.4. Thực thể lớp học

Các thuộc tính:

- ✓ Mã lớp học (**Khóa chính**): Mã lớp học là thuộc tính khóa để phân biệt với các lớp học khác.
- ✓ Mã người dùng (**Khóa ngoại**)
- ✓ Tiêu đề lớp học
- ✓ Mô tả lớp học
- ✓ Mã lớp
- ✓ Danh sách thành viên
- ✓ Ngày tạo
- ✓ Ngày cập nhật

2.7.5. Thực thể bài tập

Các thuộc tính:

- ✓ Mã bài tập (**Khóa chính**): Mã bài tập là thuộc tính khóa để phân biệt với các bài tập khác.
- ✓ Mã lớp học (**Khóa ngoại**)
- ✓ Tiêu đề bài tập
- ✓ Hướng dẫn
- ✓ Thời gian bắt đầu
- ✓ Thời gian kết thúc
- ✓ Trạng thái
- ✓ Định dạng tệp
- ✓ Danh sách nộp bài
- ✓ Ngày tạo
- ✓ Ngày cập nhật

2.7.6. Thực thể báo cáo

Các thuộc tính:

- ✓ Mã báo cáo (**Khóa chính**): Mã báo cáo là thuộc tính khóa để phân biệt với các báo cáo khác.

- ✓ Tiêu đề báo cáo
- ✓ Loại báo cáo
- ✓ Tệp tin
- ✓ Ngày tải lên
- ✓ Trạng thái
- ✓ Mã sinh viên (**Khóa ngoại**)
- ✓ Báo cáo mẫu

2.7.7. Thực thể kết quả kiểm tra

Các thuộc tính:

- ✓ Mã kiểm tra (**Khóa chính**): Mã kiểm tra là thuộc tính khóa để phân biệt với các kết quả kiểm tra khác.
- ✓ Mã báo cáo (**Khóa ngoại**)
- ✓ Mã sinh viên (**Khóa ngoại**)
- ✓ Tỷ lệ trùng lặp
- ✓ Tổng số câu
- ✓ Tổng số từ
- ✓ Tổng số câu trùng
- ✓ Tổng số từ trùng
- ✓ Tổng số đoạn trùng
- ✓ Tổng số đoạn chắp vá
- ✓ Số nguồn phát hiện
- ✓ Trạng thái
- ✓ Ngày kiểm tra
- ✓ Ngày tạo
- ✓ Ngày cập nhật

2.7.8. Thực thể chi tiết nộp bài

Các thuộc tính:

- ✓ Mã bài tập (**Khóa ngoại**)
- ✓ Mã sinh viên (**Khóa ngoại**)
- ✓ Mã báo cáo (**Khóa ngoại**)
- ✓ Tiêu đề tệp
- ✓ Ngày nộp

- ✓ Trạng thái
- ✓ Loại báo cáo
- ✓ Ngày tạo
- ✓ Ngày cập nhật

2.8. Xây ma trận thực thể khóa

Bảng 2.9. Bảng ma trận thực thể khóa

Thực thể / Khóa	Người dùng	Sinh viên	Giảng viên	Lớp học	Bài tập	Báo cáo	Kết quả kiểm tra	Chi tiết nộp bài
Mã người dùng	PK	FK	FK	FK				
Mã sinh viên		PK				FK	FK	FK
Mã giảng viên			PK					
Mã lớp học				PK	FK			
Mã bài tập					PK			FK
Mã báo cáo						PK	FK	FK
Mã kiểm tra							PK	

CHƯƠNG 3
XÂY DỰNG VÀ CÀI ĐẶT THỰC NGHIỆM

3.1. Môi trường và công nghệ phát triển hệ thống

3.1.1. Ngôn ngữ lập trình Node.js

Node.js là môi trường thực thi JavaScript phía máy chủ được xây dựng trên nền tảng V8 Engine của Google. Khác với các nền tảng xử lý truyền thống sử dụng cơ chế đa luồng, Node.js hoạt động dựa trên mô hình Event Loop và Non-blocking I/O, cho phép xử lý đồng thời nhiều yêu cầu với mức tiêu thụ tài nguyên thấp.

Trong đề tài này, Node.js được sử dụng để xây dựng toàn bộ hệ thống Backend, quản lý luồng xử lý dữ liệu, tiếp nhận yêu cầu từ người dùng và điều phối quá trình kiểm tra trùng lặp văn bản.

Việc lựa chọn Node.js xuất phát từ các ưu điểm sau:

- Hỗ trợ xử lý bất đồng bộ hiệu quả.
- Khả năng đáp ứng cao khi có nhiều người dùng truy cập đồng thời.
- Hệ sinh thái thư viện phong phú.
- Dễ dàng tích hợp với MongoDB, Redis và BullMQ.
- Thuận lợi trong việc phát triển các API phục vụ hệ thống.

Các chức năng chính được xây dựng bằng Node.js gồm:

- Quản lý người dùng.
- Quản lý lớp học.
- Quản lý bài tập.
- Quản lý báo cáo.
- Kiểm tra trùng lặp văn bản.
- Thống kê và báo cáo dữ liệu.

3.1.2. Framework ExpressJS

ExpressJS là Framework phổ biến của Node.js dùng để xây dựng các ứng dụng Web và RESTful API. Trong hệ thống, ExpressJS được sử dụng nhằm tổ chức cấu trúc chương trình theo hướng module hóa, giúp việc bảo trì và mở rộng hệ thống trở nên thuận tiện hơn.

Một số chức năng được triển khai thông qua ExpressJS bao gồm:

- API xác thực người dùng.

- API quản lý báo cáo.
- API quản lý lớp học.
- API quản lý bài tập.
- API kiểm tra trùng lặp.
- API thống kê dữ liệu.

3.1.3. Hệ quản trị cơ sở dữ liệu MongoDB

MongoDB là hệ quản trị cơ sở dữ liệu NoSQL lưu trữ dữ liệu dưới dạng Document. Khác với cơ sở dữ liệu quan hệ truyền thống, MongoDB cho phép lưu trữ dữ liệu linh hoạt và phù hợp với các hệ thống xử lý văn bản có khối lượng dữ liệu lớn. Trong đề tài, MongoDB được sử dụng để lưu trữ:

- Thông tin người dùng.
- Thông tin lớp học.
- Thông tin bài tập.
- Thông tin báo cáo.
- Kết quả kiểm tra.
- Chi tiết các câu và đoạn văn trùng lặp.

MongoDB mang lại các lợi ích như:

- Khả năng mở rộng cao.
- Tốc độ truy vấn nhanh.
- Dễ dàng thay đổi cấu trúc dữ liệu.
- Hỗ trợ tốt cho dữ liệu phi cấu trúc.

3.1.4. Redis và BullMQ

Kiểm tra trùng lặp văn bản là một tác vụ tiêu tốn nhiều tài nguyên xử lý, đặc biệt khi tài liệu có kích thước lớn hoặc số lượng người dùng truy cập đồng thời tăng cao. Để giải quyết vấn đề này, hệ thống sử dụng Redis kết hợp BullMQ để xây dựng hàng đợi tác vụ bất đồng bộ. Redis đóng vai trò lưu trữ các Job trong bộ nhớ. BullMQ chịu trách nhiệm:

- Tạo Job.
- Quản lý Queue.
- Theo dõi tiến trình xử lý.
- Retry khi xảy ra lỗi.

Mô hình xử lý được triển khai theo sơ đồ: Người dùng → Upload báo cáo → BullMQ Queue → Redis → Worker → Kiểm tra trùng lặp → MongoDB

Cách tiếp cận này giúp:

- Tăng hiệu năng hệ thống.
- Hạn chế nghẽn luồng xử lý.
- Nâng cao khả năng chịu tải.
- Bảo đảm ổn định khi xử lý nhiều báo cáo đồng thời.

3.2. Xây dựng kiến trúc hệ thống

3.2.1. Kiến trúc tổng thể

Hệ thống được xây dựng theo mô hình Client - Server kết hợp xử lý bất đồng bộ. Kiến trúc gồm năm thành phần chính:

Frontend

Đóng vai trò giao tiếp với người dùng.

Các chức năng:

- Đăng nhập.
- Quản lý lớp học.
- Nộp bài.
- Xem kết quả kiểm tra.
- Theo dõi thống kê.

Backend API

Tiếp nhận và xử lý các yêu cầu từ giao diện.

MongoDB

Lưu trữ toàn bộ dữ liệu của hệ thống.

Redis Queue

Lưu trữ hàng đợi xử lý.

Worker NLP

Thực hiện các thao tác phân tích văn bản và kiểm tra trùng lặp.

3.2.2. Luồng xử lý kiểm tra trùng lặp

Khi người dùng tải báo cáo lên hệ thống, quá trình xử lý được thực hiện theo các bước:

Bước 1: Tiếp nhận báo cáo

Người dùng lựa chọn tệp PDF hoặc DOCX và tải lên hệ thống.

Bước 2: Lưu trữ dữ liệu

Thông tin báo cáo được lưu vào MongoDB.

Bước 3: Khởi tạo tác vụ

Hệ thống tạo một Job mới trong BullMQ.

Bước 4: Worker nhận Job

Worker lấy Job từ hàng đợi và bắt đầu xử lý.

Bước 5: Tiền xử lý văn bản

- Trích xuất nội dung.
- Chuẩn hóa dữ liệu.
- Tách câu.
- Loại bỏ Stopword.

Bước 6: Thực hiện đối sánh

Tiến hành kiểm tra trùng lặp bằng mô hình Hybrid.

Bước 7: Lưu kết quả

Kết quả kiểm tra được ghi xuống cơ sở dữ liệu.

Bước 8: Trả kết quả

Người dùng được thông báo khi quá trình kiểm tra hoàn tất.

3.3. Hiện thực thuật toán kiểm tra trùng lặp

3.3.1. Phát hiện trùng lặp bằng Fingerprint

Sau khi tiền xử lý, mỗi câu được chuyển thành tập các Word K-Gram. Mỗi K-Gram được băm thành giá trị Hash. Các giá trị Hash được sử dụng để tạo Fingerprint đại diện cho nội dung câu. Phương pháp này giúp phát hiện nhanh các câu sao chép nguyên văn.

3.3.2. Áp dụng thuật toán Winnowing

Thuật toán Winnowing được triển khai gồm các bước:

- **Sinh K-Gram:** Văn bản được chia thành các chuỗi từ liên tiếp.
- **Tính Hash:** Tạo giá trị băm cho từng K-Gram.
- **Tạo Sliding Window:** Các giá trị băm liên tiếp được nhóm thành các cửa sổ trượt.
- **Chọn Fingerprint:** Giá trị nhỏ nhất trong mỗi cửa sổ được lựa chọn làm dấu vân tay.

3.3.3. Tính độ tương đồng bằng TF-IDF và Cosine Similarity

TF-IDF (Term Frequency - Inverse Document Frequency) là phương pháp đánh giá mức độ quan trọng của một từ trong tài liệu.

TF (Term Frequency) dùng để ước lượng tần số xuất hiện của một từ trong một văn bản.

$$\mathrm{TF}\ (t, d) = \frac{f(t, d)}{\max\{f(w, d) : w \in d\}}$$

Trong đó:

- f(t,d) là số lần xuất hiện của từ t trong văn bản d.
- $\max\{f(w, d) : w \in d\}$ là tần xuất của từ xuất hiện nhiều nhất trong văn bản d.

IDF (Inverse Document Frequency) dùng để ước lượng mức độ quan trọng của một từ trong toàn bộ tập văn bản.

$$\mathrm{IDF}(t, D) = \log\left(\frac{|D|}{|\{d \in D : t \in d\}|}\right)$$

Trong đó:

- |D| là tổng số văn bản trong tập văn bản D.
- $|\{d \in D : t \in d\}|$ là số lượng văn bản trong tập văn bản D có chứa từ t.

Trọng số TF-IDF:

$$TF - IDF(t,d,D) = TF(t,d) \times IDF(t,D)$$

Sau khi tính trọng số TF-IDF cho từng từ trong tài liệu, hệ thống biểu diễn mỗi tài liệu dưới dạng vector đặc trưng. Các vector này được sử dụng để tính toán Cosine Similarity nhằm đánh giá mức độ tương đồng giữa các văn bản. Giá trị Cosine Similarity càng lớn thể hiện mức độ tương đồng giữa hai văn bản càng cao.

3.3.4. Áp dụng Jaccard Similarity

Trong hệ thống, Jaccard Similarity được sử dụng để đánh giá mức độ tương đồng giữa các văn bản dựa trên mức độ giao nhau của tập từ sau quá trình tiền xử lý. Sau khi thực hiện chuẩn hóa văn bản, tách từ và loại bỏ từ dừng, mỗi câu hoặc đoạn văn được biểu diễn dưới dạng một tập từ đặc trưng để phục vụ quá trình đối sánh.

Độ đo Jaccard Similarity được sử dụng nhằm bổ sung cho các phương pháp đối sánh dựa trên Fingerprint, Winnowing và Cosine Similarity. Việc kết hợp nhiều độ đo tương đồng giúp hệ thống đánh giá toàn diện hơn mức độ giống nhau giữa các văn bản,

đặc biệt trong những trường hợp nội dung có sự thay đổi nhất định về cách diễn đạt hoặc cấu trúc trình bày nhưng vẫn duy trì nhiều thành phần từ vựng chung.

Kết quả tính toán từ Jaccard Similarity được sử dụng như một thành phần trong mô hình phát hiện trùng lặp lai của hệ thống và được tổng hợp với các kết quả đánh giá khác để xác định mức độ tương đồng cuối cùng giữa các tài liệu.

3.3.5. Phát hiện đoạn trùng lặp liên tiếp

Sau khi thực hiện quá trình đối sánh và phát hiện các câu có mức độ tương đồng vượt ngưỡng cho phép, hệ thống tiếp tục thực hiện bước xác định các đoạn văn trùng lặp liên tiếp. Mục tiêu của giai đoạn này là phát hiện các trường hợp sao chép nguyên đoạn thay vì chỉ xác định các câu trùng lặp riêng lẻ.

Nhiều trường hợp sao chép không chỉ xuất hiện ở một câu đơn lẻ mà còn bao gồm nhiều câu liên tiếp được lấy từ cùng một nguồn tài liệu. Nếu chỉ hiển thị từng câu riêng biệt, người sử dụng sẽ khó đánh giá chính xác phạm vi sao chép của nội dung. Do đó, hệ thống thực hiện cơ chế gom nhóm các câu trùng lặp liền kề để tạo thành các đoạn văn hoàn chỉnh.

Quy trình phát hiện đoạn trùng lặp được thực hiện theo các bước sau:

Bước 1: Xác định các câu đã được đánh giá là trùng lặp thông qua mô hình đối sánh văn bản.

Bước 2: Sắp xếp các câu trùng lặp theo thứ tự xuất hiện trong tài liệu.

Bước 3: Kiểm tra tính liên tiếp giữa các câu trùng lặp. Các câu có vị trí liền kề nhau và cùng tham chiếu đến một nguồn tài liệu sẽ được gom vào cùng một nhóm.

Bước 4: Hợp nhất các câu trong cùng nhóm thành một đoạn văn trùng lặp hoàn chỉnh.

Bước 5: Lưu trữ thông tin đoạn trùng lặp bao gồm:

- Nội dung đoạn văn.
- Vị trí xuất hiện trong tài liệu.
- Nguồn tài liệu tham chiếu.
- Số câu trong đoạn.
- Tỷ lệ tương đồng của đoạn.

3.3.6. Phát hiện nội dung chắp vá từ nhiều nguồn

Đạo văn chắp vá (Patchwork Plagiarism) là hình thức sao chép trong đó nội dung của một tài liệu được hình thành từ nhiều đoạn văn lấy từ các nguồn khác nhau. Đây là một trong những dạng đạo văn khó phát hiện vì mức độ tương đồng với từng nguồn

riêng lẻ thường không quá cao, trong khi tổng thể tài liệu lại được xây dựng chủ yếu từ các nội dung đã tồn tại trước đó. Để giải quyết vấn đề này, hệ thống triển khai cơ chế phát hiện nội dung chắp vá dựa trên kết quả đối sánh ở mức câu và mức đoạn văn.

Quy trình phát hiện được thực hiện như sau:

Bước 1: Thực hiện đối sánh giữa tài liệu kiểm tra và toàn bộ các tài liệu trong cơ sở dữ liệu tham chiếu.

Bước 2: Xác định các câu hoặc đoạn văn có mức độ tương đồng vượt ngưỡng quy định.

Bước 3: Ghi nhận nguồn tham chiếu của từng câu hoặc đoạn được phát hiện trùng lặp.

Bước 4: Thống kê số lượng nguồn xuất hiện trong toàn bộ tài liệu.

Bước 5: Xác định các trường hợp trong đó nhiều đoạn văn khác nhau được lấy từ nhiều nguồn khác nhau và kết hợp trong cùng một tài liệu.

3.3.7. Mô hình phát hiện trùng lặp lai

Đề tài xây dựng mô hình Hybrid nhằm kết hợp ưu điểm của nhiều thuật toán khác nhau. Quá trình xử lý: Văn bản → Tiền xử lý → Hash → Fingerprint→ TF-IDF → Cosine Similarity → Jaccard Similarity → Điểm đánh giá cuối cùng

Trong mô hình đề xuất, kết quả từ các phương pháp Winnowing, Cosine Similarity và Jaccard Similarity được tổng hợp để xác định mức độ tương đồng cuối cùng giữa các tài liệu.

Điểm tương đồng cuối được tính theo công thức:

$$DiemTongHop = 0.4 \times Cosine + 0.4 \times Winnowing + 0.2 \times Jaccard$$

Trong đó:

- **Winnowing** có trọng số 0,4 do có khả năng phát hiện hiệu quả các trường hợp sao chép nguyên văn và các đoạn văn trùng lặp liên tiếp.
- **Cosine Similarity** có trọng số 0,4 nhằm đánh giá mức độ tương đồng của nội dung văn bản thông qua biểu diễn TF-IDF.
- **Jaccard Similarity** có trọng số 0,2 và được sử dụng như một độ đo bổ sung để đánh giá mức độ giao nhau giữa các tập từ.

Các trọng số 0.4, 0.4 và 0.2 được lựa chọn dựa trên vai trò của từng thuật toán trong hệ thống. Winnowing và Cosine Similarity là hai thành phần chính phục vụ phát hiện sao chép nguyên văn và đánh giá mức độ tương đồng nội dung nên được gán trọng số cao hơn. Jaccard Similarity đóng vai trò bổ trợ trong việc đánh giá sự giao nhau giữa các tập từ nên được gán trọng số thấp hơn. Ngoài ra, hệ thống cho phép cấu hình lại các

trọng số này thông qua cơ chế quản lý cấu hình nhằm phục vụ các kịch bản sử dụng khác nhau.

Mô hình này giúp phát hiện hiệu quả:

- Đạo văn từng câu.
- Đạo văn theo đoạn.
- Đạo văn chắp vá từ nhiều nguồn.

3.4. Xây dựng giao diện hệ thống

3.4.1. Giao diện hướng dẫn sử dụng

Giao diện hướng dẫn sử dụng cung cấp các thông tin cần thiết giúp người dùng dễ dàng tiếp cận và sử dụng hệ thống. Nội dung hướng dẫn bao gồm:

- Hướng dẫn đăng ký tài khoản.
- Hướng dẫn đăng nhập hệ thống.
- Hướng dẫn tải báo cáo lên hệ thống và thực hiện kiểm tra trùng lặp.
- Hướng dẫn xem kết quả kiểm tra.

3.4.2. Giao diện đăng nhập

Giao diện đăng nhập cho phép người dùng truy cập vào hệ thống bằng tài khoản đã đăng ký. Sau khi xác thực thành công, hệ thống thực hiện phân quyền tương ứng cho sinh viên, giảng viên hoặc quản trị viên.

3.4.3. Giao diện đăng ký

Giao diện đăng ký cho phép người dùng tạo tài khoản mới bằng cách cung cấp các thông tin cá nhân cần thiết. Sau khi đăng ký thành công, người dùng có thể đăng nhập và sử dụng các chức năng của hệ thống.

3.4.4. Giao diện giới thiệu hệ thống

Giao diện giới thiệu cung cấp thông tin tổng quan về hệ thống kiểm tra trùng lặp văn bản, mục tiêu xây dựng và các phương pháp xử lý được sử dụng.

Nội dung giới thiệu bao gồm:

- Chi tiết kiến trúc hệ thống
- Phương pháp trích chọn đặc trưng TF-IDF
- Thuật toán Winnowing.
- Độ tương đồng Jaccard.
- Đô tương đồng Consine

- Thuật toán Winnowing.

3.4.5. Giao diện quản lý tài liệu

Giao diện quản lý tài liệu cho phép người dùng tải tài liệu lên hệ thống và thực hiện kiểm tra trùng lặp.

Các chức năng chính gồm:

- Tải tài liệu lên hệ thống.
- Xem danh sách tài liệu đã kiểm tra.
- Xem trạng thái xử lý tài liệu.
- Xem tỷ lệ trùng lặp của từng tài liệu.
- Truy cập trang chi tiết kết quả kiểm tra.

Tại giao diện chi tiết kết quả kiểm tra, hệ thống hiển thị:

- Tỷ lệ trùng lặp của tài liệu.
- Số lượng nguồn phát hiện trùng lặp.
- Danh sách các nguồn tương đồng.
- Chi tiết các câu trùng lặp.
- Chi tiết các đoạn trùng lặp.
- Chi tiết các đoạn chắp vá.
- Nội dung tài liệu được tô màu theo mức độ trùng lặp của câu (bôi màu theo câu).

3.4.6. Giao diện quản lý lớp học

Giao diện quản lý lớp học hỗ trợ giảng viên và sinh viên quản lý các hoạt động học tập trên hệ thống.

Các chức năng chính gồm:

Đối với giảng viên

- Tạo lớp học.
- Cập nhật thông tin lớp học.
- Xóa lớp học.
- Quản lý danh sách thành viên lớp học.
- Tạo bài tập.
- Cập nhật bài tập.
- Xóa bài tập.
- Theo dõi tiến độ nộp bài của sinh viên.

- Xem danh sách sinh viên đã nộp bài.
- Xem danh sách sinh viên chưa nộp bài.
- Xem kết quả kiểm tra của sinh viên.
- Tải xuống báo cáo của sinh viên đã được tô màu.

Đối với sinh viên

- Tham gia lớp học bằng mã lớp.
- Xem danh sách bài tập.
- Nộp bài tập.

3.4.7. Giao diện thống kê hệ thống

Giao diện thống kê cung cấp các thông tin tổng hợp về tình trạng hoạt động của hệ thống.

Hệ thống hiển thị:

- Thống kê lớp học.
- Thống kê kết quả kiểm tra.
- Thống kê tài khoản.
- Số lượng báo cáo vượt ngưỡng cảnh báo.
- Số lượng báo cáo đang xử lý.
- Phân bố tỷ lệ trùng lặp.
- Thống kê số lượng bài theo từng mức độ trùng lặp.
- Xuất báo cáo thống kê ra tệp Excel.

3.5. Cài đặt thực nghiệm

3.5.1. Cấu hình phần cứng

Hệ thống được triển khai và thực nghiệm trên máy tính cá nhân với cấu hình phần cứng như sau:

- Bộ xử lý (CPU): Intel Core 5 120U.
- Bộ nhớ RAM: 16 GB.
- Ổ cứng: SSD 512 GB.
- Kiến trúc hệ thống: x64-based PC.

3.5.2. Cấu hình phần mềm

Môi trường phát triển và triển khai hệ thống được xây dựng trên nền tảng các công cụ và phần mềm sau:

- Hệ điều hành: Windows 11 Pro Version 25H2 (OS Build 26200.9457).
- Node.js phiên bản 22.22.0.
- MongoDB Server phiên bản 8.3.
- MongoDB Compass phiên bản 1.50.0.
- Redis Server.
- Visual Studio Code phiên bản 1.108.0.
- Git phiên bản 2.55.0.
- Trình duyệt web Google Chrome và Microsoft Edge.

Trong đó:

- Node.js được sử dụng để xây dựng máy chủ ứng dụng và xử lý các yêu cầu từ phía người dùng.
- MongoDB được sử dụng làm hệ quản trị cơ sở dữ liệu để lưu trữ thông tin người dùng, lớp học, bài tập, báo cáo và kết quả kiểm tra.
- Redis được sử dụng kết hợp với BullMQ để quản lý hàng đợi xử lý các tác vụ kiểm tra trùng lặp, giúp nâng cao hiệu năng và giảm tải cho hệ thống khi xử lý nhiều yêu cầu đồng thời.
- Visual Studio Code được sử dụng làm môi trường phát triển chính trong quá trình xây dựng hệ thống.
- Git được sử dụng để quản lý phiên bản mã nguồn.

3.5.3. Bộ dữ liệu thực nghiệm

Bộ dữ liệu được sử dụng trong quá trình thực nghiệm bao gồm các tài liệu học thuật tiếng Việt được thu thập từ nhiều nguồn khác nhau nhằm đánh giá khả năng phát hiện trùng lặp của hệ thống.

Các loại tài liệu sử dụng trong thực nghiệm gồm:

- Báo cáo thực tập cơ sở (TTCS).
- Báo cáo thực tập tốt nghiệp (TTTN).
- Đồ án học phần 1 (DAHP1).
- Đồ án học phần 2 (DAHP2).
- Đồ án tốt nghiệp (DATN).

Các tài liệu được phân loại và lưu trữ trong kho dữ liệu mẫu của hệ thống để làm nguồn tham chiếu phục vụ quá trình kiểm tra trùng lặp. Trong quá trình thực nghiệm,

hệ thống thực hiện đối sánh báo cáo được tải lên với các tài liệu đã lưu trong kho dữ liệu nhằm xác định các nội dung có dấu hiệu tương đồng.

Hệ thống hỗ trợ xử lý các định dạng tài liệu phổ biến như:

- DOCX (.docx)
- PDF (.pdf)

Bộ dữ liệu thực nghiệm được sử dụng để đánh giá khả năng:

- Phát hiện trùng lặp theo từng câu.
- Phát hiện trùng lặp theo từng đoạn văn.
- Phát hiện đạo văn chắp vá từ nhiều nguồn khác nhau.
- Xác định tỷ lệ trùng lặp của toàn bộ tài liệu.
- Thống kê số lượng câu, đoạn văn và nguồn tài liệu có nội dung tương đồng.

Thông qua quá trình thực nghiệm trên bộ dữ liệu thực tế, hệ thống được đánh giá về khả năng phát hiện trùng lặp theo câu, theo đoạn văn, phát hiện đạo văn chắp vá từ nhiều nguồn, tốc độ xử lý và mức độ hỗ trợ đối với các tài liệu học thuật tiếng Việt.

CHƯƠNG 4
KIỂM THỬ VÀ ĐÁNH GIÁ KẾT QUẢ THỰC NGHIỆM

4.1. Kiểm thử chức năng hệ thống

4.1.1. Kiểm thử chức năng đăng ký tài khoản

Mục đích kiểm thử: Kiểm tra khả năng tiếp nhận, kiểm tra tính hợp lệ của dữ liệu đầu vào và tạo tài khoản mới của hệ thống.



Hình 4.1. Giao diện form đăng ký tài khoản

Bảng kiểm thử:

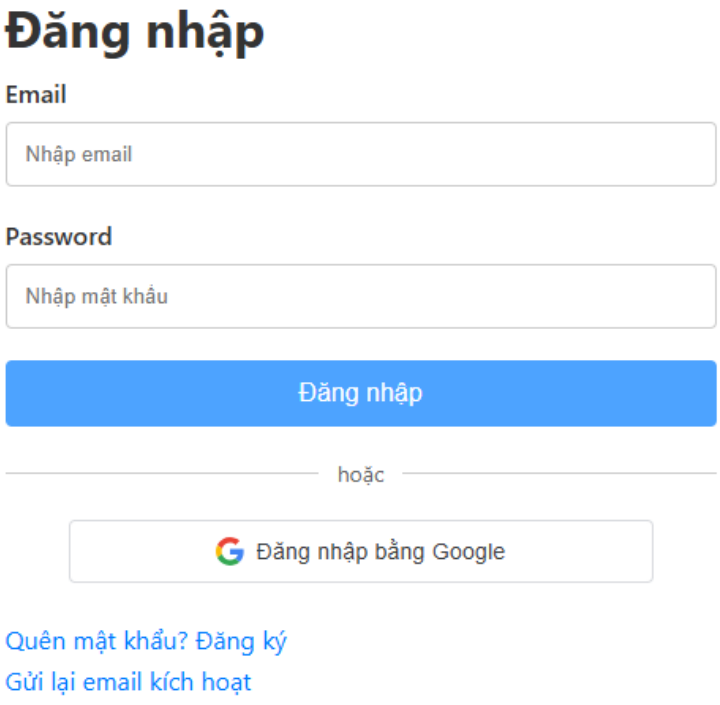
Bảng 4.1. Bảng kiểm thử chức năng đăng ký tài khoản

STT	Trường hợp kiểm thử	Kết quả mong đợi	Kết quả thực tế	Đánh giá
1	Nhập đầy đủ thông tin hợp lệ	Đăng ký thành công	Đăng ký thành công	Đạt
2	Để trống họ tên	Bạn chưa nhập Họ và tên! Vui lòng nhập Họ và tên!	Bạn chưa nhập Họ và tên! Vui lòng nhập Họ và tên!	Đạt
3	Để trống email	Bạn chưa nhập địa chỉ Email! Vui lòng nhập địa chỉ Email!	Bạn chưa nhập địa chỉ Email! Vui lòng nhập địa chỉ Email!	Đạt

4	Email không đúng định dạng	Địa chỉ Email bạn nhập không hợp lệ! Vui lòng kiểm tra lại!	Địa chỉ Email bạn nhập không hợp lệ! Vui lòng kiểm tra lại!	Đạt
5	Để trống mật khẩu	Bạn chưa nhập mật khẩu! Vui lòng nhập mật khẩu!	Bạn chưa nhập mật khẩu! Vui lòng nhập mật khẩu!	Đạt
6	Mật khẩu xác nhận không khớp	Mật khẩu bạn nhập chưa trùng khớp! Vui lòng kiểm tra lại!	Mật khẩu bạn nhập chưa trùng khớp! Vui lòng kiểm tra lại!	Đạt
7	Email đã tồn tại trong hệ thống	Địa chỉ Email này đã được đăng ký!	Địa chỉ Email này đã được đăng ký!	Đạt
8	Đăng ký bằng tài khoản Google	Đăng ký bằng Google thành công!	Đăng ký bằng Google thành công!	Đạt

4.1.2. Kiểm thử chức năng đăng nhập tài khoản

Mục đích kiểm thử: Kiểm tra khả năng xác thực người dùng của hệ thống, đảm bảo chỉ những người dùng có tài khoản hợp lệ mới được phép truy cập và sử dụng các chức năng của hệ thống.



Hình 4.2. Giao diện form đăng nhập tài khoản

Bảng kiểm thử:

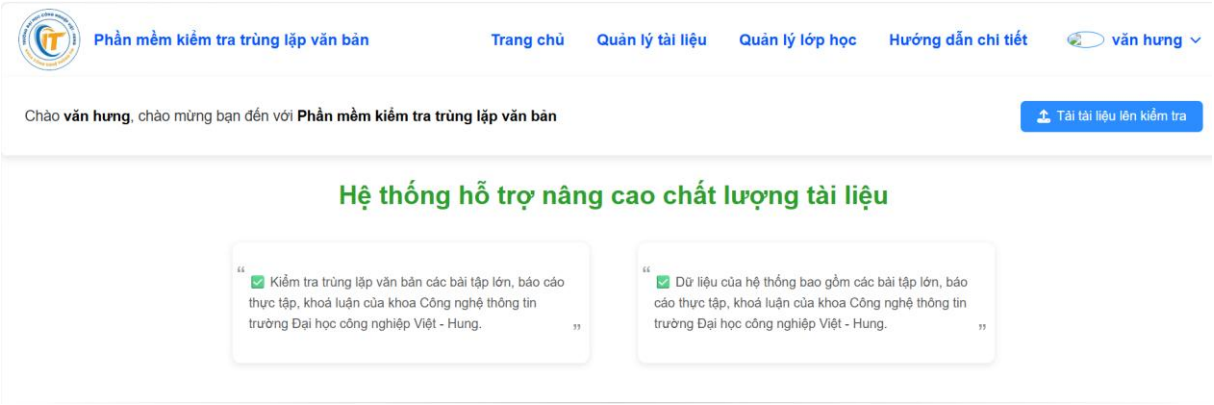
Bảng 4.2. Bảng kiểm thử chức năng đăng nhập tài khoản

STT	Trường hợp kiểm thử	Dữ liệu kiểm thử	Kết quả mong đợi	Kết quả thực tế	Đánh giá
1	Đăng nhập thành công	Email và mật khẩu hợp lệ	Đăng nhập tài khoản thành công! (chuyển đến trang chủ)	Đăng nhập tài khoản thành công! (chuyển đến trang chủ)	Đạt
2	Để trống email	Không nhập email	Mời bạn nhập Email!	Mời bạn nhập Email!	Đạt
3	Email không đúng định dạng	cao980@gmailcom; cao980@gmail.; cao980gmail.com; @gmail.com	Địa chỉ Email không hợp lệ! Vui lòng kiểm tra lại!	Địa chỉ Email không hợp lệ! Vui lòng kiểm tra lại!	Đạt
4	Để trống mật khẩu	Không nhập mật khẩu	Mời bạn nhập mật khẩu!	Mời bạn nhập mật khẩu!	Đạt
5	Email hoặc mật khẩu không chính xác	Sai email hoặc mật khẩu	Email hoặc mật khẩu chưa đúng!	Email hoặc mật khẩu chưa đúng!	Đạt
6	Quên mật khẩu	Email đã đăng ký	Mật khẩu mới đã được gửi lại qua Email!	Mật khẩu mới đã được gửi lại qua Email!	Đạt
7	Quên mật khẩu	Email chưa đăng ký	Không tìm thấy tài khoản!	Không tìm thấy tài khoản!	Đạt
8	Gửi lại email kích hoạt	Email đã đăng ký	Đây là địa chỉ email	Đây là địa chỉ email	Đạt

			bạn muốn kích hoạt lại!	bạn muốn kích hoạt lại!	
9	Gửi lại email kích hoạt	Email chưa đăng ký	Không tìm thấy địa chỉ Email!	Không tìm thấy địa chỉ Email!	Đạt
10	Đăng nhập bằng Google	Chọn tài khoản Google	Đăng nhập thành công!	Đăng nhập thành công!	Đạt

4.1.3. Kiểm thử giao diện trang chủ sau đăng nhập

Mục đích kiểm thử: Kiểm tra khả năng hiển thị thông tin tổng quan của hệ thống sau khi người dùng đăng nhập thành công.



Hình 4.3. Giao diện trang chủ sau đăng nhập

Bảng kiểm thử:

Bảng 4.3. Bảng kiểm thử chức năng giao diện trang chủ sau đăng nhập

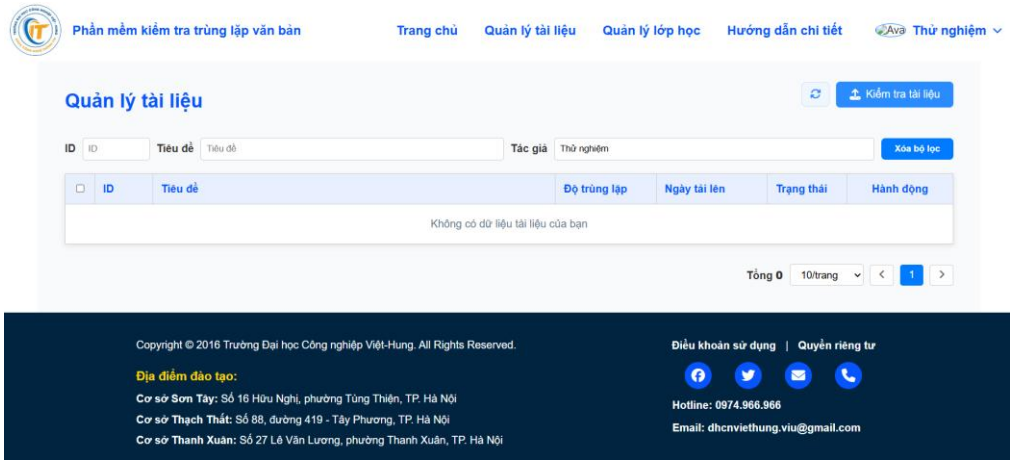
STT	Trường hợp kiểm thử	Kết quả mong đợi	Kết quả thực tế	Đánh giá
1	Truy cập trang chủ sau khi đăng nhập	Hiển thị trang chủ	Hiển thị trang chủ	Đạt
2	Hiển thị thông tin người dùng	Hiển thị họ tên người dùng	Hiển thị họ tên người dùng	Đạt
3	Hiển thị menu chức năng	Hiển thị đầy đủ menu hệ thống	Hiển thị đầy đủ menu hệ thống	Đạt

4	Truy cập Quản lý tài liệu	Chuyển đúng trang	Chuyển đúng trang	Đạt
5	Truy cập Quản lý lớp học	Chuyển đúng trang	Chuyển đúng trang	Đạt
6	Truy cập Hướng dẫn chi tiết	Chuyển đúng trang	Chuyển đúng trang	Đạt

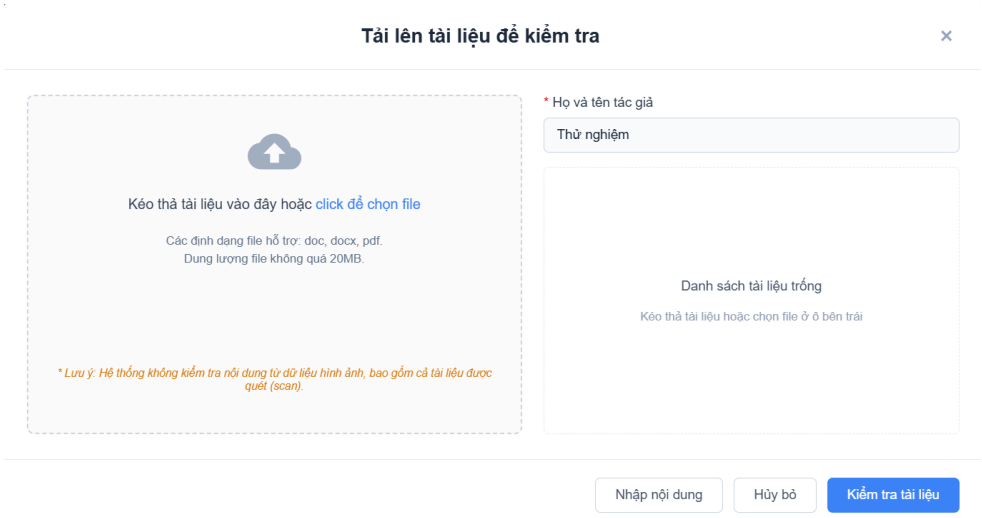
4.1.4. Kiểm thử chức năng quản lý tài liệu

Mục đích kiểm thử: Chức năng quản lý tài liệu cho phép người dùng tải tài liệu lên hệ thống, thực hiện kiểm tra trùng lặp, lưu trữ kết quả kiểm tra và quản lý các tài liệu đã được xử lý. Quá trình kiểm thử nhằm đánh giá khả năng tiếp nhận tài liệu, xử lý dữ liệu đầu vào và quản lý kết quả kiểm tra của hệ thống.

Hình ảnh giao diện:



Hình 4.4. Giao diện quản lý tài liệu



Hình 4.5. Giao diện tải tài liệu kiểm tra

Bảng kiểm thử:

Bảng 4.4. Bảng kiểm thử chức năng tải tài liệu kiểm tra

STT	Trường hợp kiểm thử	Kết quả mong đợi	Kết quả thực tế	Đánh giá
1	Tải tệp DOC hợp lệ	Hiển thị file lên giao diện	Hiển thị file lên giao diện	Đạt
2	Tải tệp DOCX hợp lệ	Hiển thị file lên giao diện	Hiển thị file lên giao diện	Đạt
3	Tải tệp PDF hợp lệ	Hiển thị file lên giao diện	Hiển thị file lên giao diện	Đạt
4	Tải tệp vượt quá 20 MB	File "Thên file" vượt quá dung lượng tối đa 20MB!	File "Tên file" vượt quá dung lượng tối đa 20MB!	Đạt
5	Tải 5 file cùng lúc	Vượt quá giới hạn! Tối đa chỉ được chọn 4 tài liệu.	Vượt quá giới hạn! Tối đa chỉ được chọn 4 tài liệu.	Đạt
6	Tải nhiều lần liên tiếp (1 lần tải tối đa 4 file)	Hệ thống hoạt động bình thường	Hệ thống hoạt động bình thường	Đạt
7	Hiển thị danh sách tài liệu	Hiển thị đầy đủ dữ liệu	Hiển thị đầy đủ dữ liệu	Đạt
8	Xem chi tiết kết quả	Hiển thị trang chi tiết	Hiển thị trang chi tiết	Đạt
9	Chỉnh sửa thông tin báo cáo	Cập nhật thành công	Cập nhật thành công	Đạt
10	Tải xuống báo cáo	Tải xuống thành công	Tải xuống thành công	Đạt
11	Xóa báo cáo	Xóa thành công	Xóa thành công	Đạt

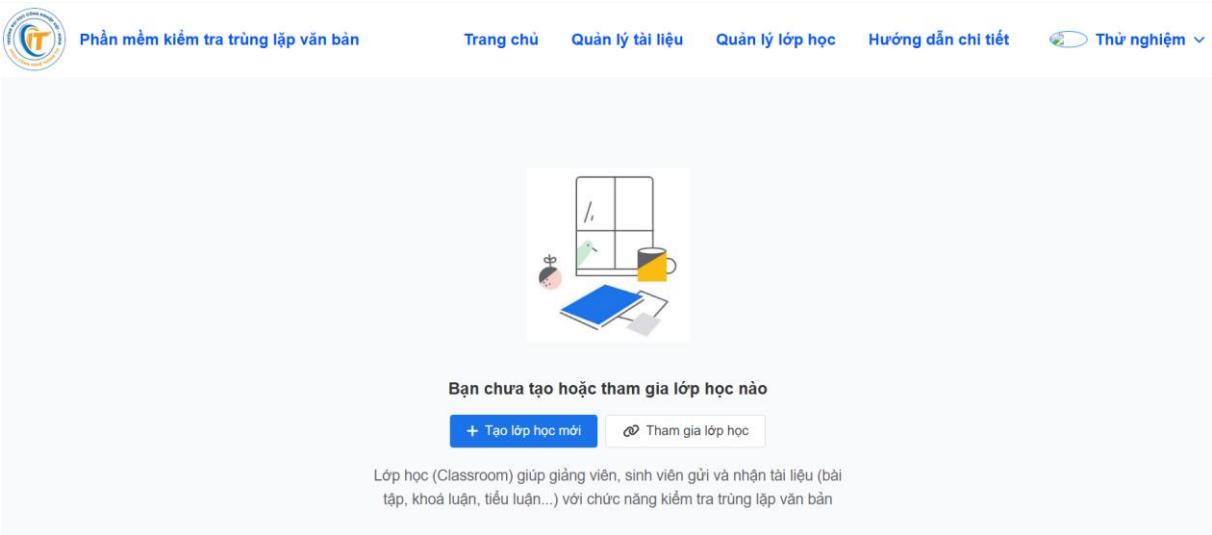
4.1.5. Kiểm thử chức năng quản lý lớp học

Chức năng quản lý lớp học cho phép giảng viên tạo lớp học, quản lý thành viên, quản lý bài tập và theo dõi tình trạng nộp bài của sinh viên. Đối với sinh viên, hệ thống hỗ trợ tham gia lớp học, xem bài tập và thực hiện nộp bài.

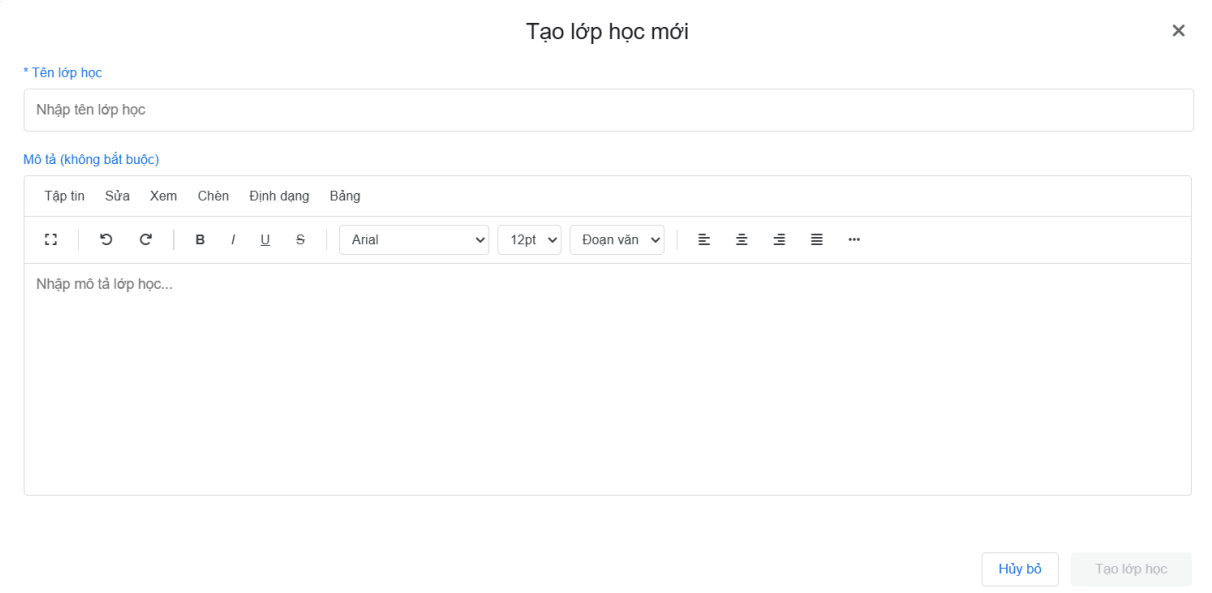
4.1.5.1. Kiểm thử chức năng tạo và tham gia lớp học

Mục đích kiểm thử: Chức năng tạo và tham gia lớp học cho phép người dùng tạo lớp học mới hoặc tham gia các lớp học đã tồn tại thông qua mã lớp học. Quá trình kiểm thử nhằm đánh giá khả năng tiếp nhận dữ liệu đầu vào, kiểm tra tính hợp lệ của thông tin lớp học và quản lý việc tham gia lớp học của người dùng.

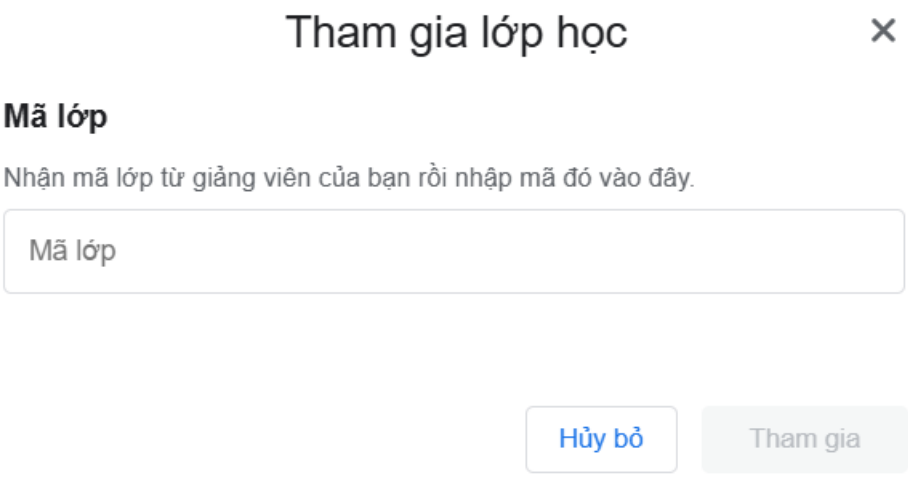
Hình ảnh giao diện:



Hình 4.6. Giao diện tạo và tham gia lớp học



Hình 4.7. Giao diện tạo lớp học



Hình 4.8. Giao diện tham gia lớp học

Bảng kiểm thử:

Bảng 4.5. Bảng kiểm thử chức năng tạo và tham gia lớp học

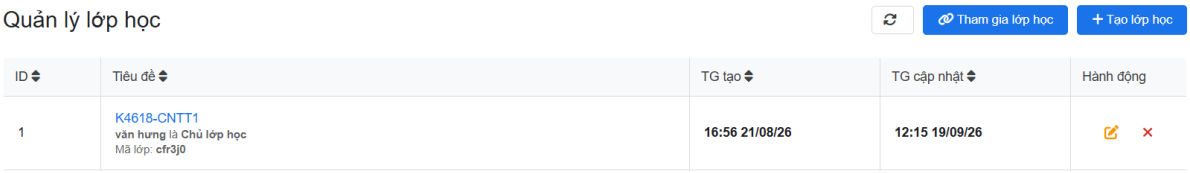
STT	Trường hợp kiểm thử	Kết quả mong đợi	Kết quả thực tế	Đánh giá
1	Nhập đầy đủ thông tin lớp học	Tạo lớp học thành công	Tạo lớp học thành công	Đạt
2	Không nhập tên lớp học	Nút "Tạo lớp học" bị vô hiệu hóa	Nút "Tạo lớp học" bị vô hiệu hóa	Đạt
3	Nhập tên lớp học, bỏ trống mô tả	Tạo lớp học thành công	Tạo lớp học thành công	Đạt
4	Tạo nhiều lớp học liên tiếp	Hệ thống hoạt động bình thường	Hệ thống hoạt động bình thường	Đạt
5	Nhập mã lớp học hợp lệ	Tham gia lớp học thành công	Tham gia lớp học thành công	Đạt
6	Để trống mã lớp học	Nút "Tham gia" bị vô hiệu hóa	Nút "Tham gia" bị vô hiệu hóa	Đạt
7	Nhập mã lớp không tồn tại	Mã lớp không tồn tại!	Mã lớp không tồn tại!	Đạt
8	Chủ lớp nhập mã lớp của chính mình	Bạn là chủ lớp học này rồi!	Bạn là chủ lớp học này rồi!	Đạt

9	Thành viên đã tham gia lớp học tiếp tục nhập mã lớp	Bạn đã tham gia lớp học này trước đó rồi!	Bạn đã tham gia lớp học này trước đó rồi!	

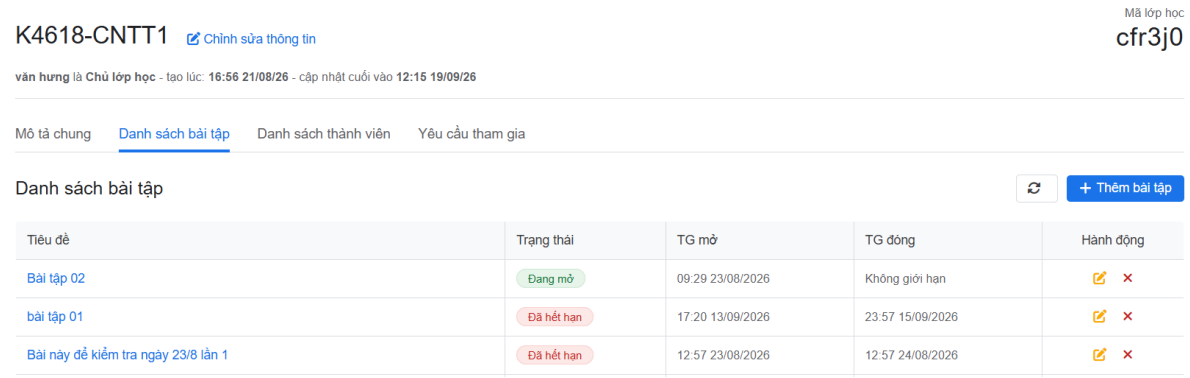
4.1.5.2. Kiểm thử chức năng quản lý lớp học của chủ lớp

Mục đích kiểm thử: Kiểm tra khả năng quản lý lớp học của chủ lớp, bao gồm cập nhật thông tin lớp học, quản lý thành viên, quản lý bài tập và theo dõi tình trạng nộp bài của sinh viên.

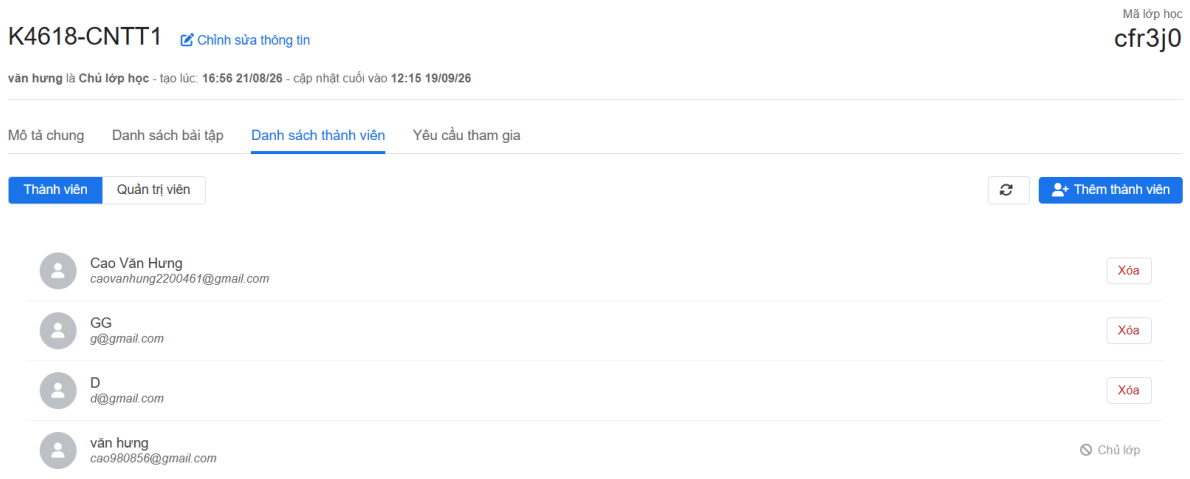
Hình ảnh giao diện:



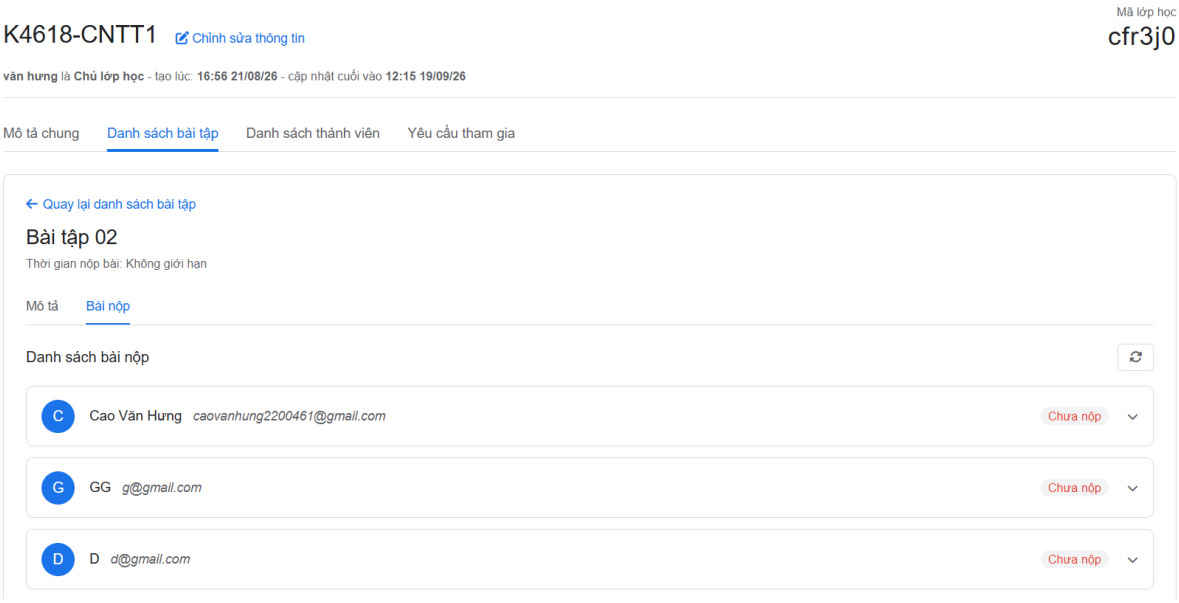
Hình 4.9. Giao diện quản lý lớp học



Hình 4.10. Giao diện danh sách bài tập trong lớp



Hình 4.11. Giao diện quản lý thành viên trong lớp



Hình 4.12. Giao diện theo dõi bài nộp

Bảng kiểm thử:

Bảng 4.6. Bảng kiểm thử chức năng quản lý lớp học của chủ lớp

STT	Trường hợp kiểm thử	Kết quả mong đợi	Kết quả thực tế	Đánh giá
1	Cập nhật thông tin lớp học	Cập nhật thông tin lớp học thành công trên CSDL và giao diện!	Cập nhật thông tin lớp học thành công trên CSDL và giao diện!	Đạt
2	Xóa lớp học	Bạn có chắc chắn muốn xóa lớp học này không?	Bạn có chắc chắn muốn xóa lớp học này không?	Đạt
3	Hiển thị danh sách thành viên	Hiển thị chính xác	Hiển thị chính xác	Đạt
4	Thêm thành viên vào lớp	Thêm thành công 1 thành viên!	Thêm thành công 1 thành viên!	Đạt
5	Xóa thành viên khỏi lớp	Không còn tài khoản thành viên đó trong lớp trên giao diện và trong csdl	Không còn tài khoản thành viên đó trong lớp trên giao diện và trong csdl	Đạt

6	Tạo bài tập mới	Bài tập mới tạo sẽ được hiển thị lên giao diện và cập nhật vào csdl	Bài tập mới tạo sẽ được hiển thị lên giao diện và cập nhật vào csdl	Đạt
7	Cập nhật bài tập	Cập nhật bài tập và lưu vào CSDL thành công!	Cập nhật bài tập và lưu vào CSDL thành công!	Đạt
8	Xóa bài tập	Bạn có chắc chắn muốn xóa bài tập này không?	Bạn có chắc chắn muốn xóa bài tập này không?	Đạt
9	Hiển thị danh sách bài tập	Hiển thị chính xác	Hiển thị chính xác	Đạt
10	Hiển thị trạng thái bài tập	Hiển thị chính xác	Hiển thị chính xác	Đạt
11	Theo dõi danh sách bài nộp	Hiển thị chính xác	Hiển thị chính xác	Đạt
12	Xem chi tiết bài nộp	Hiển thị chính xác	Hiển thị chính xác	Đạt
13	Tải xuống bài nộp	Tải xuống thành công	Tải xuống thành công	Đạt

4.1.5.3. Kiểm thử chức năng quản lý lớp học của thành viên

Kết quả kiểm thử cho thấy sinh viên có thể xem đầy đủ danh sách bài tập được giao trong lớp học, bao gồm tiêu đề bài tập, trạng thái, thời gian mở và thời gian đóng bài tập.

Khi truy cập vào chi tiết bài tập, hệ thống hiển thị trạng thái nộp bài của sinh viên. Đối với các bài tập chưa được nộp, hệ thống hiển thị trạng thái 0/1 (chưa nộp) và cung cấp chức năng “Thêm file nộp” để sinh viên lựa chọn tài liệu đã được kiểm tra trong danh mục tài liệu của mình.

Khi thực hiện thao tác nộp bài, hệ thống mở cửa sổ lựa chọn tài liệu và hiển thị danh sách các báo cáo đã được kiểm tra, bao gồm mã báo cáo, tiêu đề báo cáo, thời gian tải lên và tỷ lệ trùng lặp. Sinh viên có thể lựa chọn một hoặc nhiều tài liệu phù hợp để gửi cho bài tập.

Sau khi nộp bài thành công, hệ thống chuyển trạng thái từ 0/1 sang 1/1 (đã nộp), đồng thời hiển thị tên bài nộp, thời gian cập nhật và các chức năng quản lý bài nộp như:

- Tải xuống bài nộp.
- Chỉnh sửa bài nộp.
- Xóa bài nộp.

Thông tin bài nộp được đồng bộ tới giao diện theo dõi bài tập của giảng viên, giúp chủ lớp dễ dàng kiểm tra và đánh giá quá trình nộp bài của sinh viên.

Bảng kiểm thử:

Bảng 4.7. Bảng kiểm thử chức năng quản lý lớp học của thành viên

STT	Trường hợp kiểm thử	Kết quả mong đợi	Kết quả thực tế	Đánh giá
1	Nộp bài thành công	Trạng thái chuyển từ 0/1 sang 1/1 Nộp bài tập thành công!	Trạng thái chuyển từ 0/1 sang 1/1 Nộp bài tập thành công!	Đạt
2	Hiển thị tên bài nộp	Hiển thị chính xác	Hiển thị chính xác	Đạt
3	Chỉnh sửa bài nộp	Cập nhật thành công	Cập nhật thành công	Đạt
4	Xóa bài nộp	Xóa thành công	Xóa thành công	Đạt
5	Tải xuống bài nộp	Tải xuống thành công	Tải xuống thành công	Đạt

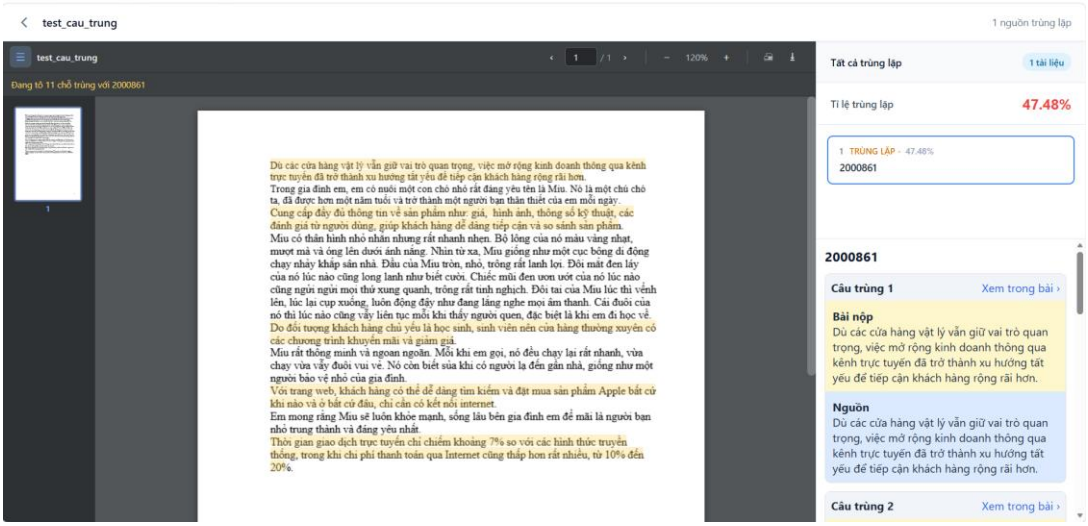
4.1.6. Kiểm thử chức năng kiểm tra trùng lặp văn bản

4.1.6.1. Kiểm thử chức năng phát hiện câu trùng lặp

Mục đích kiểm thử: Chức năng phát hiện câu trùng lặp được kiểm thử nhằm đánh giá khả năng phát hiện các câu có nội dung giống hoặc tương đồng với tài liệu nguồn trong kho dữ liệu tham chiếu.

Kịch bản kiểm thử: Tài liệu kiểm thử được xây dựng bằng cách chèn các câu được sao chép từ tài liệu có mã **2000861** vào giữa các đoạn văn tự viết. Các câu được bố trí rời rạc và không đặt liên tiếp nhau nhằm đảm bảo hệ thống chỉ ghi nhận đây là các câu trùng lặp riêng lẻ, không hình thành đoạn văn trùng lặp.

Hình ảnh kết quả thực nghiệm



Hình 4.13. Kết quả phát hiện câu trùng lặp

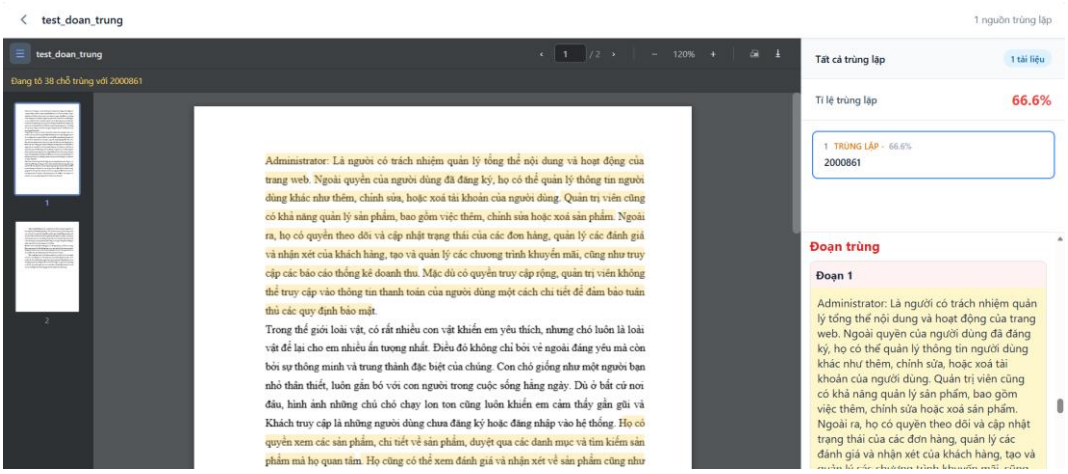
Kết quả kiểm tra cho thấy hệ thống phát hiện được **11 vị trí trùng lặp (tương ứng với 5 câu được chia thành 11 hàng)** từ **01 nguồn tài liệu tham chiếu**, với tỷ lệ trùng lặp đạt **47,48%**. Hệ thống đồng thời hiển thị câu trùng trong bài nộp và câu tương ứng trong tài liệu nguồn, giúp người dùng dễ dàng đối chiếu và xác minh nội dung tương đồng.

4.1.6.2. Kiểm thử chức năng phát hiện đoạn trùng lặp

Mục đích kiểm thử: Đánh giá khả năng phát hiện các đoạn văn có nội dung được sao chép nguyên vẹn từ tài liệu nguồn.

Kịch bản kiểm thử: Tài liệu kiểm thử được xây dựng bằng cách sao chép liên tiếp nhiều câu từ tài liệu có mã **2000861**, tạo thành các đoạn văn hoàn chỉnh. Các đoạn này được xen kẽ với nội dung tự viết nhằm mô phỏng tình huống sao chép từng phần trong tài liệu thực tế.

Hình ảnh kết quả thực nghiệm



Hình 4.14. Kết quả phát hiện đoạn trùng lặp

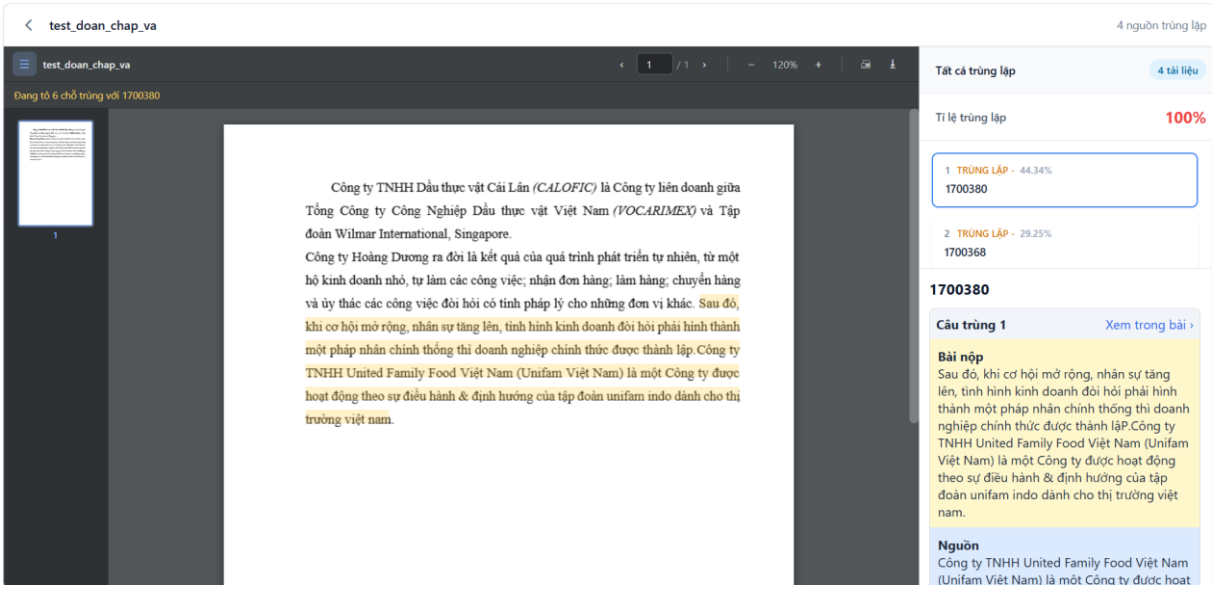
Kết quả kiểm tra cho thấy hệ thống phát hiện **38 vị trí trùng lặp**, xác định được **01 nguồn tương đồng** và tính toán tỷ lệ trùng lặp đạt **66,6%**. Thay vì hiển thị riêng lẻ từng câu, hệ thống tự động nhóm các câu trùng liên tiếp thành một đoạn văn hoàn chỉnh và trình bày tại khu vực **Đoạn trùng**, giúp người dùng dễ dàng nhận biết các trường hợp sao chép nguyên đoạn.

4.1.6.3. Kiểm thử chức năng phát hiện đoạn chắp vá

Mục đích kiểm thử: Đánh giá khả năng phát hiện các tài liệu được hình thành từ nhiều nguồn khác nhau, một trong những dạng đạo văn phổ biến hiện nay.

Kịch bản kiểm thử: Tài liệu kiểm thử được xây dựng bằng cách ghép nhiều đoạn văn lấy từ các tài liệu khác nhau trong kho dữ liệu mẫu. Các đoạn văn này được sắp xếp lại thành một tài liệu mới nhằm mô phỏng hành vi đạo văn chắp vá, trong đó nội dung được tổng hợp từ nhiều nguồn thay vì sao chép nguyên văn từ một tài liệu duy nhất.

Hình ảnh kết quả thực nghiệm



Hình 4.15. Kết quả phát hiện đạo văn chắp vá

Kết quả kiểm tra cho thấy hệ thống phát hiện được **04 tài liệu tương đồng** với tài liệu kiểm thử và tỷ lệ trùng lặp đạt **100%**. Trong số các tài liệu được phát hiện, báo cáo có mã **1700288** tồn tại dưới hai định dạng khác nhau (DOCX và PDF), do đó hệ thống ghi nhận thành hai tài liệu riêng biệt. Hệ thống chỉ ra chính xác nguồn gốc của từng đoạn văn bị sao chép, giúp người dùng dễ dàng xác định nội dung được lấy từ tài liệu nào.

4.2. Đánh giá kết quả thực nghiệm

4.2.1. Đánh giá khả năng phát hiện trùng lặp văn bản

Kết quả thực nghiệm trên các bộ dữ liệu kiểm thử được xây dựng có chủ đích cho thấy hệ thống có khả năng phát hiện hiệu quả các nội dung trùng lặp trong tài liệu học thuật tiếng Việt.

Đối với các trường hợp sao chép nguyên văn ở mức câu, hệ thống xác định chính xác các câu có nội dung tương đồng và hiển thị đầy đủ thông tin nguồn tham chiếu. Các câu trùng lặp được trình bày trực quan giúp người dùng dễ dàng đối chiếu nội dung giữa bài nộp và tài liệu nguồn.

Đối với các trường hợp sao chép liên tiếp nhiều câu, hệ thống không chỉ phát hiện từng câu riêng lẻ mà còn thực hiện gom nhóm thành các đoạn văn trùng lặp. Điều này giúp kết quả kiểm tra trực quan hơn và hỗ trợ người dùng nhanh chóng xác định các phần nội dung bị sao chép trong tài liệu.

Đối với các trường hợp đạo văn chắp vá, hệ thống phát hiện được các nguồn nội dung khác nhau được sử dụng để hình thành tài liệu kiểm thử. Kết quả cho thấy hệ thống có khả năng nhận diện và truy vết nguồn gốc của các đoạn văn tương đồng ngay cả khi nội dung được tổng hợp từ nhiều tài liệu khác nhau.

4.2.2. Đánh giá khả năng xác định nguồn tham chiếu

Bên cạnh việc xác định tỷ lệ trùng lặp, khả năng truy vết và xác định chính xác nguồn tham chiếu của các nội dung tương đồng cũng là một tiêu chí quan trọng đối với hệ thống kiểm tra trùng lặp văn bản. Việc xác định đúng nguồn giúp người sử dụng dễ dàng kiểm chứng kết quả, đánh giá phạm vi sao chép và truy xuất tài liệu gốc phục vụ quá trình đối chiếu.

Kết quả thực nghiệm cho thấy hệ thống có khả năng xác định chính xác các nguồn tài liệu tham chiếu liên quan đến nội dung trùng lặp. Trong kịch bản kiểm thử phát hiện câu trùng lặp, hệ thống phát hiện được 01 nguồn tham chiếu và chỉ ra chính xác các câu tương ứng giữa tài liệu kiểm tra và tài liệu nguồn. Đối với kịch bản phát hiện đoạn trùng lặp, hệ thống tiếp tục xác định đúng nguồn chứa các đoạn văn bị sao chép và liên kết các đoạn văn này với tài liệu gốc.

Đặc biệt, trong kịch bản kiểm thử đạo văn chắp vá, tài liệu kiểm thử được xây dựng từ nhiều nguồn khác nhau trong kho dữ liệu mẫu. Kết quả cho thấy hệ thống phát hiện đầy đủ các nguồn tham gia hình thành nội dung của tài liệu và xác định được từng

đoạn văn tương ứng với từng nguồn tham chiếu. Mặc dù có trường hợp cùng một tài liệu tồn tại dưới nhiều định dạng khác nhau như DOCX và PDF, hệ thống vẫn nhận diện chính xác nội dung tương đồng và ghi nhận đầy đủ các nguồn liên quan.

Thông qua kết quả thực nghiệm, có thể nhận thấy hệ thống không chỉ phát hiện được nội dung trùng lặp mà còn hỗ trợ hiệu quả việc truy vết nguồn gốc của các nội dung được phát hiện. Đây là cơ sở quan trọng giúp nâng cao tính minh bạch của kết quả kiểm tra và hỗ trợ người sử dụng trong quá trình đánh giá tính nguyên bản của tài liệu.

4.2.3. Đánh giá mức độ đáp ứng mục tiêu đề tài

Mục tiêu chính của đề tài là xây dựng hệ thống kiểm tra trùng lặp văn bản tiếng Việt có khả năng phát hiện nội dung tương đồng theo nhiều cấp độ khác nhau, đồng thời hỗ trợ quản lý tài liệu học thuật trong môi trường đào tạo.

Kết quả thực nghiệm cho thấy hệ thống đã đáp ứng đầy đủ các mục tiêu đề ra.

Bảng 4.8. Bảng đánh giá mức độ đáp ứng mục tiêu của đề tài

Mục tiêu đề tài	**Kết quả**
Phát hiện câu trùng	Đạt
Phát hiện đoạn trùng	Đạt
Phát hiện đoạn chắp vá	Đạt
Xác định nguồn tài liệu tương đồng	Đạt
Hiển thị kết quả trực quan	Đạt
Quản lý tài liệu	Đạt
Quản lý lớp học	Đạt
Highlight báo cáo	Đạt
Thống kê báo cáo	Đạt

KẾT LUẬN

1. Kết quả đạt được

Sau quá trình nghiên cứu, phân tích, thiết kế, xây dựng và thực nghiệm, đề tài "Nghiên cứu xây dựng mô hình kiểm tra trùng lặp văn bản dựa trên xử lý ngôn ngữ tự nhiên" đã hoàn thành các mục tiêu nghiên cứu đặt ra ban đầu.

Về mặt lý thuyết, đề tài đã nghiên cứu và hệ thống hóa các cơ sở khoa học liên quan đến bài toán phát hiện trùng lặp văn bản, bao gồm các khái niệm về liêm chính học thuật, đạo văn, xử lý ngôn ngữ tự nhiên, các phương pháp tiền xử lý văn bản tiếng Việt, các phương pháp biểu diễn văn bản, độ đo tương đồng văn bản và kỹ thuật dấu vân tay văn bản dựa trên thuật toán Winnowing. Đề tài đồng thời phân tích các đặc điểm riêng của tiếng Việt và những khó khăn khi áp dụng các kỹ thuật xử lý ngôn ngữ tự nhiên vào bài toán phát hiện nội dung trùng lặp.

Về mặt hệ thống, đề tài đã xây dựng thành công một hệ thống kiểm tra trùng lặp văn bản trên nền tảng Web với đầy đủ các chức năng quản lý người dùng, quản lý tài liệu, quản lý lớp học, quản lý bài tập, quản lý bài nộp, thống kê báo cáo và kiểm tra trùng lặp văn bản. Hệ thống cho phép người dùng thực hiện kiểm tra tài liệu trực tuyến, theo dõi kết quả kiểm tra và quản lý các hoạt động học thuật trong cùng một môi trường làm việc thống nhất.

Một trong những đóng góp quan trọng của đề tài là xây dựng mô hình phát hiện trùng lặp văn bản dựa trên sự kết hợp của nhiều phương pháp khác nhau gồm thuật toán Winnowing, mô hình TF-IDF, độ đo Cosine Similarity và Jaccard Similarity. Thay vì sử dụng riêng lẻ một thuật toán, đề tài đề xuất mô hình lai (Hybrid Model) nhằm tận dụng ưu điểm của từng phương pháp trong quá trình phát hiện nội dung tương đồng.

Tính mới của đề tài được thể hiện ở một số điểm nổi bật sau:

- Xây dựng mô hình phát hiện trùng lặp văn bản tiếng Việt dựa trên sự kết hợp của nhiều phương pháp xử lý khác nhau nhằm nâng cao chất lượng phát hiện.
- Đề xuất cơ chế phát hiện trùng lặp ở nhiều cấp độ gồm mức câu, mức đoạn văn và mức toàn bộ tài liệu thay vì chỉ đánh giá tỷ lệ trùng lặp tổng thể.
- Xây dựng chức năng phát hiện đạo văn chắp vá từ nhiều nguồn khác nhau thông qua việc tổng hợp và phân tích các đoạn nội dung tương đồng xuất hiện trong cùng một tài liệu.

- Xây dựng cơ chế hiển thị kết quả trực quan giúp người dùng xác định được câu trùng, đoạn trùng, nguồn trùng lặp và vị trí xuất hiện nội dung tương đồng trong tài liệu.
- Kết hợp chức năng kiểm tra trùng lặp với các chức năng quản lý lớp học, quản lý bài tập và quản lý bài nộp trong cùng một hệ thống thống nhất.
- Triển khai cơ chế xử lý bất đồng bộ bằng Redis và BullMQ nhằm nâng cao hiệu năng xử lý đối với các tác vụ kiểm tra tài liệu có kích thước lớn.

  Kết quả thực nghiệm cho thấy hệ thống có khả năng:
- Phát hiện các câu trùng lặp giữa tài liệu kiểm tra và tài liệu nguồn.
- Phát hiện các đoạn văn được sao chép liên tiếp.
- Phát hiện các trường hợp đạo văn chắp vá từ nhiều nguồn khác nhau.
- Xác định và hiển thị nguồn tài liệu tương đồng.
- Tính toán tỷ lệ trùng lặp của tài liệu.
- Hỗ trợ người dùng tra cứu và theo dõi kết quả kiểm tra một cách trực quan.
- Hỗ trợ các hoạt động quản lý lớp học, quản lý bài tập và quản lý bài nộp.

2. Những hạn chế còn tồn tại

Mặc dù đã đạt được các mục tiêu nghiên cứu đề ra, hệ thống vẫn còn tồn tại một số hạn chế nhất định:

- Khả năng phát hiện các trường hợp đạo văn diễn giải sâu vẫn còn hạn chế. Trong trường hợp người viết thay đổi đáng kể cấu trúc câu, sử dụng nhiều từ đồng nghĩa hoặc diễn đạt lại nội dung theo cách khác nhưng vẫn giữ nguyên ý nghĩa, độ chính xác của kết quả phát hiện có thể giảm so với các trường hợp sao chép nguyên văn.
- Hiệu quả phát hiện trùng lặp của hệ thống phụ thuộc vào quy mô và chất lượng của kho dữ liệu đối sánh. Đối với các nội dung chưa tồn tại trong cơ sở dữ liệu tham chiếu, hệ thống sẽ không thể phát hiện được các mối liên hệ tương đồng tương ứng.
- Khi số lượng tài liệu trong kho dữ liệu tăng lên đáng kể, thời gian xử lý và đối sánh giữa các tài liệu có thể tăng theo. Điều này có thể ảnh hưởng đến hiệu năng tổng thể của hệ thống nếu không có các giải pháp tối ưu bổ sung.

- Hệ thống hiện tại chủ yếu tập trung vào việc phát hiện sự tương đồng dựa trên nội dung văn bản tiếng Việt. Việc đánh giá mức độ tương đồng ngữ nghĩa ở mức chuyên sâu vẫn chưa được triển khai đầy đủ và cần được tiếp tục nghiên cứu trong tương lai.
- Các ngưỡng đánh giá mức độ trùng lặp hiện nay được xác định dựa trên quá trình thực nghiệm với bộ dữ liệu hiện có. Khi áp dụng cho các lĩnh vực chuyên ngành khác nhau, các ngưỡng này có thể cần được điều chỉnh để phù hợp với đặc điểm dữ liệu thực tế.
- Hệ thống mới tập trung vào việc phát hiện và đánh giá sự tương đồng về nội dung văn bản. Các yếu tố học thuật khác như chất lượng lập luận, chất lượng trích dẫn hoặc tính mới của ý tưởng nghiên cứu chưa được xem xét trong phạm vi của đề tài.

3. Hướng phát triển trong tương lai

Từ kết quả nghiên cứu đạt được, đề tài đề xuất một số kiến nghị và hướng phát triển trong tương lai như sau:

Đối với hoạt động nghiên cứu

- Tiếp tục nghiên cứu các phương pháp xử lý ngữ nghĩa hiện đại nhằm nâng cao khả năng phát hiện đạo văn diễn giải, đặc biệt đối với các trường hợp thay đổi mạnh về cấu trúc câu nhưng vẫn giữ nguyên ý nghĩa nội dung.
- Nghiên cứu các kỹ thuật đánh giá mức độ tương đồng ngữ nghĩa để bổ sung cho các phương pháp đối sánh hiện tại.
- Nghiên cứu cơ chế phát hiện nội dung được tạo ra bởi các hệ thống trí tuệ nhân tạo tạo sinh như ChatGPT, Gemini, Copilot và các công cụ AI khác.

Đối với hệ thống phần mềm

- Mở rộng quy mô kho dữ liệu đối sánh nhằm nâng cao khả năng phát hiện nội dung tương đồng.
- Tối ưu hóa hiệu năng hệ thống để giảm thời gian xử lý khi số lượng tài liệu cần kiểm tra ngày càng lớn.
- Hỗ trợ thêm nhiều định dạng tài liệu bên cạnh DOC, DOCX và PDF.
- Bổ sung chức năng kiểm tra lỗi chính tả, lỗi ngữ pháp và hỗ trợ chỉnh sửa văn bản.

- Bổ sung chức năng đánh giá chất lượng trích dẫn và tài liệu tham khảo.
- Mở rộng hệ thống thống kê và báo cáo phục vụ công tác quản lý đào tạo.

Đối với khả năng ứng dụng thực tiễn

- Triển khai thử nghiệm hệ thống trong phạm vi các học phần, đồ án và khóa luận tốt nghiệp nhằm đánh giá hiệu quả trên quy mô thực tế.
- Tích hợp hệ thống với các nền tảng quản lý học tập và quản lý đào tạo của nhà trường nhằm hỗ trợ quy trình giao bài, nộp bài và kiểm tra trùng lặp.
- Xây dựng cơ chế chia sẻ dữ liệu tham chiếu giữa nhiều đơn vị đào tạo nhằm nâng cao hiệu quả phát hiện trùng lặp.
- Mở rộng khả năng hỗ trợ đa ngôn ngữ để đáp ứng nhu cầu kiểm tra các tài liệu sử dụng đồng thời tiếng Việt và các ngôn ngữ khác.

TÀI LIỆU THAM KHẢO

Tài liệu tiếng Việt

[1] Bộ Giáo dục và Đào tạo (2021). *Thông tư số 08/2021/TT-BGDĐT ban hành Quy chế đào tạo trình độ đại học*. Hà Nội.

[2] Đinh Điền (2018). *Xử lý ngôn ngữ tự nhiên*. Nhà xuất bản Đại học Quốc gia Thành phố Hồ Chí Minh, Hồ Chí Minh.

[3] Hà Quang Thụy (2009). *Giáo trình Khai phá dữ liệu Web*. Nhà xuất bản Giáo dục Việt Nam, Hà Nội.

[4] Nguyễn Văn Ba (2003). *Phân tích và thiết kế hệ thống thông tin*. Nhà xuất bản Đại học Quốc gia Hà Nội, Hà Nội.

Tài liệu tiếng Anh

[5] Jaccard, P. (1901). *Étude Comparative de la Distribution Florale dans une Portion des Alpes et des Jura*. Bulletin de la Société Vaudoise des Sciences Naturelles.

[6] Jurafsky, D. and Martin, J. H. (2024). Speech and Language Processing. 3rd Edition, Pearson Education, New Jersey.

[7] Manning, C. D., Raghavan, P. and Schütze, H. (2008). Introduction to Information Retrieval. Cambridge University Press, Cambridge.

[8] McCabe, D. L., Butterfield, K. D. and Trevino, L. K. (2012). *Cheating in College: Why Students Do It and What Educators Can Do About It*. Johns Hopkins University Press, Baltimore.

[9] Ramos, J. (2003). *Using TF-IDF to Determine Word Relevance in Document Queries*. Rutgers University, New Jersey.

[10] Salton, G. and Buckley, C. (1988). *Term-Weighting Approaches in Automatic Text Retrieval*. Information Processing & Management.

[11] Salton, G., Wong, A. and Yang, C. S. (1975). *A Vector Space Model for Automatic Indexing*. Communications of the ACM.

[12] Schleimer, S., Wilkerson, D. S. and Aiken, A. (2003). *Winnowing: Local Algorithms for Document Fingerprinting*. Proceedings of the ACM SIGMOD International Conference on Management of Data.

Tài liệu Internet

[13] BullMQ (2026). *BullMQ Documentation*. Truy cập ngày 15/09/2026 tại: https://docs.bullmq.io

[14] Express.js (2026). *Express Documentation*. Truy cập ngày 15/09/2026 tại: https://expressjs.com

[15] International Center for Academic Integrity (2025). *Academic Integrity Statistics*. Truy cập ngày 15/09/2026 tại: https://academicintegrity.org

[16] MongoDB Inc. (2026). *MongoDB Documentation*. Truy cập ngày 15/09/2026 tại: https://www.mongodb.com/docs

[17] Node.js (2026). Node.js Documentation. Truy cập ngày 15/09/2026 tại: https://nodejs.org/docs

[18] Plagiarism Detector Team (2025). *Plagiarism Statistics 2025: Facts, Trends, and Research Data*. Truy cập ngày 15/09/2026 tại: https://plagiarism-detector.com/en/plagiarism-statistics

[19] Redis Ltd. (2026). *Redis Documentation*. Truy cập ngày 15/09/2026 tại: https://redis.io/docs

[20] Scribbr (2024). *Types of Plagiarism*. Truy cập ngày 15/09/2026 tại: https://www.scribbr.com/plagiarism/types-of-plagiarism/

[21] Turnitin (2025). *How Similarity Reports Work*. Truy cập ngày 15/09/2026 tại: https://www.turnitin.com